

Lista de exercícios 4 de C24 - Inteligência Artificial

Transformações de dados

Exercícios teóricos

1. Se um cientista de dados utiliza o conjunto de teste para ajustar os hiperparâmetros de um modelo e escolher a melhor arquitetura, qual é a consequência técnica direta dessa ação?

- A) O modelo terá um desempenho superior no mundo real, pois foi otimizado com dados inéditos.
- B) Ocorre vazamento de dados (data leakage), invalidando a estimativa imparcial do desempenho real do modelo.
- C) O modelo sofrerá de underfitting, pois o conjunto de teste é geralmente menor que o de treinamento.
- D) O conjunto de validação torna-se o único capaz de simular dados nunca vistos pelo modelo.

2. Ao aplicar a Normalização (Min-Max Scaling) em um atributo que possui um único valor extremamente alto (um outlier discrepante), o que acontece com a distribuição dos demais valores "normais" após a transformação?

- A) Eles serão distribuídos uniformemente entre os valores -1 e 1.
- B) Eles permanecerão inalterados, pois a fórmula utiliza apenas a média dos dados.
- C) Eles serão "esmagados" para um intervalo muito pequeno próximo de zero, perdendo a distinção entre eles.
- D) Eles assumirão valores negativos, já que o outlier puxa o ponto central para cima.

3. Em qual cenário o uso do Robust Scaling é tecnicamente superior ao Standard Scaling (Padronização)?

- A) Quando os dados seguem uma distribuição perfeitamente Gaussiana (Normal).
- B) Quando o objetivo é garantir que os dados fiquem estritamente limitados entre 0 e 1.
- C) Quando o conjunto de dados possui outliers significativos que podem distorcer a média e o desvio padrão.
- D) Quando o modelo de Machine Learning utilizado é uma Árvore de Decisão, que exige dados centrados.

4. Considere um atributo categórico "Cidade" com 500 nomes diferentes em um dataset de 1.000 linhas. Por que o One-Hot Encoding não seria a escolha ideal para codificar essa variável?

- A) Porque ele introduz uma ordem falsa entre as cidades, prejudicando modelos lineares.

- B) Porque ele gera alta dimensionalidade (muitas colunas), podendo causar a "maldição da dimensionalidade".
- C) Porque ele substitui o nome da cidade pela média do alvo, causando overfitting.
- D) Porque ele só funciona com categorias que possuem uma hierarquia clara.

5. Qual é o principal risco de utilizar o Target Encoding em categorias que aparecem pouquíssimas vezes no conjunto de treinamento?

- A) Aumento excessivo da dimensionalidade do dataset.
- B) O modelo pode sofrer overfitting, pois a média do alvo para essa categoria pode refletir ruído e não um padrão real.
- C) Perda total da informação sobre a variância dos atributos numéricos.
- D) Incompatibilidade com algoritmos baseados em distância, como o KNN.

6. Um cientista de dados cria um novo atributo chamado "Valor por Metro Quadrado" dividindo o "Preço da Casa" pela "Área". Essa prática é um exemplo de:

- A) Extração de Atributos, pois reduz o número total de variáveis.
- B) Seleção de Atributos, pois escolhe as variáveis mais importantes.
- C) Engenharia de Atributos, pois cria um novo atributo mais informativo a partir de interações entre os existentes.
- D) Padronização, pois coloca o preço e a área na mesma escala.

7. Sobre a técnica de PCA (Análise de Componentes Principais), o que acontece se os dados originais apresentarem um padrão de distribuição curvo ou circular?

- A) O PCA identificará o centro do círculo e extrairá a curvatura perfeitamente.
- B) O desempenho será insatisfatório, pois o PCA assume relações lineares entre os atributos.
- C) O PCA converterá automaticamente o padrão circular em um formato linear antes da projeção.
- D) A primeira componente principal (PC1) explicará 100% da variância independentemente do formato.

8. Qual é a principal diferença operacional entre os métodos de Seleção de Atributos por Filtragem e por Encapsulamento (Wrapper)?

- A) Métodos de filtro dependem do treinamento do modelo, enquanto os de encapsulamento são estatísticos.
- B) Métodos de encapsulamento usam um modelo de ML para avaliar subconjuntos de variáveis, sendo mais caros computacionalmente.
- C) Métodos de filtro são suscetíveis ao overfitting, enquanto os de encapsulamento são independentes do modelo.
- D) A filtragem é usada apenas para dados de imagem, enquanto o encapsulamento é para dados tabulares.

9. A técnica de Regressão LASSO (L1) é citada como um método de seleção de atributos Embarcado. O que define essa categoria de seleção?

- A) A seleção ocorre em um passo de pré-processamento totalmente isolado do treino.
- B) Os atributos são selecionados manualmente por um especialista antes de rodar o algoritmo.
- C) A seleção de atributos ocorre de forma integrada durante o processo de treinamento do modelo de ML.
- D) Os atributos são selecionados com base apenas na correlação linear com o alvo.

10. Para evitar o vazamento de dados (data leakage) durante o processo de escalonamento com a biblioteca Scikit-learn, qual é o fluxo de trabalho correto?

- A) Ajustar o escalonador (fit) no conjunto completo antes de dividir em treino e teste.
- B) Ajustar (fit) no conjunto de teste e aplicar (transform) no conjunto de treinamento.
- C) Ajustar (fit) no conjunto de treinamento e usar os parâmetros aprendidos para transformar (transform) tanto o conjunto de validação quanto o de teste.
- D) Não utilizar o método fit, apenas o transform com valores aleatórios em ambos os conjuntos.

11. Você possui um dataset com variáveis numéricas (algumas com outliers extremos) e um alvo (rótulo) contínuo. Para treinar um modelo KNN (sensível à escala e também afetado por outliers), qual procedimento é o melhor em termos de escalonamento e prevenção de vazamento de dados?

- A) Aplicar Min-Max em todo o dataset (treino + val + teste) para garantir o mesmo intervalo.
- B) Ajustar um RobustScaler apenas no conjunto de treino e aplicar a transformação aprendida nos conjuntos de validação e teste.
- C) Padronizar (StandardScaler) usando média e desvio padrão computados sobre o dataset inteiro.
- D) Não escalonar, pois K-NN funciona bem com distâncias em escala original quando há outliers.

12. Suponha que você queira aplicar PCA para reduzir a dimensionalidade antes de treinar um modelo. Qual passo prévio é obrigatório e por quê?

- A) Aplicar One-Hot Encoding em todas as variáveis categóricas (porque PCA só aceita numéricos).
- B) Escalonar os atributos para que tenham a mesma variância (por exemplo, com StandardScaler).
- C) Remover outliers extremos, pois PCA não funciona com dados contínuos.
- D) Aplicar Target Encoding em todo o dataset para reduzir a cardinalidade antes do PCA.

13. Você tem um atributo categórico nominal de alta cardinalidade (muitas categorias) e um problema de regressão. Considerando desempenho e dimensionalidade, qual codificação é a

mais adequada e qual risco principal deve ser gerenciado?

- A) One-Hot Encoding — risco: maldição da dimensionalidade.
- B) Label Encoding — risco: introduzir ordem falsa entre categorias.
- C) Target Encoding — risco: overfitting em categorias com poucos exemplos.
- D) Binary Encoding — risco: criar dependência linear que confunda árvores.

14. Em um pipeline de treino, qual das seguintes práticas provoca vazamento de dados e, portanto, deve ser evitada?

- A) Ajustar o parâmetro do StandardScaler apenas no conjunto de treinamento e, depois, aplicar a validação/o teste.
- B) Calcular as estatísticas de imputação (por exemplo, com a média) usando todo o dataset antes de dividir em treino, validação e teste.
- C) Aplicar seleção de features via métodos encapsulados (wrapper) usando validação cruzada restrita ao treino.
- D) Guardar o conjunto de teste para avaliação final e não usá-lo durante o ajuste de hiperparâmetros.

15. Você está escolhendo uma técnica de seleção de atributos para um problema em que se suspeita que interações complexas entre variáveis explicam o alvo. Qual abordagem tem maior chance de capturar essas interações e por quê?

- A) Filtro (ex.: correlação de Pearson). Porque é rápido e independente do modelo.
- B) Encapsulamento (wrapper, ex.: RFE). Porque usa o desempenho do modelo sobre subconjuntos, capturando interações.
- C) Embutido (embedded, ex.: LASSO). Porque penaliza pesos e sempre captura interações não lineares.
- D) VarianceThreshold. Porque variância alta implica interações fortes.

16. Em um conjunto assimétrico (distribuição com cauda longa) e com presença de outliers extremos, qual escalonador preserva melhor as relações entre os valores não discrepantes e por quê?

- A) Min-Max, porque restringe tudo a $[0, 1]$ e destaca diferenças pequenas.
- B) StandardScaler, porque centraliza em média 0 e desvio padrão 1 e é imune a outliers.
- C) RobustScaler, porque usa a mediana e o IQR, minimizando a influência de outliers e mantendo as distâncias entre os valores não discrepantes.
- D) Nenhum. O correto é excluir outliers sempre antes do escalonamento.

17. Sobre extração versus seleção de atributos, qual afirmação resume corretamente a distinção entre eles?

- A) A extração seleciona as melhores colunas originais. A seleção gera novas combinações lineares.
- B) A seleção transforma atributos originais em um conjunto menor (perdendo informação). A extração escolhe um subconjunto sem alterá-lo.
- C) A extração transforma atributos (geralmente reduzindo a dimensionalidade e podendo perder informação). A seleção escolhe um subconjunto dos atributos originais sem alterá-los.
- D) Ambos são sinônimos e a escolha entre termos depende apenas da biblioteca utilizada.

18. Você tem atributos de texto e precisa transformá-los para usá-los com modelos que aceitam apenas números. O material de aula lista técnicas para extração de atributos de texto. Assinale a alternativa que não aparece como opção no material e explique por que as demais são apropriadas.

- A) Bag of Words (BoW). Aparece. Conta a ocorrência de palavras.
- B) TF-IDF. Aparece. Pondera palavras informativas.
- C) Word Embeddings. Aparece. Vetores densos que capturam semântica.
- D) LDA (Latent Dirichlet Allocation). Aparece. Gera atributos de tópicos usados diretamente como embeddings.

19. Em um projeto de IA, após aplicar o PCA em 10 atributos originais, você observa que o primeiro componente principal (PC1) explica 95% da variância dos dados. O que se pode inferir sobre os atributos originais?

- A) Eles são altamente independentes entre si e não possuem correlação.
- B) Eles são redundantes ou altamente correlacionados, permitindo que uma única direção capture quase toda a informação.
- C) O PCA falhou, pois cada componente deveria explicar exatamente 10% da variância.
- D) O modelo de ML final obrigatoriamente terá 95% de acurácia.

20. Por que o PCA pode ter desempenho ruim em dados com padrões não lineares?

- A) Porque ignora a variância.
- B) Porque assume independência estatística.
- C) Porque projeta os dados usando combinações lineares.
- D) Porque não reduz a dimensionalidade.

Exercícios práticos: Transformações com o dataset do Titanic

O dataset inclui colunas como:

- PassengerId: identificador do passageiro
- Survived: 1 = sobreviveu, 0 = não sobreviveu
- Pclass: classe no navio (1, 2, 3)
- Name: nome do passageiro
- Sex: sexo do passageiro

- Age: idade em anos
- SibSp: irmãos/cônjuges no navio
- Parch: pais/filhos no navio
- Ticket: número do bilhete
- Fare: preço da passagem
- Cabin: número da cabine
- Embarked: porto de embarque (C, Q, S)

O dataset está disponível em:

https://github.com/zz4fap/c24_inteligencia_artificial/blob/main/data/titanic.csv

OBS.: Crie um notebook Jupyter para responder aos exercícios abaixo.

1. Divisão do Dataset

Objetivo: dividir corretamente os dados entre treino e teste antes de qualquer transformação.

Tarefa:

1. Carregue o dataset.
2. Separe os dados em X (features) e y (target: Survived).
3. Divida em treino (80%) e teste (20%) de forma estratificada pela sobrevivência.

Dica: use `train_test_split` do `scikit-learn`.

O que mostrar:

- Dimensões de `X_train`, `X_test`, `y_train`, `y_test`;
- Proporções de `Survived` nas divisões.

2. Escalonamento de Atributos

Objetivo: aplicar escalonamento para variáveis numéricas.

Tarefa:

1. Liste as colunas numéricas (Age, Fare, SibSp, Parch).
2. Aplique `StandardScaler` ou `MinMaxScaler` apenas nos dados de treino.
3. Transforme os dados de teste com o mesmo scaler.

Dica: use pipelines para que o escalonamento seja aplicado corretamente.

O que mostrar:

- Histogramas antes e depois do escalonamento.

3. Codificação de Variáveis Categóricas

Objetivo: transformar categorias em números.

Tarefa:

1. Identifique as colunas categóricas (ex.: Sex, Embarked, Cabin, Ticket).
2. Aplique:
 - a. One-Hot Encoding para variáveis sem ordem (Sex, Embarked).
 - b. Label Encoding se fizer sentido (ex: extrair títulos de Name).
3. Observe o aumento no número de colunas após a codificação.

Dica: use OneHotEncoder ou get_dummies do pandas.

O que mostrar:

- Lista de colunas originais vs colunas codificadas.

4. Engenharia de Atributos

Objetivo: criar variáveis que melhorem a informação dos dados.

Tarefa:

1. Crie a variável FamilySize = SibSp + Parch + 1.
2. Extraia o título do nome (Mr, Mrs, Miss, Master etc.).
3. Crie uma nova coluna indicadora (IsAlone) que valha 1 se o passageiro estava sozinho e 0 caso contrário.

Dica: nomes estão no estilo "Last, Title. First".

O que mostrar:

- Novas colunas e breve análise de distribuição (ex: quantos viajavam sozinhos).

5. Extração de Atributos de Colunas de Texto

Objetivo: extrair informação útil de colunas complexas.

Tarefa:

1. A partir da coluna Cabin, extraia apenas o bloco da cabine (primeira letra).
 - a. Aqui, você deve criar uma coluna com apenas o bloco da cabine.
2. Mostre quantos passageiros estão em cada tipo de bloco de cabine.
3. Compare a taxa de sobrevivência por bloco de cabine.

Dica: pode haver valores nulos. Portanto, trate-os antes de extrair.

O que mostrar:

- Gráfico ou tabela com taxa de sobrevivência por tipo de bloco.

6. Seleção de Atributos

Objetivo: reduzir o número de features relevantes para modelagem.

Tarefa:

1. Aplicar uma técnica de seleção de atributos como:

- a. Variância mínima
 - b. Seleção univariada (ex: SelectKBest, qui-quadrado)
 - c. Importância via árvore de decisão
2. Liste as 10 melhores features selecionadas.

Dica: use `sklearn.feature_selection` ou árvores de decisão.

O que mostrar:

- Lista de features ordenadas por importância ou por score.

7. Integração Final – Pré-Processamento Completo

Objetivo: montar um pipeline de pré-processamento que combine tudo.

Tarefa:

1. Criar um pipeline que:
 - a. trate atributos faltantes,
 - b. codifique atributos categóricos,
 - c. escalone atributos numéricos,
 - d. aplique seleção de atributos,
 - e. prepare dados para modelo.
2. Treine um modelo simples, como a regressão logística.
3. Avalie a acurácia nos conjuntos de treinamento e teste.

Dica: use `ColumnTransformer` para aplicar transformações separadas por tipo de dado.

O que mostrar:

- Relatório com métricas de avaliação.