

Lista de exercícios 4 de C24 - Inteligência Artificial

Transformações de dados

Exercícios teóricos

1. Se um cientista de dados utiliza o conjunto de teste para ajustar os hiperparâmetros de um modelo e escolher a melhor arquitetura, qual é a consequência técnica direta dessa ação?

- A) O modelo terá um desempenho superior no mundo real, pois foi otimizado com dados inéditos.
- B) Ocorre vazamento de dados (data leakage), invalidando a estimativa imparcial do desempenho real do modelo.
- C) O modelo sofrerá de underfitting, pois o conjunto de teste é geralmente menor que o de treinamento.
- D) O conjunto de validação torna-se o único capaz de simular dados nunca vistos pelo modelo.

2. Ao aplicar a Normalização (Min-Max Scaling) em um atributo que possui um único valor extremamente alto (um outlier discrepante), o que acontece com a distribuição dos demais valores "normais" após a transformação?

- A) Eles serão distribuídos uniformemente entre os valores -1 e 1.
- B) Eles permanecerão inalterados, pois a fórmula utiliza apenas a média dos dados.
- C) Eles serão "esmagados" para um intervalo muito pequeno próximo de zero, perdendo a distinção entre eles.
- D) Eles assumirão valores negativos, já que o outlier puxa o ponto central para cima.

3. Em qual cenário o uso do Robust Scaling é tecnicamente superior ao Standard Scaling (Padronização)?

- A) Quando os dados seguem uma distribuição perfeitamente Gaussiana (Normal).
- B) Quando o objetivo é garantir que os dados fiquem estritamente limitados entre 0 e 1.
- C) Quando o conjunto de dados possui outliers significativos que podem distorcer a média e o desvio padrão.
- D) Quando o modelo de Machine Learning utilizado é uma Árvore de Decisão, que exige dados centrados.

4. Considere um atributo categórico "Cidade" com 500 nomes diferentes em um dataset de 1.000 linhas. Por que o One-Hot Encoding não seria a escolha ideal para codificar essa variável?

- A) Porque ele introduz uma ordem falsa entre as cidades, prejudicando modelos lineares.

- B) Porque ele gera alta dimensionalidade (muitas colunas), podendo causar a "maldição da dimensionalidade".
- C) Porque ele substitui o nome da cidade pela média do alvo, causando overfitting.
- D) Porque ele só funciona com categorias que possuem uma hierarquia clara.

5. Qual é o principal risco de utilizar o Target Encoding em categorias que aparecem pouquíssimas vezes no conjunto de treinamento?

- A) Aumento excessivo da dimensionalidade do dataset.
- B) O modelo pode sofrer overfitting, pois a média do alvo para essa categoria pode refletir ruído e não um padrão real.
- C) Perda total da informação sobre a variância dos atributos numéricos.
- D) Incompatibilidade com algoritmos baseados em distância, como o KNN.

6. Um cientista de dados cria um novo atributo chamado "Valor por Metro Quadrado" dividindo o "Preço da Casa" pela "Área". Essa prática é um exemplo de:

- A) Extração de Atributos, pois reduz o número total de variáveis.
- B) Seleção de Atributos, pois escolhe as variáveis mais importantes.
- C) Engenharia de Atributos, pois cria um novo atributo mais informativo a partir de interações entre os existentes.
- D) Padronização, pois coloca o preço e a área na mesma escala.

7. Sobre a técnica de PCA (Análise de Componentes Principais), o que acontece se os dados originais apresentarem um padrão de distribuição curvo ou circular?

- A) O PCA identificará o centro do círculo e extrairá a curvatura perfeitamente.
- B) O desempenho será insatisfatório, pois o PCA assume relações lineares e traça linhas retas para capturar a variância.
- C) O PCA converterá automaticamente o padrão circular em um formato linear antes da projeção.
- D) A primeira componente principal (PC1) explicará 100% da variância independentemente do formato.

8. Qual é a principal diferença operacional entre os métodos de Seleção de Atributos por Filtragem e por Encapsulamento (Wrapper)?

- A) Métodos de filtro dependem do treinamento do modelo, enquanto os de encapsulamento são estatísticos.
- B) Métodos de encapsulamento usam o próprio modelo de ML para avaliar subconjuntos de variáveis, sendo mais caros computacionalmente.
- C) Métodos de filtro são suscetíveis ao overfitting, enquanto os de encapsulamento são independentes do modelo.

D) A filtragem é usada apenas para dados de imagem, enquanto o encapsulamento é para dados tabulares.

9. A técnica de Regressão LASSO (L1) é citada como um método de seleção de atributos Embarcado. O que define essa categoria de seleção?

- A) A seleção ocorre em um passo de pré-processamento totalmente isolado do treino.
- B) Os atributos são selecionados manualmente por um especialista antes de rodar o algoritmo.
- C) A seleção de atributos ocorre de forma integrada, durante o processo de treinamento do próprio modelo.
- D) Os atributos são selecionados com base apenas na correlação linear com o alvo.

10. Para evitar o vazamento de dados (data leakage) durante o processo de escalonamento com a biblioteca Scikit-learn, qual é o fluxo de trabalho correto?

- A) Ajustar o escalonador (fit) no conjunto completo antes de dividir em treino e teste.
- B) Ajustar (fit) no conjunto de teste e aplicar (transform) no conjunto de treinamento.
- C) Ajustar (fit) no conjunto de treinamento e usar os parâmetros aprendidos para transformar (transform) tanto o conjunto de validação quanto o de teste.
- D) Não utilizar o método fit, apenas o transform com valores aleatórios em ambos os conjuntos.

11. Você possui um dataset com variáveis numéricas (algumas com outliers extremos) e um alvo (rótulo) contínuo. Para treinar um modelo KNN, qual procedimento é o melhor em termos de escalonamento e prevenção de vazamento de dados?

- A) Aplicar Min-Max em todo o dataset (treino + val + teste) para garantir o mesmo intervalo.
- B) Ajustar um RobustScaler apenas no conjunto de treino e aplicar a transformação aprendida em validação e teste.
- C) Padronizar (StandardScaler) usando média e desvio padrão computados sobre o dataset inteiro.
- D) Não escalonar, pois K-NN funciona bem com distâncias em escala original quando há outliers.

12. Suponha que você queira aplicar PCA para reduzir a dimensionalidade antes de treinar um modelo. Qual passo prévio é obrigatório e por quê?

- A) Aplicar One-Hot Encoding em todas as variáveis categóricas (porque PCA só aceita numéricos).
- B) Escalonar os atributos para que tenham a mesma variância (por exemplo, com StandardScaler).
- C) Remover outliers extremos, pois PCA não funciona com dados contínuos.
- D) Aplicar Target Encoding em todo o dataset para reduzir a cardinalidade antes do PCA.

13. Você tem um atributo categórico nominal de alta cardinalidade (muitas categorias) e um problema de regressão. Considerando desempenho e dimensionalidade, qual codificação é a mais adequada e qual risco principal deve ser gerenciado?

- A) One-Hot Encoding — risco: maldição da dimensionalidade.
- B) Label Encoding — risco: introduzir ordem falsa entre categorias.
- C) Target Encoding — risco: overfitting em categorias com poucos exemplos.
- D) Binary Encoding — risco: criar dependência linear que confunda árvores.

14. Em um pipeline de treino, qual das seguintes práticas provoca vazamento de dados e, portanto, deve ser evitada?

- A) Ajustar o parâmetro do StandardScaler apenas no conjunto de treinamento e, depois, aplicar a validação/o teste.
- B) Calcular as estatísticas de imputação (média) usando todo o dataset antes de dividir em treino, validação e teste.
- C) Aplicar seleção de features via métodos encapsulados (wrapper) usando validação cruzada restrita ao treino.
- D) Guardar o conjunto de teste para avaliação final e não usá-lo durante o ajuste de hiperparâmetros.

15. Considere um atributo binário resultante da codificação one-hot. Sobre escalonamento, qual afirmação está correta?

- A) Sempre aplicar StandardScaler a toda variável binária para centrá-la em zero.
- B) Escalonar variáveis binárias é desnecessário e pode gerar valores fracionários indesejáveis.
- C) Min-Max scaling é obrigatório para variáveis binárias.
- D) Variáveis binárias devem ser removidas antes do treinamento porque atrapalham modelos baseados em distância.

16. Você está escolhendo uma técnica de seleção de atributos para um problema em que se suspeita que interações complexas entre variáveis explicam o alvo. Qual abordagem tem maior chance de capturar essas interações e por quê?

- A) Filtro (ex.: correlação de Pearson). Porque é rápido e independente do modelo.
- B) Encapsulamento (wrapper, ex.: RFE). Porque usa o desempenho do modelo sobre subconjuntos, capturando interações.
- C) Embutido (embedded, ex.: LASSO). Porque penaliza pesos e sempre captura interações não lineares.
- D) VarianceThreshold. Porque variância alta implica interações fortes.

17. Em um conjunto assimétrico (distribuição com cauda longa) e com presença de outliers extremos, qual escalonador preserva melhor as relações entre os valores não discrepantes e

por quê?

- A) Min-Max, porque restringe tudo a $[0, 1]$ e destaca diferenças pequenas.
- B) StandardScaler, porque centraliza em média 0 e desvio padrão 1 e é imune a outliers.
- C) RobustScaler, porque usa a mediana e o IQR, minimizando a influência de outliers e mantendo as distâncias entre os valores não discrepantes.
- D) Nenhum. O correto é excluir outliers sempre antes do escalonamento.

18. Sobre extração versus seleção de atributos, qual afirmação resume corretamente a distinção entre eles?

- A) A extração seleciona as melhores colunas originais. A seleção gera novas combinações lineares.
- B) A seleção transforma atributos originais em um conjunto menor (perdendo informação). A extração escolhe um subconjunto sem alterá-los.
- C) A extração transforma atributos (geralmente reduzindo dimensionalidade e podendo perder informação). A seleção escolhe um subconjunto dos atributos originais sem alterá-los.
- D) Ambos são sinônimos e a escolha entre termos depende apenas da biblioteca utilizada.

19. Você tem atributos de texto e precisa transformá-los para usá-los com modelos que aceitam apenas números. O material de aula lista técnicas para extração de atributos de texto. Assinale a alternativa que não aparece como opção no material e explique por que as demais são apropriadas.

- A) Bag of Words (BoW). Aparece. Conta a ocorrência de palavras.
- B) TF-IDF. Aparece. Pondera palavras informativas.
- C) Word Embeddings. Aparece. Vetores densos que capturam semântica.
- D) LDA (Latent Dirichlet Allocation). Aparece. Gera atributos de tópicos usados diretamente como embeddings.

20. Em um projeto de IA, após aplicar o PCA em 10 atributos originais, você observa que o primeiro componente principal (PC1) explica 95% da variância dos dados. O que se pode inferir sobre os atributos originais?

- A) Eles são altamente independentes entre si e não possuem correlação.
- B) Eles são redundantes ou altamente correlacionados, permitindo que uma única direção capture quase toda a informação.
- C) O PCA falhou, pois cada componente deveria explicar exatamente 10% da variância.
- D) O modelo de ML final obrigatoriamente terá 95% de acurácia.

21. Por que o PCA pode ter desempenho ruim em dados com padrões não lineares?

- A) Porque ignora a variância.
- B) Porque assume independência estatística.

- C) Porque projeta os dados usando combinações lineares.
- D) Porque não reduz a dimensionalidade.

Exercícios práticos: Transformações com o dataset do Titanic

O dataset inclui colunas como:

- PassengerId: identificador do passageiro
- Survived: 1 = sobreviveu, 0 = não sobreviveu
- Pclass: classe no navio (1, 2, 3)
- Name: nome do passageiro
- Sex: sexo do passageiro
- Age: idade em anos
- SibSp: irmãos/cônjuges no navio
- Parch: pais/filhos no navio
- Ticket: número do bilhete
- Fare: preço da passagem
- Cabin: número da cabine
- Embarked: porto de embarque (C, Q, S)

O dataset está disponível em:

https://github.com/zz4fap/c24_inteligencia_artificial/blob/main/data/titanic.csv

OBS.: Crie um notebook Jupyter para responder aos exercícios abaixo.

1. Divisão do Dataset

Objetivo: dividir corretamente os dados entre treino e teste antes de qualquer transformação.

Tarefa:

1. Carregue o dataset.
2. Separe os dados em X (features) e y (target: Survived).
3. Divida em treino (80%) e teste (20%) de forma estratificada pela sobrevivência.

Dica: use `train_test_split` do `scikit-learn`.

O que mostrar:

- Dimensões de `X_train`, `X_test`, `y_train`, `y_test`;
- Proporções de `Survived` nas divisões.

2. Escalonamento de Atributos

Objetivo: aplicar escalonamento para variáveis numéricas.

Tarefa:

1. Liste as colunas numéricas (`Age`, `Fare`, `SibSp`, `Parch`).
2. Aplique `StandardScaler` ou `MinMaxScaler` apenas nos dados de treino.

3. Transforme os dados de teste com o mesmo scaler.

Dica: use pipelines para que o escalonamento seja aplicado corretamente.

O que mostrar:

- Histogramas antes e depois do escalonamento.

3. Codificação de Variáveis Categóricas

Objetivo: transformar categorias em números.

Tarefa:

1. Identifique as colunas categóricas (ex.: Sex, Embarked, Cabin, Ticket).
2. Aplique:
 - a. One-Hot Encoding para variáveis sem ordem (Sex, Embarked).
 - b. Label Encoding se fizer sentido (ex: extrair títulos de Name).
3. Observe o aumento no número de colunas após a codificação.

Dica: use OneHotEncoder ou get_dummies do pandas.

O que mostrar:

- Lista de colunas originais vs colunas codificadas.

4. Engenharia de Atributos

Objetivo: criar variáveis que melhorem a informação dos dados.

Tarefa:

1. Crie a variável $\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$.
2. Extraia o título do nome (Mr, Mrs, Miss, Master etc.).
3. Crie uma nova coluna indicadora (IsAlone) que valha 1 se o passageiro estava sozinho e 0 caso contrário.

Dica: nomes estão no estilo "Last, Title. First".

O que mostrar:

- Novas colunas e breve análise de distribuição (ex: quantos viajavam sozinhos).

5. Extração de Atributos de Colunas de Texto

Objetivo: extrair informação útil de colunas complexas.

Tarefa:

1. A partir da coluna Cabin, extraia apenas o bloco da cabine (primeira letra).
 - a. Aqui, você deve criar uma coluna com apenas o bloco da cabine.
2. Mostre quantos passageiros estão em cada tipo de bloco de cabine.
3. Compare a taxa de sobrevivência por bloco de cabine.

Dica: pode haver valores nulos. Portanto, trate-os antes de extrair.

O que mostrar:

- Gráfico ou tabela com taxa de sobrevivência por tipo de bloco.

6. Seleção de Atributos

Objetivo: reduzir o número de features relevantes para modelagem.

Tarefa:

1. Aplicar uma técnica de seleção de atributos como:
 - a. Variância mínima
 - b. Seleção univariada (ex: SelectKBest, qui-quadrado)
 - c. Importância via árvore de decisão
2. Liste as 10 melhores features selecionadas.

Dica: use `sklearn.feature_selection` ou árvores de decisão.

O que mostrar:

- Lista de features ordenadas por importância ou por score.

7. Integração Final – Pré-Processamento Completo

Objetivo: montar um pipeline de pré-processamento que combine tudo.

Tarefa:

1. Criar um pipeline que:
 - a. trate atributos faltantes,
 - b. codifique atributos categóricos,
 - c. escalone atributos numéricos,
 - d. aplique seleção de atributos,
 - e. prepare dados para modelo.
2. Treine um modelo simples, como a regressão logística.
3. Avalie a acurácia nos conjuntos de treinamento e teste.

Dica: use `ColumnTransformer` para aplicar transformações separadas por tipo de dado.

O que mostrar:

- Relatório com métricas de avaliação.