

Lista de exercícios 5 de C24 - Inteligência Artificial

Regressão

Exercícios teóricos

1. Na regressão linear, é comum utilizarmos polinômios de graus variados para ajustar os dados. Considere a função-hipótese $h(x) = a_0 + a_1x + a_2x^2$. Embora o gráfico dessa função seja uma curva (uma parábola), este modelo ainda é classificado como "regressão linear". Qual é a justificativa técnica correta para essa classificação?

- A) O modelo é linear porque a variável x pode ser substituída por qualquer valor numérico linear.
- B) A linearidade refere-se à relação entre a saída e os pesos (parâmetros a), e não necessariamente em relação aos atributos de entrada x .
- C) O termo quadrático x^2 é desprezível para grandes conjuntos de dados, tornando a função essencialmente uma reta.
- D) O teorema de Stone-Weierstrass garante que toda função curva pode ser linearizada através da derivada.

2. A função de custo Erro Quadrático Médio (EQM ou MSE) é amplamente utilizada em problemas de regressão. Ao plotarmos o valor do EQM em função dos pesos do modelo, obtemos uma superfície de erro. Por que a propriedade de "convexidade" dessa superfície (formato de tigela) é fundamental para o sucesso do algoritmo do Gradiente Descendente?

- A) Ela garante que o passo de aprendizagem possa ser infinito sem causar divergência.
- B) Ela assegura que a função tenha múltiplos pontos de mínimo local, permitindo várias soluções válidas.
- C) Ela garante a existência de apenas um ponto de mínimo global, assegurando que o algoritmo convirja e não fique preso em mínimos locais subótimos.
- D) Ela elimina a necessidade de calcular a derivada da função de erro, simplificando o processo computacional.

3. O algoritmo do Gradiente Descendente atualiza os pesos iterativamente usando o gradiente da função de erro. Na equação de atualização, subtrai-se uma parcela proporcional ao gradiente do peso atual ($w_{\text{novo}} = w_{\text{antigo}} - \alpha * \text{gradiente}$). Por que a subtração é necessária em vez da adição?

- A) Porque o gradiente aponta para a direção de maior crescimento da função, e o objetivo é minimizar o erro, indo na direção oposta.
- B) Porque o valor do gradiente é sempre negativo, a subtração o torna positivo para incrementar os pesos.

C) Para garantir que a magnitude dos pesos diminua com o tempo, evitando estouro de memória (overflow).

D) A subtração serve apenas para normalizar os dados, não influenciando a direção da otimização.

4. A taxa de aprendizagem (learning rate, alpha) é um hiperparâmetro crítico no Gradiente Descendente. Imagine que você está treinando um modelo e observa que, a cada iteração, o erro não diminui, mas sim oscila drasticamente ou aumenta progressivamente (diverge). Qual é a causa mais provável para esse comportamento?

A) A taxa de aprendizagem escolhida é muito pequena, fazendo o algoritmo progredir muito lentamente.

B) O conjunto de dados possui poucos exemplos, causando underfitting imediato.

C) A taxa de aprendizagem é excessivamente grande, fazendo com que o algoritmo "pule" o ponto de mínimo e se afaste dele.

D) A função de erro utilizada não é diferenciável, impedindo o cálculo do gradiente.

5. Existem diferentes variações do Gradiente Descendente baseadas na quantidade de dados usados para calcular o gradiente a cada passo: Batch (Batelada), Estocástico (SGD) e Mini-batch. Qual das alternativas descreve corretamente uma vantagem do Gradiente Descendente Estocástico em comparação ao Batch?

A) O Estocástico é mais preciso, pois usa todos os dados de uma vez para calcular a direção exata do mínimo global.

B) O Estocástico é computacionalmente mais leve e rápido por iteração, pois usa apenas uma amostra para atualizar os pesos, embora a convergência seja mais ruidosa.

C) O Estocástico garante que o erro diminua monotonicamente a cada iteração, sem flutuações.

D) O Estocástico é o único método capaz de resolver a Equação Normal de forma analítica.

6. Ao comparar a solução analítica (Equação Normal) com a solução iterativa (Gradiente Descendente) para encontrar os pesos ótimos de uma regressão linear, qual é uma limitação significativa da Equação Normal que favorece o uso do Gradiente Descendente em aplicações modernas de Big Data?

A) A Equação Normal não fornece o valor exato dos pesos, sendo apenas uma aproximação estatística.

B) A Equação Normal exige o cálculo da inversa de uma matriz ($X^T X$), cuja complexidade computacional cresce cubicamente ($O(K^3)$), tornando-a inviável para modelos com muitos atributos.

C) A Equação Normal exige o ajuste manual da taxa de aprendizagem, o que é difícil de calibrar.

D) A Equação Normal só funciona para problemas de classificação, não servindo para regressão.

7. Um cientista de dados treinou um modelo polinomial de grau muito alto para prever preços de casas. Ele observou que o erro no conjunto de treinamento (EQM) é quase zero, mas o erro no conjunto de teste (dados inéditos) é extremamente alto. Qual fenômeno descreve essa situação e o que ela indica sobre o modelo?

- A) Underfitting (subajuste); o modelo é simples demais para capturar a tendência dos dados.
- B) Overfitting (sobreajuste); o modelo "memorizou" o ruído dos dados de treino e perdeu a capacidade de generalização.
- C) Convergência Prematura; o treinamento foi interrompido antes do tempo ideal.
- D) Viés Alto: o modelo está fazendo suposições erradas sobre a forma dos dados.

8. Para mitigar o problema de Overfitting identificado na questão anterior, quais das seguintes estratégias seriam as mais indicadas?

- A) Aumentar o grau do polinômio e reduzir a quantidade de dados de treinamento.
- B) Reduzir a complexidade do modelo (diminuir o grau do polinômio), obter mais dados de treinamento ou aplicar técnicas de regularização.
- C) Aumentar a taxa de aprendizagem e treinar por mais épocas (iterações).
- D) Substituir a função de erro quadrático médio por uma função linear simples.

9. Considere a técnica de validação cruzada (Cross-Validation), especificamente o método k-fold. Qual é o principal objetivo de utilizar essa técnica durante o desenvolvimento de um modelo de aprendizado de máquina?

- A) Aumentar artificialmente o tamanho do dataset duplicando os dados k vezes.
- B) Encontrar os valores exatos dos pesos, θ , que serão usados no modelo final de produção.
- C) Avaliar a capacidade de generalização do modelo de forma robusta e auxiliar no ajuste de hiperparâmetros (como o grau do polinômio), utilizando o dataset para treino e validação de forma rotativa.
- D) Garantir que o modelo tenha viés zero e variância zero simultaneamente.

10. O conceito de Underfitting (subajuste) está associado a um modelo que apresenta "alto viés". O que caracteriza o desempenho de um modelo sofrendo de underfitting?

- A) Erro baixo no conjunto de treinamento e erro alto no conjunto de validação.
- B) Erro alto tanto no conjunto de treinamento quanto no conjunto de validação, pois o modelo falha em capturar a relação básica entre os dados.
- C) Erro variando drasticamente dependendo da semente aleatória utilizada na inicialização.
- D) O modelo prevê perfeitamente todos os pontos, inclusive os outliers.

11. Considere o Teorema de Stone-Weierstrass no contexto da modelagem de dados. Ao utilizarmos um modelo de regressão polinomial da forma $\hat{y} = a_0 + a_1x + a_2x^2 + \dots + a_kx^k$, estamos essencialmente tentando aproximar uma função contínua desconhecida. Sob

a ótica do aprendizado de máquina e da complexidade do modelo, qual é a principal implicação prática desse teorema ao aumentarmos arbitrariamente o grau k do polinômio?

- A) O aumento de k garante que o erro de validação diminuirá monotonicamente, pois o modelo se torna capaz de representar qualquer função linear.
- B) O teorema assegura que qualquer função contínua pode ser aproximada, mas o aumento excessivo de k confere flexibilidade demasiada, permitindo que o modelo capture o ruído estocástico dos dados (overfitting) e não apenas o padrão subjacente.
- C) Polinômios de grau elevado deixam de ser tratáveis via Regressão Linear, pois a relação entre a saída $\hat{y}$ e os coeficientes a deixa de ser linear, exigindo o uso de redes neurais.
- D) O teorema afirma que polinômios de grau ímpar convergem mais rápido para o mínimo global da função de custo do que polinômios de grau par.

12. Analise a complexidade computacional das abordagens para encontrar os pesos ótimos em uma regressão linear: a Equação Normal (solução analítica) e o Gradiente Descendente (solução iterativa). Em um cenário de deep learning onde o número de atributos (features) K é extremamente grande (e.g., $K > 100.000$), por que o Gradiente Descendente é preferível à Equação Normal?

- A) Porque a Equação Normal requer o cálculo da inversa da matriz $X^T X$, uma operação com complexidade cúbica $O(K^3)$, tornando-se computacionalmente inviável para grandes valores de K .
- B) Porque o Gradiente Descendente é o único método capaz de garantir a convergência para o mínimo global em superfícies de erro convexas, enquanto a Equação Normal frequentemente estaciona em mínimos locais.
- C) Porque a Equação Normal exige o ajuste de hiperparâmetros sensíveis, como a taxa de aprendizagem, que são difíceis de otimizar em grandes dimensões.
- D) Porque a complexidade do Gradiente Descendente independe do número de atributos K , sendo afetada apenas pelo número de amostras N .

13. O conceito de "Viés" (Bias) e "Variância" é fundamental para diagnosticar o desempenho de modelos. Considerando um modelo que apresenta um baixo erro de treinamento, mas um alto erro de validação, como podemos classificar esse comportamento em termos de viés/variância e qual seria a intervenção correta baseada na estrutura do modelo?

- A) O modelo sofre de alto viés (Underfitting). A solução seria reduzir o grau do polinômio ou adicionar regularização.
- B) O modelo sofre de alta variância (Overfitting). Isso ocorre porque o modelo é excessivamente flexível e memorizou o ruído. A solução envolve reduzir a complexidade do modelo, aumentar a regularização ou obter mais dados.
- C) O modelo sofre de alto viés e alta variância simultaneamente. A única solução é alterar o algoritmo de otimização de Gradiente Descendente para Equação Normal.
- D) O comportamento indica convergência prematura. A solução é aumentar a taxa de aprendizagem α para "saltar" para um mínimo global melhor.

14. Analise o comportamento de convergência e o custo computacional dos algoritmos Gradiente Descendente em Batelada (GDB) e Gradiente Descendente Estocástico (GDE) ao serem aplicados em um problema de regressão linear com um conjunto de dados massivo (N muito grande). Considerando a relação entre a precisão do gradiente calculado e a frequência de atualização dos pesos, assinale a alternativa que descreve corretamente o trade-off (compromisso) entre esses dois métodos.

- A) O GDB realiza atualizações nos pesos mais frequentes que o GDE, pois calcula o gradiente para cada ponto individualmente, garantindo que o algoritmo nunca fique preso em mínimos locais, embora sua trajetória seja muito ruidosa.
- B) O GDE calcula o gradiente exato da função de custo usando todos os N pontos antes de realizar um único passo, o que resulta em uma convergência extremamente rápida em termos de tempo de processamento, mas com uma trajetória em "zigue-zague".
- C) O GDB calcula a média dos gradientes de todos os pontos de treinamento para dar um único passo, resultando em uma descida suave e direta em direção ao mínimo, porém com alto custo computacional por iteração. Em contraste, o GDE atualiza os pesos a cada exemplo processado, gerando uma trajetória oscilatória que flutua ao redor do mínimo devido à estimativa ruidosa do gradiente.
- D) Ambos os algoritmos possuem o mesmo custo computacional por iteração, diferenciando-se apenas pelo fato de que o GDE exige que a função de custo seja não-convexa, enquanto o GDB exige funções estritamente convexas para funcionar.

15. A taxa de aprendizagem, α , é um hiperparâmetro crítico. Se, durante o treinamento de um modelo de regressão linear, você observar que o valor da função de custo (MSE) está aumentando progressivamente a cada iteração em vez de diminuir, qual é o diagnóstico mais provável e a ação corretiva apropriada?

- A) O modelo está em Underfitting; deve-se aumentar a complexidade do modelo (aumentar o grau do polinômio).
- B) O algoritmo caiu em um mínimo local; deve-se aumentar a taxa de aprendizagem para sair dessa região.
- C) A taxa de aprendizagem é excessivamente grande, causando divergência (overshooting). Deve-se reduzir o valor de α .
- D) A matriz de atributos não foi transposta corretamente. Deve-se revisar a derivação matemática do gradiente.

16. A validação cruzada k -fold é uma técnica robusta para avaliação de modelos. Suponha que você utilize $k=5$ para avaliar um modelo polinomial. O processo envolve treinar o modelo 5 vezes. Qual é o racional estatístico por trás de calcular a média e o desvio padrão dos erros obtidos nessas 5 rodadas?

- A) A média fornece uma estimativa da capacidade de generalização do modelo em dados não vistos, enquanto o desvio padrão indica a estabilidade do modelo diante de diferentes subconjuntos de treinamento.
- B) O objetivo é aumentar artificialmente o tamanho do conjunto de dados (Data Augmentation) para evitar o overfitting, somando os resultados das 5 redes.
- C) O cálculo serve apenas para encontrar os coeficientes β exatos da Equação Normal, dividindo o problema em 5 partes menores para facilitar a inversão da matriz.
- D) Realiza-se esse processo para garantir que o erro de treinamento seja zero em pelo menos um dos folds (partes), confirmando a flexibilidade do modelo.

17. Em relação à superfície de erro do Erro Quadrático Médio (EQM) em uma Regressão Linear, a propriedade de convexidade é frequentemente citada como uma grande vantagem. Por que a convexidade é tão importante para a garantia de eficácia do algoritmo de Gradiente Descendente neste contexto específico?

- A) Porque funções convexas possuem múltiplos mínimos locais, o que oferece ao algoritmo várias opções de convergência válidas.
- B) Porque garante que, independentemente da inicialização aleatória dos pesos, o algoritmo (com α adequado) sempre terá um caminho descendente em direção a um único mínimo global.
- C) Porque elimina a necessidade de calcular derivadas parciais, permitindo o uso de métodos de busca aleatória.
- D) Porque assegura que a função de erro seja sempre igual a zero no ponto de mínimo, indicando uma predição perfeita sem ruído.

18. Considere a atualização de pesos no Gradiente Descendente em Mini-lotes (MB GD). Se definirmos o tamanho do lote MB igual ao tamanho total do conjunto de dados N , e depois definirmos $MB = 1$, estamos efetivamente revertendo o algoritmo para quais métodos, respectivamente?

- A) Gradiente Descendente Estocástico e Equação Normal.
- B) Gradiente Descendente em Batelada e Gradiente Descendente Estocástico.
- C) Equação Normal e Gradiente Descendente em Batelada.
- D) Gradiente Descendente Estocástico e Gradiente Descendente em Batelada.

19. Suponha que você esteja treinando um modelo de regressão e obtenha um cenário onde tanto o erro de treinamento quanto o erro de validação são altos e muito próximos um do outro. O modelo não consegue reduzir o erro mesmo após muitas épocas. Baseados na teoria de viés e variância, qual é o diagnóstico e a solução estrutural mais adequada?

- A) O modelo sofre de Overfitting (Alta Variância). Deve-se obter mais dados.
- B) O modelo sofre de Underfitting (Alto Viés). O modelo é simples demais para capturar o padrão dos dados (e.g., tentando ajustar uma reta em dados quadráticos). Deve-se aumentar a complexidade do modelo ou adicionar novos atributos.

- C) O modelo está convergindo corretamente, pois a proximidade entre os erros de treino e validação é o objetivo final da validação cruzada.
- D) O passo de aprendizagem é muito pequeno. A solução é apenas computacional, sem necessidade de alterar a estrutura do modelo.

20. A validação cruzada é especialmente útil porque permite:

- A) ajustar coeficientes sem precisar de dados de teste.
- B) estimar o desempenho de generalização do modelo.
- C) reduzir o ruído dos dados automaticamente.
- D) transformar variáveis não-lineares em lineares.

Exercícios práticos

1. Copie e execute o código abaixo. Analise o código e a figura, na sequência, responda:

- Por que o MSE do modelo polinomial foi significativamente menor que o modelo linear? Relacione com o conceito de underfitting.
- No modelo de grau 2, quantos pesos, a, o algoritmo precisou encontrar?
- Se você aumentasse o grau do polinômio para 100, o MSE de treinamento chegaria próximo de zero. Por que isso seria um problema para novos dados?

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
from sklearn.metrics import mean_squared_error

# 1. Gerando dados sintéticos
np.random.seed(42)
X = 2 - 3 * np.random.normal(0, 1, 100)
y = 0.5 * X**2 + X + 2 + np.random.normal(0, 3, 100) # Função quadrática com ruído

# Redimensionando para o Scikit-Learn
X = X[:, np.newaxis]

# 2. Regressão Linear Simples (Grau 1)
model_linear = LinearRegression()
model_linear.fit(X, y)
y_pred_linear = model_linear.predict(X)

# 3. Regressão Polinomial (Grau 2)
# Dica: Use PolynomialFeatures para transformar X em [1, x, x^2]
poly = PolynomialFeatures(degree=2)
X_poly = poly.fit_transform(X)

model_poly = LinearRegression()
model_poly.fit(X_poly, y)
y_pred_poly = model_poly.predict(X_poly)
```

```
# 4. Avaliação: Calcule o MSE para ambos
mse_linear = mean_squared_error(y, y_pred_linear)
mse_poly = mean_squared_error(y, y_pred_poly)

print(f"MSE Linear (Grau 1): {mse_linear:.2f}")
print(f"MSE Polinomial (Grau 2): {mse_poly:.2f}")

# 5. Visualização
plt.scatter(X, y, color='blue', label='Dados Reais')
# Ordenando para o gráfico de linha ficar correto
sort_axis = np.argsort(X.flatten())
plt.plot(X[sort_axis], y_pred_linear[sort_axis], color='red', label='Reta (Grau 1)')
plt.plot(X[sort_axis], y_pred_poly[sort_axis], color='green', label='Curva (Grau 2)')
plt.legend()
plt.show()
```

2. Copie e execute o código abaixo. Em seguida, encontre o melhor grau para um polinômio aproximador. Use k-fold, com $k = 10$, para encontrar o melhor polinômio. Ao invés da classe SGDRegressor use a classe LinearRegression.

- Divida o conjunto total em 90% para treinamento e 10% para teste.
- Teste polinômios de grau 1 até grau 20.
- Plote o gráfico de MSE de treinamento e validação para os diferentes graus.
- Defina o grau do melhor polinômio.
- Treine um novo modelo com o melhor grau encontrado. Use todo o conjunto de treinamento.
- Apresente uma figura comparando todas as funções: objetivo, observável e aproximada.

```
import pandas as pd
import matplotlib.pyplot as plt

# Tamanho total do dataset
N = 1000

# Criando dados entre -1.5 e 1.5 para focar no comportamento local
X = np.linspace(-0.5, 0.5, N).reshape(N, 1)

# Função cosenoidal
y = np.cos(2*np.pi*X).reshape(N, 1)

# Ruído
w = np.sqrt(0.1)*np.random.randn(N, 1)

# Função ruidosa
y_noisy = y + w

# Compare as diferentes funções
fig = plt.figure(figsize=(10,10))
```

```
plt.plot(X, y, 'b.', label='Função objetivo')
plt.plot(X, y_noisy, 'x', label='Função observável (ruidosa)')
plt.xlabel('$x$', fontsize=14)
plt.ylabel('$y$', fontsize=14)
plt.legend()
plt.grid()
plt.show()
```