

Lista de exercícios 6 de C24 - Inteligência Artificial

Classificação

Exercícios teóricos

1. Qual é a distinção fundamental entre o objetivo de uma função em uma tarefa de regressão e em uma tarefa de classificação supervisionada?

- A) A regressão busca identificar a categoria exata de um dado, enquanto a classificação busca prever um valor numérico contínuo.
- B) A regressão foca em capturar o comportamento geral dos dados para aproximação, enquanto a classificação foca em estabelecer uma fronteira de decisão para separar grupos.
- C) A classificação não utiliza rótulos conhecidos no treinamento, ao passo que a regressão exige saídas esperadas bem definidas.
- D) Na classificação, a função mapeia atributos para um conjunto infinito de valores, enquanto na regressão o conjunto de valores é sempre finito e discreto.

2. Um sistema de análise de imagens médicas que deve identificar, em uma mesma radiografia, se há presença de "Pneumonia", "Fratura" e "Derrame Pleural" (podendo haver mais de um simultaneamente) é um exemplo de:

- A) Classificação binária simples.
- B) Classificação multiclasse single-label.
- C) Classificação multilabel.
- D) Regressão linear múltipla.

3. Na regressão logística, a função sigmoide (ou logística) é utilizada para mapear a saída da função discriminante para o intervalo $[0, 1]$. Se o modelo retornar um valor exatamente igual a 0,5 para uma determinada amostra, o que se pode inferir sobre ela?

- A) A amostra está posicionada exatamente sobre a fronteira de decisão, indicando ambiguidade máxima.
- B) O modelo tem 100% de certeza de que a amostra pertence à classe positiva.
- C) A amostra é um valor atípico (outlier) que deve ser removido do conjunto de dados.
- D) O erro de treinamento para essa amostra específica foi reduzido a zero.

4. Por que a função de Erro Quadrático Médio (EQM) geralmente é evitada no treinamento de regressores logísticos, sendo preferível a Entropia Cruzada?

- A) Porque o EQM é matematicamente impossível de ser calculado para funções não-lineares.

- B) Porque a combinação da função logística com o EQM gera uma superfície de erro não-convexa, o que pode prender o algoritmo em mínimos locais.
- C) Porque a Entropia Cruzada permite que o modelo aprenda sem a necessidade de utilizar o Gradiente Descendente.
- D) Porque o EQM só pode ser aplicado se o número de amostras for superior a um milhão.

5. Considere um problema de classificação com 4 classes mutuamente exclusivas (A, B, C e D). Utilizando a codificação "one-hot", como seria representado o rótulo da classe "C"?

- A) $[3, 0, 0, 0]^T$
- B) $[1, 1, 1, 0]^T$
- C) $[0, 0, 1, 0]^T$
- D) 0,75

6. Sobre as fronteiras de decisão em modelos de classificação, assinale a alternativa correta:

- A) Elas são sempre obrigatoriamente retas ou planos (lineares), independentemente da função utilizada.
- B) Elas são superfícies no espaço de atributos que separam as regiões de decisão de cada classe, podendo ser lineares ou não-lineares.
- C) Uma fronteira de decisão só existe se o problema tiver exatamente duas classes.
- D) A fronteira de decisão é o local onde a probabilidade da classe negativa é máxima.

7. Um modelo de classificação apresenta um erro de treinamento extremamente baixo (próximo de zero), mas um erro de teste muito elevado ao lidar com dados inéditos. Esse fenômeno é conhecido como:

- A) Subajuste (underfitting), causado por uma fronteira de decisão muito simples.
- B) Convergência ideal, indicando que o modelo aprendeu perfeitamente os dados.
- C) Sobreajuste (overfitting), indicando que o modelo perdeu a capacidade de generalização por ser excessivamente flexível.
- D) Regularização excessiva, que impediu o modelo de ajustar os pesos corretamente.

8. Diferente da Regressão Linear, a Regressão Logística não possui uma solução analítica direta (como a Equação Normal) para encontrar os pesos ideais. Como os pesos são obtidos na prática?

- A) Através de sorteio aleatório até que o erro seja satisfatório.
- B) Por meio de processos iterativos de otimização, como o Gradiente Descendente.
- C) Fixando todos os pesos em zero, pois a função logística compensa os valores.
- D) Utilizando apenas a validação cruzada para decidir os pesos sem cálculos de erro.

9. Como a aplicação de técnicas de regularização, como Ridge ou LASSO, auxilia na melhoria de um classificador?

- A) Aumentando a complexidade do modelo para que ele memorize todos os dados de entrada.
- B) Penalizando pesos com valores absolutos muito altos, o que restringe a flexibilidade excessiva e ajuda a evitar o sobreajuste.
- C) Removendo automaticamente metade das amostras do conjunto de treinamento para acelerar o cálculo.
- D) Transformando a classificação multiclasse em múltiplas classificações binárias de forma aleatória.

10. Em uma aplicação de detecção de fraude bancária (classe positiva = "Fraude" e classe negativa = "Não Fraude"), o sistema retorna uma probabilidade de 0,65 para uma transação. Se o desenvolvedor configurar o limiar (threshold) de decisão para 0,70, qual será o destino dessa transação?

- A) Será classificada como "Fraude", pois está acima de 0,5.
- B) Será classificada como "Não Fraude", pois a probabilidade calculada é inferior ao limiar estabelecido.
- C) O modelo entrará em estado de indeterminação, pois 0,65 é um valor "médio".
- D) A transação será excluída automaticamente do banco de dados por segurança.

11. Em um classificador linear, a fronteira de decisão é determinada principalmente por:

- A) A função de perda apenas
- B) Os pesos do modelo
- C) O número de épocas de treinamento
- D) A variância do conjunto de dados

12. Se um classificador apresenta alto viés e baixa variância, qual ação tende a melhorar seu desempenho?

- A) Reduzir o tamanho do conjunto de treino
- B) Aumentar a complexidade do modelo
- C) Aplicar regularização mais forte
- D) Remover atributos informativos

13. Qual é a principal vantagem de usar validação cruzada na avaliação de classificadores?

- A) Garantir erro zero no conjunto de teste
- B) Reduzir a necessidade de métricas adicionais
- C) Estimar desempenho mais robusto e generalizável
- D) Aumentar automaticamente a acurácia

14. No contexto da Regressão Logística, a função sigmoide (logística) é utilizada para mapear combinações lineares de atributos em um intervalo entre 0 e 1. Se um modelo de classificação

binária retorna um valor $h(x) = 0,7$ para um determinado exemplo, qual é a interpretação probabilística desse resultado?

- A) O modelo tem 70% de certeza de que a instância pertence à classe 0, assumindo um limiar padrão de 0,5.
- B) A probabilidade estimada de que a instância pertença à classe positiva ($y=1$) é de 0,7.
- C) O erro de classificação para essa instância é exatamente 0,3, independentemente do rótulo real.
- D) O valor 0,7 representa a distância euclidiana da instância até o hiperplano de separação das classes.

15. Ao treinar um modelo de Regressão Logística, utiliza-se a função de erro de Entropia Cruzada em vez do Erro Quadrático Médio (MSE). Qual é a principal razão matemática para essa escolha no processo de otimização?

- A) O MSE produz uma função de custo não convexa para a regressão logística, o que pode levar o Gradiente Descendente a convergir para mínimos locais.
- B) A função de Entropia Cruzada é linear, o que torna o cálculo do gradiente mais rápido do que no MSE.
- C) O MSE não pode ser utilizado com variáveis dependentes discretas, apenas com variáveis contínuas.
- D) A Entropia Cruzada garante que a acurácia do modelo seja sempre superior à obtida com o MSE durante a validação cruzada.

16. Considere um problema de classificação onde as classes não são linearmente separáveis no espaço de atributos original. Qual estratégia é mais adequada para permitir que um classificador linear, como a Regressão Logística, capture a fronteira de decisão correta?

- A) Aumentar a taxa de aprendizado (α) para que o modelo ignore as sobreposições de dados.
- B) Aplicar uma transformação polinomial aos atributos originais, criando novos atributos de ordem superior para mapear os dados em um espaço de maior dimensão.
- C) Reduzir o número de instâncias de treinamento para simplificar a fronteira de decisão.
- D) Substituir a função sigmoide por uma função degrau unitário para forçar uma separação rígida.

17. Sobre o algoritmo de Gradiente Descendente aplicado à classificação, se a taxa de aprendizado (α) for definida com um valor excessivamente alto, o que provavelmente ocorrerá com a função de erro $J(a)$ ao longo das iterações?

- A) $J(a)$ diminuirá rapidamente até atingir o zero absoluto na primeira iteração.
- B) $J(a)$ poderá oscilar ou até aumentar, falhando em convergir para o mínimo da função de custo.
- C) $J(a)$ permanecerá constante, pois o modelo entrará em um estado de equilíbrio estático.

D) O modelo convergirá para o mesmo ponto, mas de forma mais lenta do que com um α pequeno.

18. Na Regressão Logística, quando o valor do rótulo é $y=0$, mas o modelo prevê uma probabilidade $h(x)$ muito próxima de 1, o que acontece com o valor da função de erro para esse exemplo específico?

A) O erro tende a zero, pois o erro é desprezível.

B) O erro permanece inalterado, pois a função logística suaviza discrepâncias.

C) O erro tende ao infinito, penalizando severamente o modelo pela confiança na predição errada.

D) O erro torna-se negativo para compensar o erro nas próximas instâncias.

Exercício prático

1. Usando o exemplo prático ao final do material sobre classificação como base, encontre o grau ideal para que um polinômio separe duas classes da melhor maneira possível. Apresente as acurácias e um gráfico com as regiões de decisão das duas classes.

Você deve atingir uma acurácia de 100% no conjunto de teste.

Use o código abaixo para gerar as amostras das duas classes.

```
# Import all necessary libraries.
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import PolynomialFeatures, StandardScaler
from sklearn.model_selection import KFold, train_test_split
from sklearn.pipeline import make_pipeline
from sklearn.datasets import make_moons
from sklearn.metrics import accuracy_score

# Reset pseudo random generator to a known value so that results are reproducible.
seed = 42
# Reset the PN sequence generator.
np.random.seed(seed)

# Number of examples.
N = 1000

# Create a 2-class dataset for classification.
X, y = make_moons(n_samples=N, noise=0.1, random_state=seed)

# Plot the two circles.
idx0 = np.argwhere(y == 0)
idx1 = np.argwhere(y == 1)
```

```
fig = plt.figure(figsize=(5,5))
plt.plot(X[idx0,0], X[idx0,1], '.', markersize=10, label='Class 0')
plt.plot(X[idx1,0], X[idx1,1], 'r^', markersize=10, label='Class 1')
plt.xlabel('$x_1$', fontsize=14)
plt.ylabel('$x_2$', fontsize=14)
plt.legend()
plt.grid()
plt.show()
```