

Lista de exercícios 8 de C24 - Inteligência Artificial

Métricas de classificação

Exercícios teóricos

1. Em um sistema de filtro de e-mails, um "falso positivo" ocorre quando um e-mail legítimo (ham) é classificado incorretamente como spam. Se o objetivo principal de um desenvolvedor é evitar que o usuário perca mensagens importantes, qual métrica deve ser priorizada?

- A) Recall.
- B) Precisão.
- C) Acurácia.
- D) F1-score.

2. Na análise de uma matriz de confusão para um problema de classificação, o que a diagonal principal representa especificamente?

- A) O total de falsos positivos e falsos negativos.
- B) A quantidade de exemplos que o classificador "confundiu".
- C) O número de classificações corretas para cada classe.
- D) A soma total de exemplos pertencentes à classe positiva.

3. Um modelo de diagnóstico médico para uma doença altamente contagiosa não pode se dar ao luxo de deixar um paciente doente sem tratamento. Nesse cenário, o custo de um "falso negativo" é considerado extremamente alto. Qual métrica melhor avalia a eficácia desse modelo?

- A) Recall (Sensibilidade).
- B) Precisão.
- C) Especificidade.
- D) Acurácia geral.

4. A acurácia é frequentemente a primeira métrica utilizada para avaliar um classificador. No entanto, ela pode ser enganosa em qual das seguintes situações?

- A) Quando o modelo possui um F1-score muito baixo.
- B) Quando o conjunto de dados possui classes desbalanceadas.
- C) Quando os custos de falsos positivos e falsos negativos são exatamente iguais.
- D) Quando o modelo é binário ($Q = 2$).

5. Qual é a principal função do F1-score em um projeto de Machine Learning?

- A) Medir a velocidade de processamento do classificador.
- B) Calcular a média aritmética simples entre acurácia e precisão.
- C) Combinar precisão e recall em uma única métrica, dando peso igual a ambas.
- D) Determinar a quantidade total de exemplos na classe negativa.

6. Considere um problema de classificação multiclasse com três classes (C_1 , C_2 , C_3). Para calcular o Recall específico da classe C_2 , como as outras classes devem ser tratadas?

- A) Devem ser ignoradas do cálculo.
- B) Devem ser agrupadas para formar uma única "classe negativa".
- C) Devem ser comparadas apenas entre si.
- D) Deve-se tirar a média aritmética dos acertos de C_1 e C_3 .

7. Matematicamente, se observarmos o limite da fórmula da acurácia quando o número de Verdadeiros Positivos (TP) tende ao infinito, enquanto as outras variáveis permanecem constantes, o resultado é 1. O que essa observação estatística revela sobre a acurácia em conjuntos de dados reais?

- A) Que a acurácia é a métrica mais estável para qualquer tipo de dado.
- B) Que um alto volume de acertos em uma classe majoritária pode mascarar falhas graves do modelo em outras classes.
- C) Que o modelo atingiu a perfeição técnica e não precisa de mais ajustes.
- D) Que os Falsos Positivos não afetam o desempenho final.

8. Em uma matriz de confusão C , o elemento C_{12} (seguindo a convenção onde linhas são predições e colunas são rótulos reais) indica:

- A) Exemplos da classe 1 que foram classificados corretamente.
- B) Exemplos da classe 1 que foram erroneamente classificados como classe 2.
- C) Exemplos da classe 2 que foram erroneamente classificados como classe 1.
- D) O total de exemplos pertencentes à classe 2.

9. Se um classificador apresenta um F1-score próximo de 1, o que se pode inferir sobre os erros cometidos pelo modelo?

- A) O modelo não cometeu Falsos Positivos, mas pode ter muitos Falsos Negativos.
- B) O modelo possui uma taxa de acurácia baixa, mas é muito rápido.
- C) Tanto a quantidade de Falsos Positivos quanto a de Falsos Negativos são próximas de zero.
- D) O modelo é bom apenas para classificar a classe negativa (TN).

10. Ao projetar um classificador para detectar transações fraudulentas em cartões de crédito, um engenheiro percebe que a precisão é muito alta, mas o recall é muito baixo. Qual o impacto prático desse resultado para a operadora do cartão?

- A) Muitos clientes terão suas compras legítimas bloqueadas injustamente.
- B) A maioria das fraudes reais não será detectada pelo sistema.
- C) O sistema é perfeito, pois não comete erros de classificação.
- D) A acurácia do sistema será necessariamente 0%.

Exercício prático

1. Neste exercício, vamos considerar o problema de classificar exemplos de veículos tendo como base alguns atributos extraídos de imagens de suas silhuetas.

Inicialmente, o conjunto de dados será dividido em duas partes, uma para treinamento e outra reservada para validação.

Em particular, usaremos os dados disponíveis na base Vehicle Silhouettes, que pode ser acessada através do link: [https://archive.ics.uci.edu/ml/datasets/Statlog+\(Vehicle+Silhouettes\)](https://archive.ics.uci.edu/ml/datasets/Statlog+(Vehicle+Silhouettes))

A base de dados possui 846 exemplos, onde cada exemplo (veículo) é descrito por 18 atributos numéricos (mostrados na tabela abaixo) e existem quatro classes possíveis: VAN, SAAB, BUS e OPEL.

Atributo	Descrição
COMPACTNESS	$(\text{average perim})^2/\text{area}$
CIRCULARITY	$(\text{average radius})^2/\text{area}$
DISTANCE CIRCULARITY	$\text{area}/(\text{av.distance from border})^2$
RADIUS RATIO	$(\text{max.rad}-\text{min.rad})/\text{av.radius}$
PR.AXIS ASPECT RATIO	$(\text{minor axis})/(\text{major axis})$
MAX.LENGTH ASPECT RATIO	$(\text{length perp. max length})/(\text{max length})$
SCATTER RATIO	$(\text{inertia about minor axis})/(\text{inertia about major axis})$
ELONGATEDNESS	$\text{area}/(\text{shrink width})^2$
PR.AXIS RECTANGULARITY	$\text{area}/(\text{pr.axis length}*\text{pr.axis width})$
MAX.LENGTH RECTANGULARITY	$\text{area}/(\text{max.length}*\text{length perp. to this})$
SCALED VARIANCE ALONG MAJOR AXIS	$(\text{2nd order moment about minor axis})/\text{area}$
SCALED VARIANCE ALONG MINOR AXIS	$(\text{2nd order moment about major axis})/\text{area}$
SCALED RADIUS OF GYRATION	$(\text{mavar}+\text{mivar})/\text{area}$
SKEWNESS ABOUT MAJOR AXIS	$(\text{3rd order moment about major axis})/\text{sigma_min}^3$
SKEWNESS ABOUT MINOR AXIS	$(\text{3rd order moment about minor axis})/\text{sigma_maj}^3$
KURTOSIS ABOUT MINOR AXIS	$(\text{4th order moment about major axis})/\text{sigma_min}^4$
KURTOSIS ABOUT MAJOR AXIS	$(\text{4th order moment about minor axis})/\text{sigma_maj}^4$
HOLLOWS RATIO	$(\text{area of hollows})/(\text{area of bounding polygon})$

1. Use o código abaixo para gerar os conjuntos de treinamento e validação.

OBS.: Perceba que os dados já são separados em conjuntos de treinamento e validação. Com 80% para treinamento e 20% para validação.

```
# Import all the necessary libraries.
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.metrics import mean_squared_error
from sklearn.model_selection import train_test_split
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import KFold
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import MinMaxScaler
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LogisticRegression
from sklearn.linear_model import LogisticRegressionCV
from sklearn.metrics import confusion_matrix, accuracy_score, roc_curve,
auc, f1_score
```

```

from sklearn.metrics import classification_report, precision_score,
recall_score

# Reset PN sequence generator.
seed = 42
np.random.seed(seed)

# Define the number of classes.
numberOfClasses = 4

# Load the dataset.
df = pd.read_csv('dataset_vehicle.csv')

# Convert the labels from strings into integer numbers.
c = {"van":0, "saab":1, "bus":2, "opel":3}
df.Class = [c[item] for item in df.Class]

# Convert dataset into numpy array.
data = df.to_numpy()

# Create attribute matrix and label vector.
X = data[:,0:18]
y = data[:,18]

# Split the data into training and validation datasets.
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=seed)

```

3. Treine o regressor softmax com o conjunto de treinamento.
 4. Calcule e imprima a acurácia do regressor softmax para os conjuntos de treinamento e teste. O que os valores indicam em termos de sobreajuste ou subajuste?
 5. Plote a matriz de confusão usando o conjunto de validação.
 6. Analise a matriz de confusão. O que você consegue concluir a respeito das confusões feitas pelo classificador?
- OBS.: Foque em classes similares e veja as confusões feitas entre elas.

7. Imprima o reporte de classificação. Qual classe o classificador tem maior dificuldade em classificar?