

Lista de exercícios 9 de C24 - Inteligência Artificial

Redes Multilayer Perceptron

Exercícios teóricos

1. Em uma rede neural do tipo MLP, qual é o papel fundamental das camadas ocultas (escondidas) no processamento dos dados?

- A) Atuar apenas como um ponto de transferência direta de atributos sem realizar cálculos.
- B) Reduzir a dimensionalidade dos dados de entrada para que a camada de saída possa processá-los linearmente.
- C) Criar representações intermediárias e extrair características relevantes dos dados de entrada.
- D) Substituir a necessidade de funções de ativação, simplificando o modelo matemático.

2. O que define uma rede neural como "profunda" (Deep Neural Network)?

- A) A complexidade matemática da função de erro utilizada.
- B) A presença de duas ou mais camadas ocultas em sua arquitetura.
- C) O fato de a rede ser treinada com um volume massivo de dados (Big Data).
- D) A utilização de conexões recursivas onde a saída volta para a entrada.

3. No modelo de um neurônio artificial, qual é a função principal do peso de "bias" (vies)?

- A) Multiplicar o valor de entrada para aumentar a força sináptica.
- B) Controlar o limiar de ativação ou o ponto de disparo da função de ativação.
- C) Inverter o sinal do gradiente durante a fase de retropropagação.
- D) Normalizar os dados de saída para ficarem entre 0 e 1.

4. O algoritmo de backpropagation (retropropagação) é essencial para o aprendizado das redes neurais. Em que princípio matemático ele se baseia primordialmente?

- A) Regra da Cadeia.
- B) Teorema de Pitágoras.
- C) Integração por Partes.
- D) Decomposição em Valores Singulares (SVD).

5. Por que as redes neurais artificiais são consideradas "aproximadores universais de funções"?

- A) Porque elas podem resolver qualquer problema sem a necessidade de treinamento.

- B) Porque possuem a capacidade de aproximar praticamente qualquer função contínua ou não contínua, desde que tenham arquitetura apropriada (e.g., nós e camadas suficientes).
- C) Porque utilizam apenas funções de ativação lineares que cobrem todos os espaços vetoriais.
- D) Porque são modelos biológicos perfeitos do cérebro humano.

6. Durante o treinamento, a etapa "forward" (direta) consiste em:

- A) Atualizar os pesos sinápticos usando o gradiente descendente.
- B) Calcular o erro e propagá-lo da saída para a entrada.
- C) Apresentar as entradas e processar os dados através das camadas para gerar uma predição (i.e., saída).
- D) Reinicializar aleatoriamente todos os pesos de bias da rede.

7. Qual é a principal diferença entre a camada de entrada e as demais camadas de uma MLP?

- A) A camada de entrada é a única que utiliza funções de ativação não lineares.
- B) A camada de entrada é responsável por calcular o erro final do modelo.
- C) A camada de entrada não possui pesos sinápticos associados a ela, servindo apenas como ponto de transferência.
- D) A camada de entrada deve ter sempre o mesmo número de neurônios que a camada de saída.

8. O que acontece se utilizarmos apenas funções de ativação lineares em todas as camadas de uma rede neural profunda?

- A) A rede se tornará extremamente poderosa e rápida.
- B) A rede será capaz de resolver problemas de classificação não linear complexos.
- C) O erro da rede sempre convergirá para zero instantaneamente.
- D) A rede se comportará como um modelo linear simples, independentemente do número de camadas.

9. No contexto de treinamento de redes neurais, o que são os "rótulos" (labels)?

- A) São os valores de saída esperados (reais) usados para calcular o erro da rede.
- B) São os nomes dados aos neurônios em cada camada.
- C) São as funções de ativação escolhidas para a camada oculta.
- D) São os parâmetros que definem a velocidade de aprendizado (learning rate).

10. Qual é a utilidade de se ter um conjunto de validação durante o desenvolvimento de uma MLP?

- A) Para treinar os pesos da rede de forma mais rápida.
- B) Para garantir que o erro de treinamento seja sempre zero.

- C) Para avaliar a capacidade de generalização e garantir que o modelo é bom em dados não vistos durante o treinamento.
- D) Para definir os valores iniciais dos pesos sinápticos de forma manual.

11. As superfícies de erro de redes neurais são descritas como não convexas. Qual é a principal implicação prática dessa característica durante o treinamento?

- A) O gradiente descendente sempre encontrará o mínimo global na primeira tentativa.
- B) Não é possível utilizar o algoritmo de retropropagação nessas superfícies.
- C) O erro da rede aumentará linearmente com o número de épocas de treinamento.
- D) O processo de otimização pode ficar preso em mínimos locais, platôs ou pontos de sela.

12. Segundo alguns estudos (como os de Choromanska e LeCun), por que o gradiente descendente ainda funciona bem em redes MLP, apesar da alta não convexidade?

- A) Porque as superfícies de erro tornam-se convexas quando o volume de dados é grande.
- B) Porque em redes complexas, a maioria dos mínimos locais possui um valor de erro muito próximo ao do mínimo global.
- C) Porque o algoritmo ignora os mínimos locais e salta diretamente para o ponto zero.
- D) Porque as funções de ativação transformam a superfície de erro em um plano perfeito.

13. Ao realizar vários treinamentos de uma mesma arquitetura com diferentes inicializações aleatórias, você observa que os resultados de erro final variam drasticamente entre as execuções. O que isso provavelmente indica?

- A) Que a superfície de erro é extremamente irregular e o treinamento pode estar convergindo para mínimos locais ruins.
- B) Que a rede já atingiu sua capacidade máxima de aprendizado.
- C) Que a função de erro escolhida é linear demais para o problema.
- D) Que a rede precisa de menos dados para estabilizar a convergência.

14. Considere a derivada parcial do erro em relação a um peso na primeira camada (por exemplo, $w_{\{1,1\}}^{(1)}$). Por que o valor do gradiente tende a diminuir à medida que a rede se torna muito profunda?

- A) Porque os pesos iniciais são sempre menores que os pesos finais.
- B) Devido às sucessivas multiplicações das derivadas das funções de ativação e pesos ao longo da regra da cadeia.
- C) Porque a camada de entrada anula o gradiente para proteger os dados originais.
- D) Porque o erro é corrigido apenas na camada de saída.

15. Qual é o impacto de se ter um número excessivo de pesos (graus de liberdade) em uma MLP em relação à complexidade da função que ela pode aproximar?

- A) A rede perde a capacidade de aproximar funções não lineares.
- B) Garante que a rede sempre funcionará perfeitamente em qualquer conjunto de teste.
- C) Aumenta o risco de a rede simplesmente memorizar os dados de treino (i.e., sobreajustar) em vez de aprender a função subjacente.
- D) Reduz a necessidade de usar o algoritmo de gradiente descendente.

16. Analisando o pseudocódigo do treinamento, o "passo de aprendizagem" (α) tem a função crítica de:

- A) Definir o número total de neurônios na camada oculta.
- B) Escalar o tamanho da atualização dos pesos em cada iteração do gradiente descendente.
- C) Escolher aleatoriamente quais amostras serão apresentadas à rede.
- D) Calcular a média dos erros quadráticos na camada de saída.

17. Em um problema de classificação com 3 classes exclusivas (por exemplo, Gato, Cachorro, Pássaro onde imagens de entrada possuem apenas um dos 3 animais), como deve ser estruturada a camada de saída da MLP? Dica: Faça uma analogia com a saída do regressor softmax.

- A) Três neurônios, onde cada um representa a probabilidade ou presença de uma classe.
- B) Um único neurônio com função de ativação linear.
- C) Um neurônio para cada atributo de entrada dos dados.
- D) A camada de saída deve ser removida e substituída por uma camada oculta extra.

18. No cálculo do gradiente para o peso $w_{11}^{(1)}$ da primeira camada oculta, a expressão final inclui a derivada da função de ativação $f'(u_{11}^{(1)})$. O que acontece com o aprendizado se o neurônio estiver "saturado" (por exemplo, em uma região muito plana da função sigmoide)?

- A) O aprendizado acelera, pois o gradiente se torna infinito.
- B) O peso $w_{11}^{(1)}$ não sofrerá ajuste significativo, pois a derivada será próxima de zero, anulando o gradiente.
- C) A função de erro mudará automaticamente para compensar a saturação.
- D) O neurônio passará a ignorar o peso de bias.

19. Durante o processo de desenvolvimento de um modelo MLP, é comum realizar vários treinamentos independentes utilizando diferentes inicializações aleatórias para os mesmos dados. Por que essa prática é recomendada para garantir a qualidade do modelo final?

- A) Para garantir que o erro de treinamento seja reduzido a zero em todas as tentativas, independentemente da arquitetura.
- B) Para testar se a rede funciona melhor sem a utilização de camadas ocultas em determinadas iterações.

- C) Para verificar a consistência dos resultados. Se diferentes inicializações convergem para erros semelhantes, há maior confiança de que a solução encontrada é robusta.
- D) Para aumentar a velocidade de processamento, já que múltiplos treinamentos simultâneos dividem a carga computacional da camada de saída.

20. Após a conclusão do treinamento de uma rede neural do tipo MLP, o modelo é capaz de receber novos dados e gerar previsões sem a necessidade de consultar os dados de treino originais. Do ponto de vista matemático e estrutural, onde fica "armazenado" o conhecimento que a rede adquiriu durante o processo de aprendizado?

- A) Na função de ativação escolhida, que se adapta dinamicamente a cada nova entrada de dados.
- B) No conjunto de rótulos (labels) que a rede memoriza durante as diversas épocas de treinamento.
- C) Na configuração específica dos valores dos pesos sinápticos e dos termos de bias (vieses) ajustados.
- D) No número de neurônios da camada de entrada, que armazena os padrões estatísticos dos dados.

21. O treinamento de uma MLP é um processo iterativo que utiliza o erro da saída para ajustar as camadas internas. Por que a existência de um "valor alvo" (rótulo ou label) é indispensável para que o algoritmo de retropropagação (backpropagation) consiga atualizar os pesos das camadas ocultas?

- A) Porque o erro nas camadas ocultas é calculado a partir da propagação reversa do erro medido na camada de saída.
- B) Porque os rótulos determinam automaticamente o número de neurônios que devem existir em cada camada oculta.
- C) Porque sem um valor alvo, a função de ativação não consegue processar números negativos vindos da entrada.
- D) Porque o valor alvo serve apenas para indicar o momento exato de parar o treinamento, não interferindo nos pesos.

Exercício prático

1. O objetivo deste exercício é implementar uma rede neural do tipo Multilayer Perceptron (MLP) para resolver um problema de classificação multiclasse usando Python. Você utilizará o Iris dataset, uma base de dados clássica de aprendizado de máquina que contém medidas de flores e suas respectivas espécies.

Utilize a base Iris Dataset, disponível em <https://archive.ics.uci.edu/ml/datasets/iris> ou carregue diretamente com a biblioteca sklearn.

A base possui:

- 150 amostras
- 4 atributos
 - comprimento da sépala
 - largura da sépala
 - comprimento da pétala
 - largura da pétala
- 3 classes
 - Iris-setosa
 - Iris-versicolor
 - Iris-virginica

Crie um notebook Jupyter utilizando TensorFlow/Keras que execute as seguintes etapas.

1.1 Carregamento da base de dados

Carregue a base de dados Iris utilizando:

```
from sklearn.datasets import load_iris
```

Separe os dados em:

- matriz de atributos, X
- vetor de classes, y

1.2 Divisão treino/teste

Divida os dados em:

- 80% para treinamento
- 20% para teste

Use a função: *train_test_split*

1.3 Normalização dos dados

Normalize os atributos para melhorar o treinamento da rede neural.

Sugestão: use o *StandardScaler*

1.4 Construção da rede neural MLP

Implemente uma rede neural com a seguinte arquitetura:

Entrada: 4 atributos de entrada

Camada oculta: 10 neurônios (ReLU)

Camada de saída: 3 neurônios (Softmax)

1.5 Treinamento da rede

Treine a rede utilizando:

- optimizer: SGD
- função de erro: *sparse_categorical_crossentropy*

- épocas: 100

1.6 Avaliação do modelo

Calcule:

- Acurácia no conjunto de teste

1.7 Predição

Utilize o modelo treinado para prever a classe de 5 amostras do conjunto de teste.

1.8 Perguntas

1. Qual foi a acurácia do modelo nos conjuntos de treinamento e teste?
2. A rede conseguiu classificar corretamente a maioria das amostras do conjunto de teste?
3. O que acontece se aumentarmos o número de neurônios na camada oculta? Altere a arquitetura da rede e execute o treinamento e testes.