Lista de exercícios 10 de C24 - Inteligência Artificial

Redes neurais convolucionais

Exercícios teóricos

1. Qual é a principal diferença estrutural entre uma Rede Neural Densa (DNN) e uma Rede Neural Convolucional (CNN) no tratamento de imagens?

A) As DNNs aprendem filtros de convolução, enquanto as CNNs focam apenas em pesos de camadas densas.
B) As CNNs consideram a estrutura espacial e a localidade dos pixels, enquanto as DNNs ignoram a topologia de grade e tratam pixels distantes da mesma forma que os próximos.
C) As DNNs são mais eficientes computacionalmente para imagens de alta resolução do que as CNNs.
D) As CNNs não utilizam funções de ativação, ao contrário das DNNs.

2. Qual é a função primordial de um "kernel" (ou filtro) dentro de uma camada convolucional?

A) Transformar um volume 3D em um vetor unidimensional para classificação.
B) Reduzir a resolução da imagem para economizar memória RAM.
C) Percorrer a imagem realizando operações matemáticas para detectar características específicas, como bordas e texturas.
D) Atuar como uma função de ativação para decidir se um neurônio deve disparar.

3. O que ocorre na camada de "Flatten" em uma arquitetura de CNN?

A) Os mapas de características 3D são transformados em um vetor 1D para alimentar as camadas densas.
B) A imagem é convertida para tons de cinza para simplificar o processamento.
C) Ocorre a subamostragem dos dados para reduzir o risco de sobreajuste.
D) São aplicados filtros de preenchimento nas bordas para manter o tamanho original.

4. Por que a função de ativação ReLU é amplamente utilizada após as operações de convolução?

A) Para garantir que a saída da rede seja sempre uma distribuição de probabilidade.
B) Para aumentar o tamanho espacial dos mapas de características.
C) Para introduzir não linearidade e mitigar o problema do desaparecimento do gradiente.
D) Para converter todos os valores negativos em valores aleatórios positivos.

5. Na operação de convolução, o parâmetro "Stride" (passo) refere-se a:

A) A quantidade de preenchimento de zeros adicionada às bordas da imagem.
B) A profundidade do kernel utilizado para imagens coloridas.
C) O número de elementos que a janela de convolução desliza por vez ao percorrer a entrada.
D) O número total de camadas convolucionais presentes na rede.

6. Qual é o principal benefício da utilização da camada de Pooling (subamostragem)?

A) Aumentar o número de parâmetros treináveis para tornar a rede mais complexa.
B) Garantir que todos os pixels da borda participem igualmente da convolução.
C) Alterar os valores dos pesos dos filtros durante a fase de retropropagação.
D) Reduzir as dimensões espaciais dos mapas de características, diminuindo a carga computacional e o risco de overfitting, além de tornar a rede mais robusta a pequenas variações na posição dos objetos.

7. O conceito de "localidade de referência" em imagens implica que:

A) Pixels em cantos opostos de uma imagem têm sempre a mesma importância semântica.
B) A posição de um objeto na imagem não influencia sua classificação final.
C) Pixels vizinhos tendem a estar correlacionados e contêm informações relacionadas, como partes de um mesmo objeto.
D) A rede deve processar a imagem inteira de uma só vez para entender padrões globais.

8. Qual é a função da camada Softmax em uma CNN voltada para classificação?

A) Extrair bordas verticais e horizontais da imagem original.
B) Gerar uma distribuição probabilística sobre as classes possíveis na saída da rede.
C) Zerar aleatoriamente alguns neurônios para evitar a dependência de combinações fixas.
D) Reduzir a dimensionalidade dos dados antes da camada de flatten.

9. Qual é o objetivo técnico de aplicar "Padding" (preenchimento) nas bordas de uma imagem?

A) Controlar o tamanho do mapa de características e evitar a perda de informação nas bordas.
B) Aumentar a velocidade de treinamento ao reduzir o número de canais.
C) Eliminar completamente a necessidade de usar camadas de Pooling.
D) Transformar imagens em tons de cinza em imagens coloridas artificialmente.

10. A técnica de "Data Augmentation" é utilizada principalmente para:

A) Reduzir o número de filtros necessários em cada camada convolucional.
B) Transferir o conhecimento de uma rede pré-treinada para uma nova tarefa.
C) Aumentar artificialmente a diversidade do dataset de treinamento, criando variações das imagens existentes.
D) Substituir o algoritmo de retropropagação por um método mais rápido.

11. Como a propriedade de "estacionariedade" é explorada pelas CNNs para otimizar o aprendizado?

A) Através da conexão total de cada neurônio a todos os pixels, garantindo visão global.
B) Pela exclusão de camadas densas no final da arquitetura para manter os dados estáticos.
C) Pelo compartilhamento de pesos, onde o mesmo filtro é aplicado em diferentes posições da imagem.
D) Pela aplicação de filtros diferentes para cada pixel individual da imagem.

12. Se uma imagem de entrada possui 32x32 pixels e aplicamos uma camada convolucional com kernel 5x5, stride 1 e sem padding, qual será a dimensão da saída?

A) 32x32
B) 27x27
C) 28x28
D) 30x30

13. No contexto da composição hierárquica de padrões, o que caracteriza o aprendizado das camadas iniciais versus as camadas finais de uma CNN?

A) Camadas iniciais aprendem objetos completos; camadas finais aprendem bordas simples.
B) Camadas iniciais aprendem bordas e texturas; camadas finais aprendem partes complexas e objetos completos.
C) Ambas as camadas aprendem os mesmos padrões, diferenciando-se apenas pelo bias.
D) Camadas iniciais realizam classificação, enquanto as finais realizam extração de características.

14. De que maneira a operação de Max Pooling contribui para a "invariância local" do modelo?

A) Ela permite que a rede reconheça um padrão mesmo que ele sofra pequenos deslocamentos ou deformações espaciais.
B) Ela força a rede a aprender apenas a posição exata de cada pixel ruidoso.
C) Ela aumenta a resolução da imagem para que detalhes mínimos não sejam perdidos.
D) Ela garante que os filtros de convolução nunca mudem de valor durante o treinamento.

15. Qual foi a principal influência das descobertas biológicas de Hubel e Wiesel (córtex visual) na concepção das CNNs?

A) A descoberta de que o cérebro processa imagens de forma tabular e global.
B) A prova de que a visão humana não utiliza nenhum tipo de hierarquia de padrões.
C) A criação do algoritmo de retropropagação baseado no sistema nervoso central.
D) A observação de que neurônios respondem a padrões específicos (como linhas) em campos receptivos locais.

16. Sobre o funcionamento do Dropout, como ele atua de forma distinta entre o treinamento e a inferência (uso do modelo)?

A) No treinamento, ele desliga neurônios aleatoriamente; na inferência, todos os neurônios são utilizados.
B) No treinamento, ele aumenta os pesos; na inferência, ele reduz os pesos a zero.
C) No treinamento, ele é aplicado apenas em imagens coloridas; na inferência, apenas em tons de cinza.
D) O Dropout é aplicado da mesma forma em ambas as fases para manter a consistência.

17. Ao processar uma imagem colorida com 3 canais (RGB), como um kernel de convolução se comporta estruturalmente?

A) O kernel permanece 2D e é aplicado apenas no canal verde (G).
B) O kernel assume 3 dimensões para processar os 3 canais simultaneamente, somando os resultados ao final.
C) Três redes neurais separadas são treinadas, uma para cada cor primária.
D) A imagem é achatada em um vetor 1D antes da aplicação do filtro.

18. Por que a conectividade total (DNN pura) é ineficiente para imagens de alta resolução em comparação com a conectividade local (CNN)?

A) Porque as DNNs não permitem o uso de pesos negativos.
B) Porque as DNNs são incapazes de realizar tarefas de classificação simples.
C) Porque gera um número enorme de parâmetros (por exemplo, milhões de pesos apenas na primeira camada), causando alto custo computacional e risco de overfitting.
D) Porque a conectividade total impede que a rede utilize funções de erro como a entropia cruzada.

19. O que indica a intensidade de ativação em um "Mapa de Características" resultante de uma convolução?

A) Indica que uma característica específica (por exemplo, uma borda) está fortemente presente naquela posição espacial.
B) Indica que o pixel naquela posição deve ser ignorado pela camada de pooling.
C) Representa a probabilidade final da imagem pertencer a uma classe específica.
D) Mostra o número de vezes que o algoritmo de dropout desligou aquele neurônio.

Questão opcional sobre transfer learning

20. O cenário mais propício para o uso de "Transfer Learning" ocorre quando:

A) Os dados de treinamento são extremamente abundantes e variados.

B) O objetivo é treinar uma rede do zero sem qualquer conhecimento prévio.
C) Os dados de treinamento são escassos, mas existe um modelo pré-treinado em uma tarefa relacionada.
D) A tarefa final não envolve nenhum tipo de reconhecimento de padrões visuais.

Exercício prático

1. Acesse o link abaixo para resolver o exercício prático. Ao clicar no link, um notebook Jupyter será aberto, contendo o enunciado e dicas para resolver o exercício.

https://colab.research.google.com/github/zz4fap/c24_inteligencia_artificial/blob/master/notebooks/Exercicio_sobre_redes_neurais_convolucionais.ipynb