

Lista de exercícios 12 de C24 - Inteligência Artificial

Árvores de decisão

Exercícios teóricos

1. Árvores de decisão são classificadas como modelos de aprendizado supervisionado não-paramétricos. O que essa característica implica fundamentalmente durante o processo de treinamento?

- A) O modelo possui uma forma funcional fixa e um número constante de parâmetros definidos antes do processamento dos dados.
- B) A complexidade do modelo é flexível e o número de parâmetros tende a crescer de acordo com o tamanho e a diversidade da base de dados.
- C) O algoritmo assume que os dados seguem necessariamente uma distribuição normal para realizar a separação das classes.
- D) O modelo é incapaz de realizar previsões de regressão, sendo restrito apenas a problemas de classificação binária.

2. Na estrutura de uma árvore de decisão, como são denominados os elementos que representam o ponto de partida do processo e as decisões finais, respectivamente?

- A) Nó de decisão e ramificações.
- B) Nó folha e nó raiz.
- C) Nó raiz e nós folha.
- D) Arestas e nós de teste.

3. Uma vantagem competitiva das árvores de decisão em relação às redes neurais artificiais é a sua natureza de "caixa branca". Isso significa que:

- A) O modelo exige um pré-processamento exaustivo, como o escalonamento obrigatório de todos os atributos.
- B) Os resultados são difíceis de interpretar, mas garantem maior precisão em qualquer tipo de dado.
- C) O modelo funciona apenas com variáveis contínuas e não aceita dados categóricos ou discretos.
- D) É possível entender e explicar facilmente a lógica utilizada pelo modelo para chegar a uma classificação baseando-se nos atributos.

4. O conceito de Entropia é fundamental para a construção de árvores via algoritmo ID3. O que uma entropia igual a zero em um subconjunto de dados sinaliza para o algoritmo?

- A) Que o conjunto é puro, ou seja, todas as amostras pertencem a uma mesma classe, não havendo mais incerteza.

- B) Que o conjunto está totalmente "bagunçado" e contém proporções iguais de todas as classes.
- C) Que o atributo testado não possui nenhuma relevância estatística para o problema em questão.
- D) Que o algoritmo encontrou um erro de inconsistência em que atributos iguais geram classes diferentes.

5. O algoritmo ID3 utiliza uma estratégia "gananciosa" (greedy) e uma abordagem "top-down". Qual a consequência direta dessa escolha técnica?

- A) O algoritmo garante a obtenção da menor árvore possível para qualquer conjunto de dados.
- B) O modelo testa todas as combinações futuras de atributos antes de realizar a primeira divisão.
- C) O atributo que melhor divide os dados no momento presente é escolhido, sem garantir que essa seja a melhor solução global.
- D) A árvore é construída de baixo para cima, começando pelas classes e subindo até os atributos raiz.

6. Quando uma árvore de decisão não é restringida, ela pode crescer até classificar perfeitamente o conjunto de treinamento, mas falhar em dados inéditos (baixa capacidade de generalização). Esse fenômeno de alta variância é conhecido como:

- A) Subajuste (Underfitting).
- B) Regularização linear.
- C) Convergência estocástica.
- D) Sobreajuste (Overfitting).

7. Diferente da classificação, as árvores de regressão realizam previsões que possuem qual característica matemática?

- A) São aproximações constantes por partes, onde o valor previsto é a média dos exemplos em cada trecho.
- B) São funções suaves, contínuas e lineares que atravessam todos os pontos do gráfico.
- C) São curvas polinomiais que minimizam apenas a entropia residual do conjunto.
- D) São retas inclinadas que dependem exclusivamente de um número fixo de pesos iniciais.

8. Para mitigar problemas de instabilidade e excesso de complexidade, utilizam-se hiperparâmetros. Qual deles é responsável por limitar diretamente o número de níveis da árvore?

- A) min_samples_split.
- B) max_depth.
- C) min_samples_leaf.
- D) max_features.

9. Na comparação entre os algoritmos ID3 e CART (utilizado no Scikit-Learn), uma diferença crucial na estrutura da árvore gerada é que o CART:

- A) Gera sempre árvores binárias, limitando cada nó a apenas duas ramificações.
- B) Não permite a utilização de atributos contínuos, aceitando apenas dados categóricos.
- C) Proíbe a repetição de qualquer atributo em diferentes ramos da mesma árvore.
- D) Utiliza exclusivamente o Ganho de Informação como critério de divisão para classificação.

10. Florestas Aleatórias (Random Forests) são frequentemente preferidas em relação a uma única árvore de decisão porque:

- A) São modelos de caixa branca muito mais fáceis de visualizar do que uma árvore simples.
- B) Reduzem a variância ao combinar as predições de várias árvores treinadas em dados aleatórios.
- C) Exigem que o usuário defina manualmente todos os pesos de cada atributo antes do treino.
- D) Garantem que a árvore final terá sempre a profundidade máxima permitida pelo hardware.

11. A indução de uma árvore de decisão ótima é um problema NP-completo. O que essa classificação teórica justifica no design de algoritmos como o ID3?

- A) A necessidade de processamento paralelo em tempo real para garantir que a árvore seja a menor possível.
- B) A obrigatoriedade de utilizar apenas dois atributos por conjunto de dados para evitar o crescimento exponencial.
- C) O uso de heurísticas práticas para encontrar soluções aproximadas em tempo viável, já que a busca exaustiva é proibitiva.
- D) A prova de que árvores de decisão não podem ser utilizadas em problemas com mais de 20 cidades, como no caso do Caixeiro Viajante.

12. Geometricamente, por que as árvores de decisão são descritas como altamente sensíveis a rotações no conjunto de treinamento?

- A) Porque elas tentam ajustar curvas de alta ordem que mudam de sinal conforme ao ângulo dos dados.
- B) Porque suas fronteiras de decisão são sempre perpendiculares aos eixos dos atributos, exigindo mais divisões para dados inclinados.
- C) Porque o cálculo da entropia depende da norma euclidiana, que não é invariante à rotação.
- D) Porque elas utilizam PCA internamente para rotacionar os dados de volta à origem em cada iteração.

13. Considere o uso do Ganho de Informação para selecionar atributos. Se um conjunto de dados incluir um atributo com um valor único para cada exemplo (como um número de CPF ou ID), qual o risco para o modelo?

- A) O atributo terá o maior ganho de informação possível, levando o modelo a criar uma árvore inútil que não generaliza para novos dados.
- B) O modelo ignorará o atributo, pois a entropia resultante seria máxima (bagunça total).
- C) O modelo entrará em um loop infinito tentando calcular o logaritmo de zero para cada classe individual.
- D) O Ganho de Informação será negativo, forçando o algoritmo a podar a árvore precocemente.

14. Por que o tratamento de atributos contínuos em árvores de decisão é computacionalmente mais exigente do que o de atributos categóricos?

- A) Dados contínuos exigem a aplicação obrigatória da regra de L'Hôpital em cada nó de decisão.
- B) Diferente de categorias fixas, atributos contínuos oferecem múltiplos pontos de corte potenciais que precisam ser ordenados e testados exaustivamente.
- C) Atributos contínuos só podem ser processados se forem previamente transformados em funções logarítmicas de base 2.
- D) O uso de números reais impede o cálculo do Ganho de Informação, exigindo o uso de Redes Neurais como passo intermediário.

15. Considere um problema de classificação no qual uma árvore de decisão foi treinada utilizando o método ID3. Após o treinamento, observou-se que:

- Um dos atributos disponíveis no conjunto de dados não foi utilizado em nenhum nó da árvore.
- A árvore resultante classifica perfeitamente todos os exemplos de treinamento.
- Alguns ramos da árvore atingem entropia zero rapidamente, enquanto outros exigem múltiplas divisões.

Com base nessas observações, analise as afirmações:

- I. O atributo não utilizado pode ser considerado irrelevante para o problema, pois não contribuiu para a redução da incerteza em nenhuma etapa do processo.
- II. A classificação perfeita dos dados de treinamento indica necessariamente boa capacidade de generalização do modelo.
- III. Ramos que atingem entropia zero rapidamente correspondem a subconjuntos mais homogêneos em relação às classes.
- IV. A necessidade de múltiplas divisões em alguns ramos indica que o ganho de informação inicial desses caminhos era menor, exigindo refinamentos sucessivos.

Assinale a alternativa correta:

- A) Apenas I, II e III estão corretas.
- B) Apenas I, III e IV estão corretas.

- C) Apenas II e IV estão corretas.
- D) Apenas I e IV estão corretas.

Exercício prático

Classificação com Árvores de Decisão (Scikit-learn)

Objetivo: Treinar, avaliar e interpretar uma árvore de decisão para um problema de classificação.

Neste exercício, usaremos o dataset Iris. Ele é um dos conjuntos de dados mais clássicos em aprendizado de máquina, introduzido por Ronald Fisher. Ele contém 150 amostras de flores de três espécies: *setosa*, *versicolor* e *virginica*. Elas são descritas por quatro atributos numéricos: comprimento e largura das sépalas, e comprimento e largura das pétalas. O objetivo é classificar corretamente a espécie da flor com base nessas medidas. Por sua simplicidade, baixo ruído e boa separabilidade entre classes, o Iris é amplamente utilizado para ensino, testes de algoritmos e validação de modelos de classificação, sendo ideal para introduzir conceitos como árvores de decisão.

1. Crie um notebook Jupyter, copie, cole o código abaixo e execute-o.

```
# Importa as bibliotecas necessárias
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import accuracy_score, classification_report

# Carrega o dataset Iris
data = load_iris()
X = data.data
y = data.target

# Converte para DataFrame para melhor visualização
df = pd.DataFrame(X, columns=data.feature_names)
df["target"] = y
print(df.head())
```

2. Divida os dados em 70% para treinamento e 30% para teste.

3. Instancie e treine um modelo de árvore de decisão para classificação (DecisionTreeClassifier) usando a entropia como critério.

4. Realize previsões com o modelo treinado usando os conjuntos de treinamento e teste, em seguida, calcule a acurácia para ambos os conjuntos.

Pergunta: Dados os valores das acurácias, podemos dizer que o modelo está se sobreajustando, subajustando ou encontramos um modelo com uma boa capacidade de generalização?

5. Imprima o relatório de classificação com a função `classification_report` usando o conjunto de teste e responda

- O modelo está equilibrado entre as classes?
- Há alguma classe com desempenho pior?

6. Plote a árvore e responda

- Qual atributo foi escolhido como raiz?
- Isso faz sentido do ponto de vista de separação dos dados?

7. Treine uma árvore com restrição de profundidade (`max_depth`). Teste valores de profundidade entre 1 e 5. Para cada valor de profundidade, calcule a acurácia com ambos os conjuntos, imprima o relatório de classificação com o conjunto de teste e plote a árvore encontrada. Responda

- A acurácia mudou?
- As árvores ficaram mais simples?
- Qual modelo generaliza melhor?

8. Teste os seguintes hiperparâmetros:

- `min_samples_leaf`
- `max_leaf_nodes`
- `max_features`

Seu objetivo será encontrar um melhor modelo que tenha uma boa capacidade de generalização. Você deve usar validação cruzada para encontrar os melhores valores.