

Lista de exercícios 13 de C24 - Inteligência Artificial

k-Means

Exercícios teóricos

1. No contexto de Aprendizado de Máquina, o clustering (agrupamento) é classificado como uma técnica de aprendizado não supervisionado. Qual é o principal objetivo dessa tarefa?
 - A) Prever uma classe específica para cada exemplo com base em rótulos previamente conhecidos.
 - B) Minimizar o erro quadrático médio em relação a uma variável alvo contínua.
 - C) Identificar a estrutura intrínseca dos dados e organizá-los em grupos com base na similaridade.
 - D) Reduzir a dimensionalidade dos dados descartando atributos que não possuem correlação.
2. O algoritmo k-Means utiliza o conceito de "centroide" para representar cada grupo. Como esse centroide é matematicamente definido durante a execução do algoritmo?
 - A) É o ponto que possui a maior densidade de amostras ao seu redor.
 - B) É a média aritmética (centro geométrico) de todos os vetores de atributos das amostras pertencentes àquele cluster.
 - C) É um exemplo real do conjunto de dados escolhido aleatoriamente para liderar o grupo.
 - D) É a mediana dos valores de cada atributo, visando reduzir a influência de outliers.
3. Uma etapa crítica do k-Means é a medição da distância entre amostras e centroides. Caso um analista utilize a distância euclidiana, o que ele está priorizando na formação dos clusters?
 - A) A densidade de conexões entre os pontos adjacentes.
 - B) A probabilidade de uma amostra pertencer a uma distribuição gaussiana.
 - C) A menor magnitude da diferença direta entre os valores dos atributos das amostras e do centroide.
 - D) A similaridade semântica baseada na frequência de ocorrência de atributos categóricos.
4. A métrica de "Inércia" (ou soma dos quadrados intra-clusters) é frequentemente usada para avaliar a qualidade de um modelo k-Means. O que uma inércia baixa indica sobre os clusters formados?
 - A) Que os pontos dentro de um mesmo cluster estão altamente coesos e próximos de seu centroide.
 - B) Que os clusters estão muito distantes uns dos outros no espaço de atributos.
 - C) Que o número de clusters (k) escolhido é insuficiente para representar a complexidade dos dados.
 - D) Que o algoritmo atingiu o número máximo de iterações sem convergir.

5. Qual das situações abaixo descreve corretamente uma aplicação de centroides na detecção de anomalias?

- A) Uma amostra é considerada normal se estiver exatamente na mesma posição que um centroide.
- B) Anomalias são identificadas quando um cluster possui mais pontos do que a média dos demais grupos.
- C) O sistema detecta anomalias apenas quando os centroides param de mudar de posição prematuramente.
- D) Uma amostra é classificada como anomalia se a distância entre ela e o centroide mais próximo for significativamente alta.

6. O algoritmo k-Means é conhecido por ser "sensível à inicialização". Qual é a consequência prática de se iniciar os centroides de forma puramente aleatória em diferentes execuções sobre o mesmo dataset?

- A) O algoritmo sempre chegará à mesma solução, mas o tempo de processamento variará drasticamente.
- B) O número final de clusters (k) pode ser alterado automaticamente pelo algoritmo para compensar a má inicialização.
- C) O algoritmo pode convergir para agrupamentos diferentes para cada execução.
- D) A distância euclidiana deixará de ser válida se os centroides iniciais estiverem muito próximos uns dos outros.

7. Ao utilizar o "Método do Cotovelo" (Elbow Method), um cientista de dados observa que a curva de inércia em função de k apresenta uma transição muito suave, dificultando a visualização clara do "cotovelo". Qual técnica avançada pode ser aplicada para identificar o k ideal nesse cenário?

- A) Selecionar o valor de k que reduz a inércia a zero, independentemente da complexidade.
- B) Traçar uma reta entre os pontos extremos da curva e localizar o ponto da curva que está à maior distância dessa reta.
- C) Calcular a média aritmética entre o menor e o maior valor de k testados no intervalo.
- D) Ignorar a inércia e utilizar um algoritmo supervisionado para validar o número de grupos.

8. Em um processo de Engenharia de Atributos (Feature Engineering), como os resultados de um modelo k-Means podem ser utilizados para melhorar um modelo de classificação supervisionada subsequente?

- A) Substituindo todos os atributos originais pelo valor numérico da inércia final.
- B) Excluindo todas as amostras que não pertencem ao cluster majoritário para simplificar o treino.

C) Utilizando o índice do cluster (Cluster ID) ou a distância da amostra até cada centroide como novos atributos de entrada.

D) Usando a média dos atributos de cada cluster para preencher valores ausentes em rótulos categóricos.

9. Por que simplesmente buscar o valor de k que minimiza a inércia total não é uma estratégia viável para definir o número ideal de clusters?

A) Porque a inércia aumenta conforme adicionamos mais clusters, tornando o modelo instável.

B) Porque a inércia atinge seu valor mínimo (zero) quando k é igual ao número total de amostras (N), o que gera um modelo extremamente complexo que se sobreajusta ao conjunto de treinamento.

C) Porque o cálculo da inércia é computacionalmente impossível para valores de k maiores que 10.

D) Porque a inércia só pode ser calculada se o número de clusters for par.

10. Durante o ciclo de execução do algoritmo k-Means, o processo entra em uma fase repetitiva de atribuição de amostras e atualização de centroides. O que caracteriza o momento da "convergência", indicando que o algoritmo pode encerrar o processamento?

A) Quando o valor da inércia (soma dos quadrados intra-clusters) atinge exatamente zero.

B) Quando o número de amostras em cada grupo torna-se perfeitamente igual em todos os clusters.

C) Quando as posições dos centroides param de mudar entre uma iteração e outra, ou um limite máximo de repetições é atingido.

D) Quando o algoritmo identifica que o número de clusters (k) escolhido é insuficiente e solicita um novo valor ao usuário.

Exercícios práticos

1. Escolha de Locais para Centros de Distribuição com k-Means

Uma empresa de logística deseja instalar centros de distribuição (CDs) em uma região para atender 1000 clientes de forma eficiente. O objetivo é minimizar a distância total de transporte entre os centros e os clientes.

1. Execute o código abaixo para observar as coordenadas geográficas (latitude e longitude) dos clientes.

```
import numpy as np
import pandas as pd
from sklearn.datasets import make_blobs
import matplotlib.pyplot as plt
```

```
# Gerar dados fictícios (1000 clientes, 2 clusters naturais)
clientes, _ = make_blobs(n_samples=1000, centers=3, cluster_std=5,
random_state=42)

df = pd.DataFrame(clientes, columns=['latitude', 'longitude'])

# Plotar clientes e centroides
plt.scatter(df['latitude'], df['longitude'], s=10)
plt.xlabel('Latitude')
plt.ylabel('Longitude')
plt.title('Coordenadas geográficas (latitude e longitude) dos clientes')
plt.show()
```

2. Qual é a quantidade correta de centros de distribuição para minimizar a distância entre os clientes e os centros?

OBS.: Você pode usar o método do cotovelo para descobrir a quantidade de centros de distribuição.

3. Plote o mapa final mostrando clientes coloridos de acordo com o CD que os atenderá e marque a localização exata de cada CD com um grande ícone de estrela (ou "X").

2. Identificação de outliers

O k-means é tradicionalmente um algoritmo de agrupamento (clustering), mas pode ser adaptado para detecção de anomalias (outliers). A lógica é simples: o comportamento normal da rede forma grupos densos. Se um evento de rede (um ponto) cai muito longe do centro (centroide) de qualquer um desses grupos, ele é um comportamento anômalo e uma possível ameaça.

Cenário: Você tem um conjunto de logs de rede monitorando duas variáveis principais por usuário/IP:

1. Tentativas de Login Falhas (indicador de força bruta).
2. Dados Transferidos em MB (indicador de exfiltração de dados).

Objetivo: Aplicar o K-means e identificar os outliers com base na distância euclidiana para os centroides: $d = \sqrt{(x - \mu_x)^2 + (y - \mu_y)^2}$, onde x e y representam o evento de rede, μ_x e μ_y formam as coordenadas dos centroides.

1. Execute o código abaixo para gerar a base de dados com tráfego normal e anormal.

```
import numpy as np
```

```
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.datasets import make_blobs

# 1. Geração de Dados Sintéticos
# Simulando comportamento normal (3 perfis de usuários normais)
X_normal, _ = make_blobs(n_samples=300, centers=3, cluster_std=1.0,
random_state=42)

# Simulando ameaças cibernéticas (outliers espalhados)
# Ex: Muitas falhas de login, ou transferência massiva de dados
X_threats = np.random.uniform(low=-5, high=15, size=(15, 2))

# Combinando os dados
X = np.vstack([X_normal, X_threats])
```

2. Treine o modelo k-Means definindo o número de clusters como 3 (já que criamos 3 perfis normais de usuários).

3. Cálculo das distâncias

- Use `.predict()` para descobrir a qual cluster cada ponto de dado pertence.
- Extraia as coordenadas dos centros dos clusters usando `.cluster_centers_`.
- Calcule a distância Euclidiana entre cada evento e o centroide do seu respectivo grupo usando `np.linalg.norm`.

4. Definição do Limiar de Risco (Threshold)

- Utilize a função `np.percentile` nas distâncias calculadas para estabelecer o limiar no percentil 95. Isso significa que os 5% dos eventos que estiverem mais afastados de seus centroides serão considerados anomalias.
- Filtre e guarde os índices dos pontos que ultrapassarem esse limiar matemático.
- Imprima no terminal o total de eventos, o valor do limiar e quantas ameaças foram detectadas.

5. Mapeamento Visual da Rede

- Crie uma figura usando `plt.figure`.
- Plote todos os eventos de rede usando `plt.scatter`, colorindo-os de acordo com os clusters previstos no passo 3.
- Plote os centroides com um marcador diferente (por exemplo, um "X" preto e grande) para evidenciar onde está o "coração" do comportamento normal.
- Desenhe círculos vermelhos (marcadores vazados) exclusivamente ao redor dos pontos que foram identificados como outliers no Passo 4.

- Adicione título, legendas e rótulos aos eixos (ex: "Tentativas de Login Falhas" e "Volume de Dados Transferidos") e exiba o gráfico com `plt.show()`.