

Lista de exercícios 14 de C24 - Inteligência Artificial

Q-learning

Exercícios teóricos

1. Qual a principal característica que diferencia o Aprendizado por Reforço (RL) do Aprendizado Supervisionado?

- A) O RL utiliza um grande conjunto de dados rotulados estruturados para treinar o agente de forma contínua antes de ele começar a agir.
- B) O RL não possui um conjunto de dados prévio; o agente aprende por tentativa e erro enquanto interage com o ambiente.
- C) O RL foca apenas em agrupar dados com características semelhantes, não havendo o conceito de recompensa ao longo do treinamento.
- D) O RL depende de um supervisor humano constante no circuito para corrigir a ação do agente após cada movimento.

2. O que a função Valor-Ação, geralmente representada pela letra "Q" (Qualidade), busca mensurar em um algoritmo de Q-Learning?

- A) A probabilidade estatística de sobrevivência do agente em um ambiente desconhecido.
- B) A quantidade mínima de episódios necessários para o algoritmo atingir a convergência total.
- C) O retorno ou a recompensa total esperada ao executar uma ação específica partindo de um determinado estado.
- D) O nível exato de exploração aleatória que o agente deve realizar na sua próxima iteração.

3. Na estratégia de tomada de decisão Epsilon-Greedy, qual é o raciocínio prático para iniciar com um valor de epsilon alto e reduzi-lo gradualmente ao longo do treinamento?

- A) Impedir que o agente explore cenários não previstos no início, focando-o puramente na coleta de recompensas imediatas de baixo risco.
- B) Garantir que a equação de Bellman gere erros de diferença temporal cada vez maiores nas fases finais.
- C) Eliminar a possibilidade do algoritmo memorizar a tabela-Q nos primeiros estágios de processamento.
- D) Permitir uma descoberta agressiva e ampla do ambiente no começo e, conforme o conhecimento se consolida, passar a utilizar (explotar) o caminho ótimo descoberto.

4. Como é caracterizado o término de um "episódio" durante o treinamento de um agente em Aprendizado por Reforço?

- A) Quando a taxa de aprendizado (α) do modelo decai a zero, estabilizando as equações matemáticas.

- B) Quando o agente preenche todas as linhas de sua tabela-Q com valores positivos.
- C) Quando é alcançado um estado terminal, o que pode ocorrer ao se atingir um objetivo, cometer um erro fatal ou atingir um limite de passos/tempo.
- D) Quando o ambiente interrompe o fornecimento de qualquer feedback em formato de recompensa imediata.

5. Na arquitetura do Q-Learning, emprega-se uma estrutura tabular, conhecida como Tabela-Q. O que representam os eixos das linhas e das colunas dessa matriz?

- A) Linhas representam penalidades e colunas representam recompensas.
- B) Linhas representam estados do ambiente e colunas representam as ações possíveis.
- C) Linhas representam as ações e colunas representam os ambientes virtuais.
- D) Linhas representam episódios iterativos e colunas representam o decaimento de epsilon.

6. No cálculo matemático de atualização da tabela-Q, qual é o papel desempenhado pelo Fator de Desconto, representado pelo símbolo gamma?

- A) Ajustar a magnitude pela qual um valor da tabela é corrigido em direção ao seu alvo.
- B) Equilibrar a importância atribuída às recompensas imediatas em contraponto às recompensas futuras esperadas.
- C) Determinar o momento exato em que a transição de um episódio para o próximo deve ocorrer.
- D) Filtrar ruídos visuais quando o algoritmo é aplicado utilizando câmeras complexas de alta resolução.

7. A "Maldição da Dimensionalidade" descreve uma grande limitação do Q-Learning. Em que contexto esse problema inviabiliza o aprendizado?

- A) Quando a equação de Bellman não consegue dividir valores fracionários contínuos corretamente.
- B) Em ambientes de natureza física ou complexos onde o conjunto de estados é tão colossal ou contínuo que é computacionalmente impossível listá-los e armazená-los numa matriz.
- C) Quando recompensas atrasadas afetam dimensões ortogonais aos movimentos iniciais do robô.
- D) Sempre que o agente explora o mapa em taxas mais rápidas do que o processador consegue ler os arquivos do projeto.

8. O problema da Tabela-Q impulsionou o desenvolvimento de uma técnica híbrida moderna chamada de Deep Q-Network (DQN). Qual o princípio fundamental dessa adaptação?

- A) Extinguir a etapa temporal substituindo recompensas numéricas por validações linguísticas em texto estruturado.
- B) Agrupar todos os estados possíveis em exatas quatro categorias absolutas para garantir a viabilidade na memória RAM.

- C) Aprimorar os limites de hardware sem alterar a estrutura de tabelas estáticas subjacente.
- D) Substituir a busca tabular em uma matriz por uma rede neural artificial capaz de receber estados contínuos e aproximar logicamente os valores das ações.

9. O Q-Learning enquadra-se metodologicamente como um algoritmo model-free (livre de modelo). Conceitualmente, do ponto de vista do funcionamento do agente, o que essa propriedade garante?

- A) Que o treinamento utiliza bibliotecas genéricas (sem modelo proprietário) na sua compilação em código em máquina.
- B) Que o algoritmo descobre e otimiza sua tomada de decisão pela pura experiência iterativa, sem ter carregado/aprendido de antemão as regras operacionais ou as probabilidades subjacentes de dinâmica do ambiente.
- C) Que a arquitetura dispensa o uso de uma métrica rígida como a Equação de Bellman para realizar atualizações parciais de estado.
- D) Que o ambiente adapta automaticamente as leis do seu modelo físico a fim de favorecer a exploração positiva por parte do robô.

10. A estrutura de atualização central do aprendizado utiliza um componente basilar conhecido como Erro de Diferença Temporal (TD error). Ao destrinchar matematicamente esse componente, descobre-se que ele representa:

- A) O somatório puro das penalidades contínuas que um robô físico absorve a cada degrau no trajeto.
- B) O cálculo exato derivado entre a exploração passiva no início e a exploração hiper-rápida do agente nas rodadas derradeiras.
- C) A divergência entre o "alvo" atualizado (recompensa obtida acrescida da melhor expectativa do futuro) e a estimativa ou crença anterior de valor que o agente detinha na tabela.
- D) O fator estabilizador paramétrico gerado automaticamente quando episódios ultrapassam o tempo limite padrão em 20%.

11. Na literatura técnica de inteligência artificial, o algoritmo Q-Learning é rotulado estritamente como off-policy (fora da política). Qual característica matemática da sua equação justifica categoricamente esta classificação?

- A) O agente atualiza as tabelas assumindo tacitamente que tomará sempre a ação ótima no estado seguinte (max Q), independentemente da política efetiva (exploratória) o poder desviar no próximo passo empírico real.
- B) O algoritmo descarta a política da rede no meio do processamento se o erro de diferença escalar for negativo de forma reiterada.
- C) O fator gamma força o sistema a sempre transacionar para recompensas baseadas na política atual do adversário.
- D) A política de recompensa é determinada por um observador estatístico externo off-grid que supervisiona ativamente cada decisão tomada nos nós neutros.

12. Examine dois problemas aplicados na indústria e no mercado: a formulação tática de day trading (ações financeiras onde operações de curtíssimo prazo afetam diretamente métricas de retorno em questão de segundos) versus o roteamento de planejamento naval contínuo (onde a ação presente pode apenas reverter resultados práticos semanas no futuro). Levando-se a teoria aos limites práticos, as configurações de gamma (Fator de Desconto) nestes dois modelos deveriam ser calibradas, de modo análogo, como:

- A) Day Trading: gamma tendendo a 1.0; Navio Naval: gamma tendendo a 0.0.
- B) Ambos os modelos requerem estritamente um gamma = 0.5 para contrabalançar as instabilidades temporais orgânicas inerentes aos sistemas model-free em simulações do mundo real.
- C) Ambos requerem gamma tendendo rigorosamente a 1.0, dado que o foco é inegociável na recompensa de longo período.
- D) Day Trading: gamma tendendo a 0.0; Navio Naval: gamma tendendo a 1.0.

13. Considere um processamento lógico da equação de Bellman em um grid com $\alpha=0.5$ e $\gamma=0.9$. O agente estava num estado "Neutro", tomou a ação de se mover e realizou a transição matemática para o Estado "Meta" (terminal, Q para todas as ações igual a zero). Ele recebeu instantaneamente uma recompensa $r = 1.0$. Assumindo categoricamente que a antiga estimativa para tomar essa ação no estado Neutro estava zerada inicialmente, calcule iterativamente o novo valor de Qualidade para esse par após o processamento deste pequeno episódio.

- A) 0.50
- B) 0.90
- C) 1.50
- D) 0.00

14. Considere um ambiente de grid 2x2 com os estados Início (I), Neutro (N), Bomba (B) e Meta (M). As ações são cima, baixo, esquerda, direita. Bater na borda mantém o agente no mesmo estado. Alcançar a Meta dá recompensa +1 e termina o episódio; cair na Bomba dá -1 e termina; demais transições dão 0. Utiliza-se Q-learning com fator de desconto $\gamma = 0,9$ e taxa de aprendizado $\alpha = 0,5$.

Após alguns episódios, a tabela-Q parcial é:

Estado	Cima	Direita	Baixo	Esquerda
I	0,0	0,45	-0,5	0,0
N	0,0	0,0	0,875	0,0

Estando em I, o agente, por exploração, escolhe a ação cima. Ela o mantém em I (borda), recompensa 0, próximo estado I. Qual será o novo valor de $Q(I, \text{cima})$ após a atualização e o que isso evidencia sobre o Q-learning?

- A) 0,2025; evidencia que, mesmo sob exploração, o algoritmo usa o valor da melhor ação do estado seguinte, caracterizando o aprendizado off-policy.
- B) 0,0; evidencia que ações exploratórias não alteram a tabela-Q, pois não são previstas na política ótima.
- C) 0,45; evidencia que o valor da ação cima é simplesmente copiado do maior Q de I, ignorando o desconto.
- D) 0,9; evidencia que o algoritmo atribui diretamente γ ao valor máximo, sem depender do estado atual.

15. Após a convergência total no mesmo ambiente da questão anterior, a tabela-Q ótima (com $\gamma = 0,9$) é:

Estado	Cima	Direita	Baixo	Esquerda
I	0,81	0,9	-1,0	0,81
N	0,0	0,0	1,0	0,0

A ação esquerda, a partir de I, faz o agente permanecer em I (borda). Por que $Q(I, \text{esquerda}) = 0,81$ e não zero?

- A) Porque, durante o treinamento, o agente ocasionalmente recebeu recompensa acidental ao mover-se para a esquerda.
- B) Porque a equação de Bellman propaga o valor da melhor ação disponível no estado resultante: ao bater na borda, o agente continua em I, onde a melhor ação (direita) vale 0,9; assim, $Q(I, \text{esquerda}) = 0 + \gamma \times 0,9 = 0,81$.
- C) Porque o algoritmo confunde esquerda com direita devido à simetria do grid, gerando o mesmo valor.
- D) Porque a exploração faz com que a ação esquerda seja atualizada com um alvo aleatório, fixando-se em 0,81.

16. Com a estratégia epsilon-greedy, o agente escolhe uma ação aleatória com probabilidade epsilon (exploração) e a melhor ação conhecida com probabilidade $1 - \text{epsilon}$ (exploração). Sobre o papel da exploração no Q-learning, analise as afirmações a seguir e assinale a correta:

- A) Se o valor de (epsilon) for mantido constante e muito baixo (e.g., 0,01) desde o início do treinamento, o agente converge mais rapidamente para a política ótima, pois explora o conhecimento desde cedo, evitando perder tempo com ações aleatórias.

B) Um decaimento muito rápido de epsilon (por exemplo, de 1,0 para 0,01 nos primeiros episódios) pode fazer com que o agente nunca descubra a política ótima, ficando preso a uma política subótima gerada por estimativas iniciais ruins da tabela-Q.

C) A exploração serve exclusivamente para evitar que o agente repita ações que já sabe serem ruins; ela não é necessária para descobrir novas recompensas em estados já visitados com frequência.

D) Durante a fase de treinamento com $\epsilon = 0,5$ (50% de exploração), o agente não consegue aprender nada útil, pois a alta taxa de aleatoriedade destrói qualquer progresso feito pelas atualizações da tabela-Q.

Exercício prático

1. Implementação de Q-learning no Frozen Lake

Objetivo: Neste exercício, você implementará o algoritmo Q-learning para resolver o ambiente FrozenLake-v1 do Gymnasium (versão determinística). Deverá treinar um agente, extrair a política ótima e visualizar tanto o aprendizado quanto as ações aprendidas em cada estado.

Descrição do Ambiente

O Frozen Lake é uma grade 4×4 onde:

- O agente começa no canto superior esquerdo (estado 'S').
- Deve alcançar o canto inferior direito (estado 'G', meta) sem cair nos buracos ('H').
- Estados totais: 16 (0 a 15).
- Ações discretas: 0 = Esquerda, 1 = Baixo, 2 = Direita, 3 = Cima.
- O ambiente é determinístico ('is_slippery=False'): a ação escolhida leva exatamente à célula adjacente (se possível; se bater na borda, o agente permanece no mesmo lugar).
- Recompensa: +1 ao atingir a meta; 0 nos demais casos (incluindo cair no buraco ou passos normais).

Tarefas

1. Configuração do ambiente

- Importe 'gymnasium' (ou 'gym', se preferir) e crie o ambiente 'FrozenLake-v1' com 'is_slippery=False'.
- Obtenha o número de estados ('observation_space.n') e de ações ('action_space.n').

2. Inicialização dos parâmetros e da Q-table

- Defina os hiperparâmetros:
 - Taxa de aprendizado ' $\alpha = 0.1$ '
 - Fator de desconto ' $\gamma = 0.99$ '
 - Probabilidade inicial de exploração ' $\epsilon = 1.0$ '
 - Menor valor de ' ϵ ' (' $\epsilon_{\min} = 0.0001$ ')
 - Fator de decaimento ' $\epsilon_{\text{decay}} = 0.999$ '
 - Número de episódios de treino ' $\text{episódios} = 20000$ '

- Crie a tabela `Q` com dimensões `(n\_estados, n\_ações)` inicializada com zeros.

3. Loop de treinamento com Q-learning

Para cada episódio:

- Reinicie o ambiente (`env.reset()`) e inicialize a recompensa total como 0.
- Enquanto o episódio não terminar:
 - Escolha uma ação usando a política ϵ -greedy:
 - Com probabilidade `epsilon`, escolha uma ação aleatória (exploração).
 - Caso contrário, escolha a ação que maximiza `Q[estado, :]` (exploitation).
 - Execute a ação no ambiente (`env.step()`) e obtenha `prox\_estado`, `recompensa`, `terminou`, `truncado` e `info`.
 - Atualize a Q-table com a regra do Q-learning
 - Atualize o estado atual (`estado = prox\_estado`) e acumule a recompensa.
- Ao final do episódio, decaia `epsilon` multiplicando-o por `epsilon\_decay`, desde que permaneça acima de `epsilon\_min`.
- Armazene a recompensa total do episódio numa lista `recompensas` para análise posterior.

4. Extração da política aprendida: Após o treino, extraia a política ótima (ação de maior valor Q por estado) e a imprima formatada como uma matriz 4×4, mapeando os números das ações para as setas: `0=←`, `1=↓`, `2=→`, `3=↑`.

5. Visualização

Produza uma figura com dois subgráficos:

- Esquerda: Grade 4×4 com a política desenhada.
 - Marque o início (`S`), a meta (`G`) e os buracos (`H`) com cores distintas (ex.: verde, amarelo, vermelho).
 - Em cada estado não terminal, desenhe uma seta indicando a ação aprendida.
 - Use as coordenadas `(dx, dy)` para cada ação: `← = (-0.4, 0)`, `↓ = (0, 0.4)`, `→ = (0.4, 0)`, `↑ = (0, -0.4)`.
- Direita: Gráfico da recompensa total por episódio, com linha pontilhada indicando a recompensa máxima (1.0). Inclua título, eixos rotulados e legenda.

6. Perguntas para reflexão

- Por que a curva de recompensa oscila mesmo após muitos episódios?
- Qual o efeito de usar um `epsilon\_min` extremamente baixo (e.g., 0) em vez de 0.0001?
- Se `is\_slippery=True` fosse usado, como o aprendizado seria afetado? Justifique.
- Como você avaliaria a influência da taxa de aprendizado `alpha` no processo? Proponha um experimento simples.