

Lista de exercícios 15 de C24 - Inteligência Artificial

k-NN

Exercícios teóricos

1. Qual das alternativas a seguir descreve corretamente uma característica fundamental de funcionamento do algoritmo k-vizinhos mais próximos (k-NN)?

- A) Ele constrói um modelo polinomial matemático durante a fase de treinamento para conseguir realizar previsões rápidas e com pouca memória.
- B) Ele assume que os dados seguem uma distribuição Gaussiana ou de Bernoulli para otimizar o cálculo de probabilidade das distâncias.
- C) Ele é considerado um algoritmo "preguiçoso" (lazy learning), pois adia todo o aprendizado até o momento exato em que uma previsão é solicitada, não havendo um modelo treinado explicitamente.
- D) Ele descarta os dados de treinamento de sua memória logo após a construção do hiperplano de separação ótimo entre as classes de dados.

2. O algoritmo k-NN pode ser aplicado tanto em problemas de classificação quanto em problemas de regressão. Como a saída do algoritmo é determinada para cada um desses cenários, respectivamente, assumindo que se trata de uma implementação padrão sem uso de pesos diferenciados?

- A) Pelo voto majoritário das classes dos vizinhos e pelo cálculo da média aritmética dos valores associados aos k vizinhos.
- B) Pela seleção aleatória entre os k vizinhos mais próximos e pela mediana dos valores de todos os dados de treinamento.
- C) Pela média aritmética das classes transformadas em probabilidade e pelo voto majoritário dos valores contínuos presentes na vizinhança.
- D) Pela classe associada exclusivamente ao primeiro vizinho mais próximo ($k=1$); e pela soma dos resíduos da regressão logística linear.

3. Ao implementar o k-NN em um conjunto de dados do mundo real com milhões de instâncias e dezenas de atributos, o algoritmo pode sofrer com gargalos de desempenho. Qual é uma das principais desvantagens computacionais do k-NN neste cenário?

- A) O tempo de treinamento inicial da base torna-se excessivamente longo e computacionalmente custoso.
- B) A fase de inferência (predição) pode ser muito demorada, pois é necessário calcular a distância geométrica entre o novo dado de entrada e todas as instâncias do conjunto de treinamento armazenadas em memória.
- C) A necessidade de aplicar funções de ativação complexas em múltiplas camadas profundas para cada cálculo de distância.

D) O modelo frequentemente superestima a classe minoritária, exigindo grande custo computacional na geração de dados sintéticos.

4. O cálculo de vizinhança requer o uso de uma métrica de distância. A "Distância de Minkowski" é uma fórmula generalizada cuja ordem pode ser alterada variando-se o hiperparâmetro 'p'. Considerando $p=1$ e $p=2$, quais são os nomes destas distâncias e suas aplicações típicas?

A) $p=1$: Distância de Mahalanobis (usada com dados não padronizados); $p=2$: Distância Euclidiana (usada para séries temporais).

B) $p=1$: Distância Euclidiana (mede relações não-lineares oblíquas); $p=2$: Distância de Manhattan (mede apenas em grade urbana).

C) $p=1$: Distância de Chebyshev (foca na dimensão de maior variância); $p=2$: Distância Euclidiana (mede a menor distância euclidiana).

D) $p=1$: Distância de Manhattan (adequada quando não há relação linear clara e os movimentos que ocorrem em eixos perpendiculares); $p=2$: Distância Euclidiana (adequada para relações lineares, medindo a menor distância direta como uma reta).

5. Por que é considerado um passo obrigatório (ou fortemente recomendado) realizar o pré-processamento de escalonamento dos dados (como padronização ou normalização) antes de usar o classificador k-NN?

A) Para transformar dados categóricos qualitativos em variáveis contínuas numéricas interpretáveis pela máquina.

B) Porque o k-NN é extremamente sensível a atributos com escalas diferentes, fazendo com que variáveis com grandezas maiores dominem desproporcionalmente os cálculos da métrica de distância.

C) Para forçar que a escolha do número de vizinhos (k) seja sempre ímpar, evitando empates e anomalias na votação majoritária final.

D) Para transformar a distribuição empírica dos dados em uma distribuição perfeitamente normal e viabilizar o cálculo da variância.

6. É de conhecimento geral entre cientistas de dados que o desempenho e a precisão do k-NN caem vertiginosamente ao lidarmos com alta dimensionalidade (dezenas ou centenas de atributos independentes). Qual das afirmações abaixo explica corretamente o fenômeno geométrico por trás dessa limitação?

A) O número de divisões necessárias para otimizar os hiperparâmetros por meio de k-fold cross-validation aumenta numa taxa exponencial, causando travamento do hardware.

B) O algoritmo de aprendizagem competitiva não consegue mais distinguir problemas de classificação de problemas de regressão.

C) Em espaços com uma quantidade muito grande de dimensões, os pontos de dados tornam-se incrivelmente esparsos e as distâncias entre eles tornam-se quase uniformes (equidistantes), destruindo o princípio base de "vizinhança significativa".

D) As regras da norma vetorial utilizadas pela equação de Minkowski perdem validade estatística ao ultrapassar um limiar de três dimensões espaciais e uma temporal.

7. Problemas do mundo real lidam com classes desbalanceadas. Se, numa base médica, 98% dos pacientes são saudáveis (maioria) e 2% têm uma anomalia (minoría), a escolha padrão de k-NN por voto majoritário pode ser fatalmente enviesada para a classe majoritária. Qual adaptação no k-NN pode solucionar matematicamente esse viés durante a inferência?

A) Substituir permanentemente o cálculo da distância Euclidiana pela métrica de Manhattan com p infinito.

B) Aplicar a validação cruzada do tipo Grid Search restrita a pequenos agrupamentos isolados da classe minoritária.

C) Atribuir pesos individuais durante a votação (ou média), de modo que o peso de um vizinho no resultado final seja inversamente proporcional à sua distância da nova entrada.

D) Aumentar artificialmente o número de dimensões do problema, copiando o vetor das amostras anômalas para as instâncias da classe majoritária.

8. Determinar o hiperparâmetro 'k' (número de vizinhos) é vital. Escolher um número não otimizado gera overfitting (sobreajuste) ou underfitting (subajuste). Do ponto de vista metodológico, como esse hiperparâmetro deve ser fixado de forma correta e robusta antes das previsões produtivas?

A) Ele deve ser resolvido usando algoritmos clássicos de retropropagação do erro na fase de treinamento, extraindo-se as derivadas parciais do modelo de pesos lineares.

B) Ele não pode ser adivinhado antecipadamente, devendo ser descoberto de forma empírica por meio de técnicas de validação cruzada exaustivas, como Grid Search ou Random Search k-fold, que medem a acurácia em subconjuntos do espaço.

C) A teoria formal da máquina de vetores indica que k deve ser sempre a raiz quadrada logarítmica do total de classes, minimizando a incerteza estatística.

D) Ao adotar o aprendizado do tipo "lazy", o desenvolvedor deve obrigatoriamente parametrizar k igual ao número de atributos do conjunto (K maiúsculo) para atingir homogeneidade.

9. Para que se calculem os "vizinhos", faz-se uso de distâncias ancoradas em uma Norma Vetorial (uma função $p(v)$ matemática que mapeia vetores nos reais positivos). Das propriedades listadas a seguir, qual é uma exigência rigorosa para que uma função atue como norma em um espaço k-NN?

A) A norma deve permitir valores de retorno negativos caso o espaço tridimensional avaliado entre em uma assíntota reversa nos eixos ordenados da função.

B) A função que representa a norma deve limitar o escalar máximo a 100%, operando como uma representação estrita de probabilidade bayesiana.

C) A função de norma deve atender à Desigualdade do Triângulo, ditando rigidamente que o tamanho (norma) da soma de dois vetores seja sempre menor ou igual à soma de seus tamanhos individuais.

D) A norma exige que a distância entre dois instantes independentes v e u tenda à convergência infinita à medida que os eixos x crescem no hiperplano de separação linear.

10. Do ponto de vista estrito do aprendizado competitivo, como o modelo de regressão avalia e equaciona os dados da dimensão (K maiúsculo) para predizer uma amostra utilizando o hiperparâmetro de contagem vizinha (k minúsculo)?

A) Na regressão ponderada, a predição atua com base nos K atributos da amostra de entrada para encontrar k vizinhos cujos vetores de distância sejam rigorosamente os mais curtos, para, em seguida, dividir a soma ponderada de seus rótulos reais pela soma total dos pesos.

B) Os elementos competem para igualar as letras ' k ' minúscula e ' K ' maiúscula; na regressão ótima, o número de vizinhos consultados deve ser estatisticamente o mesmo volume absoluto do número de atributos presentes no vetor avaliado.

C) No modo preditivo de retroaprendizado competitivo, o k -NN descarta completamente a análise de vizinhos de classe em k , voltando o algoritmo iterativo a uma soma estrita baseada na dimensão escalar superior a k .

D) O modelo foca primeiramente na dimensão superior K para determinar o valor da classe e , consequentemente, rebaixa as features pela média aritmética do hiperparâmetro k , realizando a supressão natural da base.

Exercício prático

Projeto e otimização de um classificador k -NN

Uma empresa desenvolveu um sistema de monitoramento para equipamentos industriais.

Cada equipamento é caracterizado por:

- Temperatura ($^{\circ}\text{C}$)
- Vibração (mm/s)
- Corrente elétrica (A)
- Potência consumida (kW)
- Tempo de operação (h)

O objetivo é classificar o equipamento como:

- Classe 0 $\rightarrow$ Operação Normal
- Classe 1 $\rightarrow$ Possível Falha

Você deverá projetar um classificador k -NN e analisar seu desempenho.

1. Geração da Base de Dados

```
import numpy as np
from sklearn.model_selection import train_test_split

np.random.seed(42)
```

```

# Equipamentos normais
normal = np.random.multivariate_normal(
    mean=[60, 3, 10, 5, 200],
    cov=np.diag([25, 0.5, 1, 0.5, 1000]),
    size=1000
)

# Equipamentos com falha
falha = np.random.multivariate_normal(
    mean=[85, 8, 16, 8, 350],
    cov=np.diag([30, 1, 2, 1, 1500]),
    size=1000
)

X = np.vstack((normal, falha))

y = np.hstack((
    np.zeros(1000),
    np.ones(1000)
))

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.3,
    random_state=42
)

```

2. Implementação básica

Treine um k-NN utilizando $k = 5$ e calcule:

- Accuracy
- Precision
- Recall
- F1-score

Construa a matriz de confusão e explique:

- O que representam FP e FN?
- Em um sistema industrial, qual erro é mais grave?

3. Influência do valor de k

- Use os seguintes valores $k = [1, 3, 5, 7, 11, 15, 21, 31]$. Para cada valor:
 - calcule a acurácia;
 - plote um gráfico.
- Explique:
 - Por que valores pequenos de k podem causar overfitting?
 - Por que valores grandes podem causar underfitting?

4. Impacto da normalização

- Padronize os dados usando a classe StandardScaler e treine novamente o modelo.
- Compare:
 - Acurácia sem normalização.
 - Acurácia com normalização.
- Explique matematicamente por que o k-NN é sensível à escala dos atributos.

5. Comparação de Métricas.

Use as distâncias: Euclidean, Manhattan, Minkowski e monte uma tabela:

Métrica	Acurácia
Euclidean	
Manhattan	
Minkowski	

Discuta as diferenças observadas.

6. KD-Tree vs Ball Tree

- Treine três modelos: brute, kd_tree e ball_tree
- Meça o tempo de treinamento e o tempo de inferência.
- Construa uma tabela:

Método	Tempo treino	Tempo inferência
Brute force		
KD-Tree		
Ball-Tree		

Explique por que o treinamento e a inferência possuem comportamentos diferentes.

7. Seleção Automática de k

Utilize: GridSearchCV e procure “n_neighbors” com validação cruzada usando cv=5. Determine:

- Melhor valor de k;
- Melhor acurácia média.

8. Desafio

Aumente artificialmente a dimensionalidade:

```
ruido = np.random.randn(  
X.shape[0],  
95  
)  
  
X_hd = np.hstack((X, ruido))
```

Agora o conjunto terá: 100 atributos

Repita os experimentos.

Analise:

- Acurácia antes e depois.
- Tempo de inferência antes e depois.
- Desempenho do KD-Tree.
- Desempenho do Ball Tree.

Relacione os resultados com o conceito de: Maldição da Dimensionalidade