


C24 – Inteligência Artificial: *Métricas de classificação*



O que vamos ver?

- Anteriormente, para analisar o desempenho de um classificador, usamos apenas a acurácia.
- Porém, existem outras métricas que podem ser usadas para se medir a qualidade de um classificador.
- Portanto, neste tópico, veremos algumas outras métricas.

Matriz de confusão

	dog	cat	lizard
dog			
cat			
lizard			

- Como o próprio nome diz, a **matriz de confusão** mostra o **quanto** um classificador está se **confundindo**.
- A matriz permite verificar quais classes o **classificador** tem **maior dificuldade em classificar**.

Matriz de confusão

$$\mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \dots & C_{1Q} \\ C_{21} & C_{22} & \dots & C_{2Q} \\ \vdots & \vdots & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \dots & C_{QQ} \end{bmatrix}$$

- A matriz de confusão **contabiliza o número de classificações corretas e incorretas** para cada uma das Q classes existentes.
- É uma **matriz quadrada** com dimensões $\mathbb{R}^{Q \times Q}$.

Matriz de confusão

Predições: classes a que os exemplos foram atribuídos

$$\begin{bmatrix} C_{11} & C_{12} & \dots & C_{1Q} \\ C_{21} & C_{22} & & C_{2Q} \\ & \vdots & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \dots & C_{QQ} \end{bmatrix}$$

Rótulos: classes a que realmente os exemplos pertencem

Matriz de confusão

$$\mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \cdots & C_{1Q} \\ C_{21} & C_{22} & \cdots & C_{2Q} \\ \vdots & \vdots & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \cdots & C_{QQ} \end{bmatrix}$$

- A **diagonal principal** fornece o número de **classificações corretas**.
- A q -ésima **linha** indica o **total de exemplos que foram classificados como pertencentes à q -ésima classe**, incluindo exemplos que pertencem e não pertencem à classe.
- A q -ésima **coluna** indica o **total de exemplos que realmente pertencem à q -ésima classe**, incluindo classificações corretas e incorretas.

Matriz de confusão

$$\mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \dots & C_{1Q} \\ C_{21} & C_{22} & \dots & C_{2Q} \\ \vdots & & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \dots & C_{QQ} \end{bmatrix}$$

Exemplos classificados como pertencentes à classe 1.

Quantidade de exemplos que realmente pertencem à classe 1.

- C_{11} indica quantos exemplos da classe 1 foram corretamente atribuídos à classe 1.
- C_{12} indica quantos exemplos da classe 2 foram atribuídos à classe 1.
- **OBS.:** Algumas versões da matriz apresentam porcentagens ao invés de contagens.

Matriz de confusão para caso binário ($Q = 2$)

Classes Preditas

- (C_1)	Verdadeiros Negativos (TN)	Falsos Negativos (FN)
+ (C_2)	Falsos Positivos (FP)	Verdadeiros Positivos (TP)
	- (C_1)	+ (C_2)

Classes Verdadeiras

- **Matriz com dimensão:** 2×2 .
- **Verdadeiros Positivos (TP):** número de exemplos da classe positiva, C_2 , classificados corretamente.
- **Verdadeiros Negativos (TN):** número de exemplos da classe negativa, C_1 , classificados corretamente.
- **Falsos Positivos (FP):** número de exemplos atribuídos à classe positiva, mas que pertencem à classe negativa.
- **Falsos Negativos (FN):** número de exemplos atribuídos à classe negativa, mas que pertencem à classe positiva.

Matriz de confusão para caso binário ($Q = 2$)

verdadeiro positivo



falso positivo



falso negativo



verdadeiro negativo

Nós podemos calcular algumas métricas de desempenho importantes a partir das informações contidas na **matriz de confusão binária**.

Acurácia

$$\text{acurácia} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FN} + \text{FP} + \text{TN}}$$

- Acurácia mede a **proporção de exemplos classificados corretamente em relação ao total de exemplos** avaliados.
- Em outras palavras, a acurácia fornece uma indicação de quão bem o modelo está fazendo suas **predições corretas em comparação com todas as previsões feitas**.
- É uma métrica útil para avaliar o **desempenho geral do modelo**.

Acurácia

$$\text{acurácia} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FN} + \text{FP} + \text{TN}}$$

- A **acurácia** é, geralmente, a **primeira escolha** para medir a qualidade de um classificador.
- Entretanto, ela pode ser **enganosa com problemas desbalanceados**.
 - Problemas onde uma ou algumas classes têm muito mais exemplos do que as demais.
- Nesses casos, ela pode nos levar a **concluir** que um **classificador ruim é muito bom**.

Acurácia

- Analisando a equação da acurácia, o que aconteceria se TP fosse muito maior do que TN, FN e FP?

$$\lim_{TP \rightarrow \infty} \text{acurácia} = \lim_{TP \rightarrow \infty} \left(\frac{TP + TN}{TP + TN + FN + FP} \right) \rightarrow \frac{TP}{TP} = 1.$$

- A acurácia pode tender à 1 mesmo que o modelo tenha um desempenho ruim na identificação da classe negativa.
- O mesmo aconteceria se TN fosse muito maior do que TP, FN e FP
- Ela também é enganosa quando os custos de falsos positivos e falsos negativos não são iguais.
 - Por exemplo, para um modelo de classificação de doenças contagiosas, o custo de um FN (tem a doença, mas o modelo diz que não) é mais alto do que o de um FP.

Portanto, quando temos **classes desbalanceadas ou custos diferentes,**
devemos analisar outras métricas

Precisão

$$\text{precisão} = \frac{\text{TP}}{\text{FP} + \text{TP}}$$

-	TN	FN
+	FP	TP
	-	+

- **Precisão** é a proporção de exemplos da classe positiva corretamente classificados (TP) em relação a todos os exemplos atribuídos à classe positiva (TP + FP).
- Ou seja, de tudo aquilo que o modelo classificou como positivo, quanto realmente é positivo?
 - Quando ele prediz positivo, podemos confiar?
- É uma **boa medida** para determinar a qualidade do classificador **quando os custos de falsos positivos são altos**.

Precisão

$$\text{precisão} = \frac{\text{TP}}{\text{FP} + \text{TP}}$$

ham	TN	FN
spam	FP	TP
	ham	spam

- Por exemplo, na classificação de *spams* onde o **verdadeiro positivo** é um email de *spam*:
 - Um **falso positivo** significa que um **email legítimo** (*ham*) (**verdadeiro negativo**) foi classificado como *spam*.
 - Nesse caso, o cliente do serviço de email pode perder correspondências importantes se a **precisão** for baixa.

Recall

$$recall = \frac{TP}{FN + TP}$$

TN	FN
FP	TP

- **Recall** ou **sensibilidade** é a proporção de exemplos da classe positiva corretamente classificados.
- Dos exemplos que realmente são positivos, quantos o modelo conseguiu acertar?
 - O modelo conseguiu encontrar todos os positivos?
- É uma **boa medida** para determinar a qualidade de um classificador **quando os custos de falsos negativos são altos**.

Recall

$$recall = \frac{TP}{FN + TP}$$

saudável	TN	FN
doente	FP	TP
	saudável	doente

- Por exemplo, na classificação de **doenças**:
 - Se um paciente doente (**verdadeiro positivo**) for classificado como não doente (**falso negativo**).
 - O custo associado ao **falso negativo** será extremamente alto se a doença for contagiosa.

Mas e se falsos positivos e falsos negativos tiverem custos iguais, que métrica usar?

Precisão versus *recall*

$$\text{precisão} = \frac{TP}{FP + TP}$$

$$\text{recall} = \frac{TP}{FN + TP}$$

- A **precisão** não fornece informações a respeito da quantidade de **falsos negativos**.
- Por outro lado, o **recall** não fornece informações a respeito da quantidade de **falsos positivos**.
- Mas e se os **custos associados a falsos positivos e negativos são iguais**?
 - Por exemplo, identificação de cães e gatos onde ambas as classificações corretas são importantes.
- Nesse caso, para analisarmos o desempenho de um classificador, precisamos de **uma métrica que combine as duas**.

F1-score

- O F1-score combina as duas métricas em uma única.
- A métrica dá a **mesma importância** à **precisão** e ao **recall**.
- Valores de F_1 próximos de 1 indicam que o **classificador** obteve ótimos resultados tanto de **precisão** quanto de **recall**.
- Em outras palavras, $F_1 \approx 1$ significa que FN e FP ≈ 0 .





$$F_1 = \frac{TP}{TP + \frac{FN + FP}{2}} = 2 \frac{\text{precisão} \times \text{recall}}{\text{precisão} + \text{recall}}.$$

OK, consigo calcular as métricas para problemas binários, mas e quando $Q > 2$?

Matriz de confusão para caso multiclass

- É possível calcular todas as métricas anteriores para o cenário multiclass (i.e., $Q > 2$).
- Para isso, basta selecionar **uma classe por vez** como sendo a **classe positiva**, enquanto todas **as demais classes formam a classe negativa**.
 - Essa abordagem se chama **um-contra-o-resto**.
 - É uma maneira de transformar um problema de Q classes em Q problemas binários.
 - Assim, **passamos a ter Q matrizes de confusão binárias, uma para cada classe sendo a classe positiva**.
- Desta forma, obtém-se os valores das **métricas para cada uma das Q classes**.
- Vejamos um exemplo para $Q = 3$, ou seja, C_1 , C_2 e C_3 .

Um-Contra-o-Resto



- Os rótulos originais são: 1, 2, 3.
- Para cada problema binário, mudamos os rótulos de **uma classe** para 2 (+) e **das demais** para 1 (-).

Com $Q = 3$, passamos a ter **3 problemas binários**.

Matriz de confusão para $Q = 3$

A classe C_1 é a positiva.

Classes Preditas	$+(C_1)$	Verdadeiro Positivo (TP)	Falso Positivo (FP)	Falso Positivo (FP)
	$-(C_2)$	Falso Negativo (FN)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)
	$-(C_3)$	Falso Negativo (FN)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)
		$+(C_1)$	$-(C_2)$	$-(C_3)$
		Classes Verdadeiras		

- Para $Q = 3$, teremos 3 matrizes de confusão binárias.
- A primeira matriz considera a classe C_1 como a classe positiva e as demais classes, C_2 e C_3 , como a classe negativa.
- Agora, de posse de TP, TN, FP, e FN, nós **conseguimos calcular as métricas anteriores para C_1 sendo a classe positiva.**
 - Devemos somar todos os elementos com a mesma identificação.

Matriz de confusão para $Q = 3$

Classe C_2 é a positiva.

Classes Preditas	- (C_1)	Verdadeiro Negativo (TN)	Falso Negativo (FN)	Verdadeiro Negativo (TN)
	+ (C_2)	Falso Positivo (FP)	Verdadeiro Positivo (TP)	Falso Positivo (FP)
	- (C_3)	Verdadeiro Negativo (TN)	Falso Negativo (FN)	Verdadeiro Negativo (TN)
		- (C_1)	+ (C_2)	- (C_3)
		Classes Verdadeiras		

- A segunda matriz considera a classe C_2 como a classe positiva e as demais classes, C_1 e C_3 , como a classe negativa.
- Agora, de posse de TP, TN, FP, e FN, nós conseguimos calcular as métricas anteriores para C_2 sendo a classe positiva.

Matriz de confusão para $Q = 3$

Classe C_3 é a positiva.

Classes Preditas	- (C_1)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)	Falso Negativo (FN)
	- (C_2)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)	Falso Negativo (FN)
	+ (C_3)	Falso Positivo (FP)	Falso Positivo (FP)	Verdadeiro Positivo (TP)
	Classes Verdadeiras			
		- (C_1)	- (C_2)	+ (C_3)

- A terceira matriz considera a classe C_3 como a classe positiva e as demais classes, C_1 e C_2 , como a classe negativa.
- Agora, de posse de TP, TN, FP, e FN, nós conseguimos calcular as métricas anteriores para C_2 sendo a classe positiva.
- Percebam que, ao final, teremos um **conjunto de métricas (precisão, recall, F1-score) por classe**.

Acurácia para o caso multiclases

$Q = 3$

0	Acerto	Erro	Erro
1	Erro	Acerto	Erro
2	Erro	Erro	Acerto
	0	1	2

- Para o caso multiclases, a acurácia é calculada como razão entre a soma de todos os acertos e o total de exemplos avaliados (i.e., a soma erros e acertos).

$$\text{acurácia} = \frac{\text{Soma dos elementos da diagonal principal}}{\text{Soma de todos os elementos (erros + acertos)}}$$



Não precisamos calcular nenhuma dessas métricas manualmente.

Existem funções prontas para isso.

Exemplo

- Exemplo: Métricas de classificação



Lista de exercícios

[Lista #8 – Métricas de classificação](#)

Perguntas?

Obrigado!