



C24 – Inteligência Artificial: *Q-learning*







- As máquinas podem aprender a tomar decisões ótimas sozinhas sem supervisão (*dataset*), apenas por tentativa e erro.
- Esse é o coração do *reinforcement learning* (RL).
- Nessa aula, aprenderemos o funcionamento do algoritmo mais clássicos da área: o Q-learning.

O que é *reinforcement learning*?

- É um dos paradigmas de aprendizado de *machine learning* focado em como tomar *ações* para maximizar uma *recompensa* futura.




Diferenças chave entre os paradigmas




- Ao contrário dos aprendizados supervisionado e não supervisionado, não temos um *dataset*, seja ele rotulado ou não.
- Não há um *dataset*: o agente **gera seus próprios dados** enquanto tenta, erra e aprende.
 - Nesse contexto, o agente é o algoritmo de aprendizado por reforço.
- O aprendizado ocorre por experiência através de interações com um ambiente.

Diferenças chave entre os paradigmas




- O algoritmo aprende na prática, sendo premiado ou penalizado pelo ambiente por ações tomadas até descobrir a melhor estratégia, chamada de política nesse contexto.
- Existe um sinal de **recompensa ou reforço enviado pelo ambiente**.
 - O ambiente diz ao agente: "Isso foi bom (+10)" ou "Isso foi péssimo (-5)".
- É um guia, mas ele não diz *qual* era a ação certa, apenas se a que foi tomada foi boa ou ruim.

Diferenças chave entre os paradigmas



- O aprendizado por reforço foca na tomada de decisão para maximizar recompensas ao longo do tempo.
- Ele responde à pergunta: *"Qual sequência de ações eu devo tomar para ganhar o prêmio lá na frente?"*

Analogia




- Aprendizado por reforço é como adestrar um cachorro.
- Você não diz a ele *como* se sentar ou pegar o graveto.
 - Não há dados rotulados ensinando os movimentos musculares.
- Você dá um petisco (recompensa) quando ele senta ou pega o graveto, e ele aprende a associar a ação ao resultado positivo.

Conceitos fundamentais de RL

- **Agente:** O tomador de decisões.
 - Exemplo: um robô, um carro autônomo.
- **Ambiente:** O mundo com o qual o agente interage.
 - Exemplo: um galpão, uma cidade, um tabuleiro de jogo.
- **Estado (s):** A situação atual do agente no ambiente.
 - Exemplo: A posição do agente e dos objetos/obstáculos no galpão, cidade ou jogo.
- **Ação (a):** O que o agente pode fazer.
 - Exemplo: movimentos (esquerda, direita, para cima/baixo), acelerar, frear.
- **Recompensa (r):** O *feedback* (positivo ou negativo) recebido após uma ação.


Conceitos fundamentais de RL



- O agente e o ambiente interagem em etapas de tempo discreto: $t, t + 1, t + 2, \dots, T$.
- A cada instante t , o agente
 - observa o estado $s_t \in S$ (conjunto de estados possíveis).
 - com base em s_t , ele seleciona uma ação $a_t \in A$ (conjunto de ações disponíveis).
 - um instante depois, como consequência de sua ação, o agente recebe uma recompensa, $r_{t+1} \in R$ (conjunto de todas as possíveis recompensas).
 - e se encontra em um novo estado, s_{t+1} .

Conceitos fundamentais de RL

- O objetivo do agente é maximizar a soma total de recompensas ao longo do tempo, não apenas a recompensa imediata.



Algoritmos de RL

- Alguns dos algoritmos de RL mais conhecidos e importantes são:
 - **Q-Learning**
 - Um dos algoritmos mais clássicos.
 - Espaços de ações e estados discretos
 - Base de muitos métodos modernos.
 - **Deep Q-Network (DQN)**
 - Combina Q-learning com redes neurais profundas.
 - Espaço de ações discreto e espaço de estados contínuo.
 - **DDPG (Deep Deterministic Policy Gradient)**
 - Extensão do DQN para espaços de ações e estados contínuos.
- Devido a sua simplicidade e por introduzir de forma clara os conceitos fundamentais de aprendizado por reforço, focaremos no ***Q-learning***, proposto por Christopher Watkins em 1989.

O que é Q-learning?

- Q-learning é um algoritmo **model-free**.
- Ele não conhece as regras do ambiente.
- Em RL, o "**modelo**" é o conhecimento das regras do ambiente.
- Ele aprende pela experiência.
- Ele começa "cego" e por tentativa e erro vai aprendendo.
- Se temos um modelo, sabemos exatamente o que vai acontecer antes de agir.
- Por exemplo em um jogo de tabuleiro: *"Se eu estou na casa A e for para a direita, eu TENHO 100% de chance de cair na casa B e ganhar 5 pontos"*.


O que significa o "Q"?

		Ações			
Estados	10	2	6	8	
	1	9	5	2	
	3	6	1	8	

- Significa **qualidade**.
- Representa o quão boa é uma determinada ação em um estado específico.
- Quem informa a **qualidade** é uma função chamada de **valor-ação**, $Q(s, a)$, que mede o retorno (qualidade) esperado ao executar a ação a no estado s .
- No *Q-learning*, ela é definida de forma **discreta** (estados e ações) por uma tabela (ou matriz), chamada de **tabela-Q**.
- As linhas são os estados e as colunas são as ações.

O que significa o "Q"?

- Cada entrada da tabela armazena um valor de qualidade para um par estado-ação.
- O objetivo do algoritmo é preencher a tabela com os valores que façam o agente escolher a melhor ação sempre.



ACTIONS

↑ ↓ → ←

Start	0	0	0	0
Blank	0	-1	1	-1
Power	0	0	0	0
Mines	0	0	0	0
Home	0	0	0	0

STATES

Como o *Q-learning* aprende?

1. Inicialize a tabela-Q com zeros.
2. Observe o estado atual s .
3. Repita até o fim do **episódio**:
 - Escolha uma ação a usando a **política ϵ -greedy**.
 - Execute a ação a , observe o novo estado s' e a recompensa r .
 - **Atualize o valor $Q(s, a)$ na tabela-Q.**
 - Atualize o estado atual: $s \leftarrow s'$.

O 'aprender' acontece na etapa de atualização, que veremos a seguir.


O que é um episódio?

- É uma sequência **completa** de interações entre o agente e o ambiente, que começa num **estado inicial** e termina quando um **estado terminal** é alcançado.
- O episódio é como uma "partida" ou uma "tentativa":
 1. **Início:** O ambiente é resetado para uma posição inicial (e.g., o rato aparece no início do mapa).
 2. **Ciclo:** O agente toma ações, recebe recompensas e o ambiente muda de estado sucessivamente.
 3. **Fim:** O episódio se encerra quando um critério é atingido, como:
 - O agente atinge o **objetivo** (e.g., rato chegar ao queijo).
 - O agente comete um **erro fatal** (e.g., rato encontrar uma bomba).
 - O tempo ou o **limite de passos** esgota-se.

O que é um episódio?


- O treino do *Q-learning* é feito ao longo de muitos episódios.
- Em cada novo episódio, o agente utiliza o que aprendeu nos anteriores (os valores na tabela-Q) para tentar obter uma recompensa total maior do que na tentativa passada.
- O treinamento encerra-se quando
 - a soma das recompensas obtidas ao longo do episódio para de subir e "estaciona" em um valor alto por muitos episódios seguidos.
 - Isso significa que o agente já explorou o suficiente e encontrou o caminho ótimo.
 - ou pela ausência de mudanças significativas nos valores da tabela-Q.

Exploração vs. Exploração (ϵ -greedy)




- **Exploração:** Tentar ações aleatórias para descobrir novas recompensas.
 - Riscos altos, mas possíveis ganhos altos a longo prazo.
- **Exploração:** Escolher a melhor ação conhecida usando a tabela-Q atual.
 - Garantia de recompensa conhecida.
- **A estratégia Epsilon-Greedy (ϵ -greedy):**
 - Com probabilidade ϵ (e.g., 10%), o agente **explora** (ação aleatória).
 - Com probabilidade $1 - \epsilon$ (e.g., 90%), o agente **explora** (escolhe o max de Q para o estado atual s).

Exploração vs. Exploração (ϵ -greedy)



- Se o agente não explorar no começo, ele pode encontrar um caminho medíocre e ficar preso nele para sempre.
- Assim, o ϵ costuma
 - começar em 1.0 (100% de exploração), fazendo com que o agente tome ações aleatórias para descobrir o ambiente
 - e decair gradualmente à medida que o agente aprende (*decay rate*).
- A exploração agressiva no início.
- Isso permite que o agente tenha a chance de aprender uma boa política.



Como o agente aprende?

Ou seja, como a tabela-Q é atualizada?

Atualização da tabela-Q: a equação de Bellman

- A tabela-Q é atualizada usando-se a equação derivada por Richard Bellman:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

- $Q(s, a)$: é o valor atual na tabela para o estado e a ação.
- α : **taxa de aprendizado, varia no intervalo (0, 1]**.
 - Define o quanto a nova informação substitui a antiga.
 - Valor pequeno $\rightarrow$ aprendizado lento.
 - Valor grande $\rightarrow$ atualização agressiva.
- r : **recompensa**.
 - O que ele acabou de ganhar por tomar a ação a .
 - Não há restrição de intervalo, mas manter r em intervalos pequenos, como $[-1, 1]$ e $[0, 1]$, ajuda na estabilidade e na velocidade de convergência.

Atualização da tabela-Q: a equação de Bellman

- A tabela-Q é atualizada usando-se a equação derivada por Richard Bellman:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

- γ : **fator de desconto, varia no intervalo [0, 1]**.
 - Determina a importância das recompensas futuras.
 - Equilibra a importância entre recompensas imediatas e futuras.
 - Determina o ***quão longe no futuro ele enxerga***.
- $\max_{a'} Q(s', a')$: é o **melhor valor Q possível no próximo estado**.
 - É a estimativa da recompensa futura.
 - A equação assume que no próximo estado tomaremos a **melhor ação possível**.

A equação de Bellman

$$\underbrace{r + \gamma \max_{a'} Q(s', a')}_{\text{alvo}} - \underbrace{Q(s, a)}_{\text{estimativa atual}}$$

- O termo dentro dos colchetes é chamado de **Erro de Diferença Temporal** (*temporal difference* (TD) *error*).
- É a diferença entre o que acabamos de descobrir ($r + \gamma \max_{a'} Q(s', a')$) e o que achávamos que sabíamos ($Q(s, a)$).
- Nós multiplicamos esse erro por α para corrigir nossa crença passo a passo.
- A cada transição, $Q(s, a)$ se aproxima da recompensa imediata r mais o valor futuro ótimo descontado ($\gamma \max_{a'} Q(s', a')$).

A equação de Bellman

- A equação de Bellman diz basicamente:

“O valor de uma ação = recompensa imediata + melhor valor futuro possível”

- Ou seja

$$Q(s, a) \approx r + \gamma \max_{a'} Q(s', a').$$

- A equação de Bellman pode ser interpretada como:

Novo valor = Valor antigo + α × erro

- Ou seja, ajusta-se a estimativa **na direção do valor alvo**.

A influência do fator de desconto, γ

- $\gamma \leftarrow 0$: o agente só liga para recompensas imediatas
 - Foca no curto prazo, recompensas futuras não importam.
 - O aprendizado é mais rápido.
 - Usado em sistemas de controle em tempo real.
 - Por exemplo: controle de potência, MAC em redes (transmitir agora ou esperar), controle de marcapasso, *day trading* (comprar ou vender ações a cada minuto).
- $\gamma \rightarrow 1$: o agente busca recompensas a longo prazo.
 - Ele valoriza recompensas que ocorrerão muito tempo depois.
 - O treinamento é mais lento.
 - Usado em navegação ou robótica, jogos de estratégia, planejamento onde ações iniciais afetam o resultado final e a recompensa só vem muito tempo depois ou no final.
 - Por exemplo: robô indo até um destino distante, *pac man*, xadrez, decidir trajetórias eficientes para veículos autônomos (planejamento de rota).

Off-policy

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

- O *Q-learning* é um algoritmo *off-policy*.
- Ele atualiza $Q(s, a)$ assumindo que o agente sempre escolhe a ação ótima futura ($\max_{a'} Q(s', a')$), independentemente da ação realmente tomada.
 - Mesmo que o algoritmo tenha explorado (ação aleatória), ele aprende como se tivesse agido de forma ótima.
- Algoritmos *on-policy* usam a ação realmente escolhida para atualizar $Q(s, a)$.

Exemplo numérico

início	neutro
bomba	meta

- O tabuleiro possui 4 **estados**:
 - Início (S): estado inicial de cada episódio, recompensa 0, não terminal.
 - Célula neutra (N): recompensa 0, não terminal.
 - Bomba (B): recompensa -1, **terminal**.
 - Meta (G): recompensa +1, **terminal**.
- **Ações**: cima, baixo, esquerda, direita.
- **Transições com bordas**: se uma ação levar para fora do tabuleiro, o agente **permanece na mesma célula**. A recompensa é a da célula onde ele permanece.
- **Dinâmica dos terminais**: ao atingir a Meta ou a Bomba, o episódio termina imediatamente. Não há ações seguintes nesses estados.

Exemplo numérico

início	neutro
bomba	meta

Parâmetros escolhidos para o exemplo:

- Taxa de aprendizado $\alpha = 0.5$.
- Fator de desconto $\gamma = 0.9$.
- **Política de exploração:** ε -greedy com $\varepsilon = 0.5$ (50% de chance de ação aleatória, 50% de ação gulosa).
- Iniciaremos o exemplo com esse ε e depois consideraremos uma fase puramente gulosa para observar a política aprendida.
- **Inicialização:** todos os $Q(s, a) = 0$.
- Bomba e Meta são terminais: nunca selecionamos ações neles.

Exemplo numérico

início	neutro
bomba	meta

Tabela Q inicial

Estado/Ação	Cima	Direita	Baixo	Esquerda
Início	0	0	0	0
Neutro	0	0	0	0
Bomba	0	0	0	0
Meta	0	0	0	0

Agora vamos simular alguns episódios, mostrando a cada passo, o cálculo da atualização e a evolução da tabela.

Exemplo numérico

Episódio 1

• Passo 1

início	neutro
bomba	meta

- Estado atual: **início**.
- Como todos os valores de $Q(s, a) = 0$, suponha que, por exploração, o agente selecionou a ação: **baixo**.
- Transição: **início** + **baixo** $\rightarrow$ **bomba**.
- Recompensa: $r = -1$, estado seguinte $s' = \mathbf{bomba}$ (terminal).
- $\max_{a'} Q(\mathbf{bomba}, a') = 0$ (terminal, Q não se altera).
- Atualização de $Q(\mathbf{início}, \mathbf{baixo})$:
$$Q(\mathbf{início}, \mathbf{baixo}) = 0 + 0.5[-1 + 0.9 \times 0 - 0] = -0.5$$
- Episódio terminado.

Exemplo numérico

início	neutro
bomba	meta

Tabela Q após episódio 1

Estado/Ação	Cima	Direita	Baixo	Esquerda
Início	0	0	-0.5	0
Neutro	0	0	0	0
Bomba	0	0	0	0
Meta	0	0	0	0

Exemplo numérico

Episódio 2

• Passo 1

início	neutro
bomba	meta

- Ações com maior Q em **início**: **cima, direita e esquerda**.
- A política poderia escolher qualquer uma delas, mas vamos supor que a escolha foi aleatória (exploração): **direita**.
- Transição: **início + direita** → **neutro**.
- Recompensa: $r = 0$, estado seguinte $s' = \mathbf{neutro}$ (não terminal).
- $\max_{a'} Q(\mathbf{neutro}, a') = 0$ (todos zero).
- Atualização de $Q(\mathbf{início}, \mathbf{direita})$:
$$Q(\mathbf{início}, \mathbf{direita}) = 0 + 0.5[0 + 0.9 \times 0 - 0] = 0$$
- O valor permanece 0.

Exemplo numérico

Episódio 2

• Passo 2

início	neutro
bomba	meta

- Agora o agente está em **neutro**.
- Todas as ações em **neutro** com $Q = 0$.
- Suponha que, por exploração, o agente escolheu **baixo**.
- Transição: **neutro** + **baixo** → **meta**.
- Recompensa: $r = +1$, estado seguinte $s' = \mathbf{meta}$ (terminal).
- $\max_{a'} Q(\mathbf{meta}, a') = 0$ (todos zero).
- Atualização de $Q(\mathbf{neutro}, \mathbf{baixo})$:
$$Q(\mathbf{neutro}, \mathbf{baixo}) = 0 + 0.5[1 + 0.9 \times 0 - 0] = 0.5$$
- Episódio terminado.

Exemplo numérico

início	neutro
bomba	meta

Tabela Q após episódio 2

Estado/Ação	Cima	Direita	Baixo	Esquerda
Início	0	0	-0.5	0
Neutro	0	0	0.5	0
Bomba	0	0	0	0
Meta	0	0	0	0

Exemplo numérico

Episódio 3

• Passo 1

início	neutro
bomba	meta

- Ações com maior Q em **início**: **cima, direita e esquerda**.
- Podemos ter exploração ou exploração. Suponha que a escolha foi gulosa (exploração): **direita**.
- Transição: **início + direita** → **neutro**.
- Recompensa: $r = 0$, estado seguinte $s' = \mathbf{neutro}$ (não terminal).
- $\max_{a'} Q(\mathbf{neutro}, a') = 0.5$ (ação **baixo** no estado **neutro**).
- Atualização:
$$Q(\mathbf{início}, \mathbf{direita}) = 0 + 0.5[0 + 0.9 \times 0.5 - 0] = 0.225$$

Exemplo numérico

Episódio 3

• Passo 2

início	neutro
bomba	meta

- Agora o agente está no estado **neutro**.
- Suponha que, por exploração, o agente escolheu **baixo**.
- Transição: **neutro** + **baixo** → **meta**.
- Recompensa: $r = +1$, estado seguinte $s' = \mathbf{meta}$ (terminal).
- $\max_{a'} Q(\mathbf{meta}, a') = 0$ (todos zero).
- Atualização:
$$Q(\mathbf{neutro}, \mathbf{baixo}) = 0.5 + 0.5[1 + 0.9 \times 0 - 0.5] = 0.75$$
- Episódio terminado.

Exemplo numérico

Tabela Q após episódio 3

início	neutro
bomba	meta

Estado/Ação	Cima	Direita	Baixo	Esquerda
Início	0	0.225	-0.5	0
Neutro	0	0	0.75	0
Bomba	0	0	0	0
Meta	0	0	0	0

Exemplo numérico

Episódio 4

• Passo 1

início	neutro
bomba	meta

- Ação com maior Q em **início**: **direita**.
- Suponha que, por exploração, o agente escolheu **direita**.
- Transição: **início** + **direita** $\rightarrow$ **neutro**.
- Recompensa: $r = 0$, estado seguinte $s' =$ **neutro** (não terminal).
- $\max_{a'} Q(\mathbf{neutro}, a') = 0.75$.
- Atualização:
$$Q(\mathbf{início}, \mathbf{direita}) = 0.225 + 0.5[0 + 0.9 \times 0.75 - 0.225] = 0.45$$

Exemplo numérico

Episódio 4

• Passo 2

início	neutro
bomba	meta

- Agora o agente está no estado **neutro**.
- Suponha que, por exploração, o agente escolheu **baixo**.
- Transição: **neutro** + **baixo** → **meta**.
- Recompensa: $r = +1$, estado seguinte $s' = \mathbf{meta}$ (terminal).
- $\max_{a'} Q(\mathbf{meta}, a') = 0$ (todos zero).
- Atualização:
$$Q(\mathbf{neutro}, \mathbf{baixo}) = 0.75 + 0.5[1 + 0 - 0.75] = 0.875$$
- Episódio terminado.

Exemplo numérico

início	neutro
bomba	meta

Tabela Q após episódio 4

Estado/Ação	Cima	Direita	Baixo	Esquerda
Início	0	0.45	-0.5	0
Neutro	0	0	0.875	0
Bomba	0	0	0	0
Meta	0	0	0	0

Exemplo numérico

Episódio 5

• Passo 1

início	neutro
bomba	meta

- Ação com maior Q em **início**: **direita**.
- Suponha que, por exploração, o agente escolheu **cima**.
- Transição: **início** + **cima** → **início**.
- Recompensa: $r = 0$, estado seguinte $s' = \mathbf{início}$ (não terminal).
- $\max_{a'} Q(\mathbf{início}, a') = 0.45$ (direita).
- Atualização:
$$Q(\mathbf{início}, \mathbf{cima}) = 0 + 0.5[0 + 0.9 \times 0.45 - 0] = 0.2025$$
- O agente aprende que mesmo uma ação que não sai do lugar pode ter valor, pois do mesmo estado inicial pode-se depois tomar a ação ótima.

Exemplo numérico

Episódio 5

• Passo 2

início	neutro
bomba	meta

- Ação com maior Q em **início**: **direita**.
- Suponha que, por exploração, o agente escolheu **baixo**.
- Transição: **início** + **baixo** $\rightarrow$ **bomba**.
- Recompensa: $r = -1$, estado seguinte $s' =$ **bomba** (terminal).
- $\max_{a'} Q(\mathbf{bomba}, a') = 0$.
- Atualização:
$$Q(\mathbf{início}, \mathbf{baixo}) = -0.5 + 0.5[-1 + 0.9 \times 0 - (-0.5)] = -0.75$$
- Episódio terminado.

Exemplo numérico

Tabela Q após episódio 5

início	neutro
bomba	meta

Estado/Ação	Cima	Direita	Baixo	Esquerda
Início	0.2025	0.45	-0.75	0
Neutro	0	0	0.875	0
Bomba	0	0	0	0
Meta	0	0	0	0

Exemplo numérico

Episódio 6

• Passo 1

início	neutro
bomba	meta

- O agente está em **início**.
- Suponha que, por exploração, o agente escolheu **direita**.
- Transição: **início** + **direita** → **neutro**.
- Recompensa: $r = 0$, estado seguinte $s' = \mathbf{neutro}$ (não terminal).
- $\max_{a'} Q(\mathbf{neutro}, a') = 0.875$.
- Atualização:
$$Q(\mathbf{início}, \mathbf{direita}) = 0.45 + 0.5[0 + 0.9 \times 0.875 - 0.45] = 0.61875$$

Exemplo numérico

Episódio 6

- **Passo 2**

início	neutro
bomba	meta

- Agora o agente está em **neutro**.
- Suponha que, por exploração, o agente escolheu **baixo**.
- Transição: **neutro** + **baixo** → **meta**.
- Recompensa: $r = +1$, estado seguinte $s' = \mathbf{meta}$ (terminal).
- $\max_{a'} Q(\mathbf{meta}, a') = 0$ (todos zero).
- Atualização:
$$Q(\mathbf{neutro}, \mathbf{baixo}) = 0.875 + 0.5[1 - 0.875] = 0.9375$$
- Episódio terminado.


Exemplo numérico

Tabela Q após episódio 6

início	neutro
bomba	meta

Estado/Ação	Cima	Direita	Baixo	Esquerda
Início	0.2025	0.61875	-0.75	0
Neutro	0	0	0.9375	0
Bomba	0	0	0	0
Meta	0	0	0	0

Exemplo numérico



- A convergência final (após muitas visitas) leva aos valores ótimos:
 - $Q^*(\text{início}, \text{direita}) = 0 + \gamma \times 1 = 0.9$
 - $Q^*(\text{neutro}, \text{baixo}) = 1 + \gamma \times 0 = 1.0$
 - $Q^*(\text{início}, \text{cima}) = 0 + \gamma \times 0.9 = 0.81$
 - $Q^*(\text{início}, \text{esquerda}) = 0 + \gamma \times 0.9 = 0.81$ (borda mantém em **início**)
 - $Q^*(\text{neutro}, \text{esquerda}) = 0 + \gamma \times 0.9 = 0.81$ (vai para **início**)
 - $Q^*(\text{início}, \text{baixo}) = -1.0$ (**bomba**, terminal)
- Após muitos episódios, se tornarmos a política completamente gulosa ($\varepsilon = 0$), o agente seguirá:
 - Em **início**: escolher **direita** ($Q = 0.9$, a maior)
 - Em **neutro**: escolher **baixo** ($Q = 1.0$)
- Esse caminho leva diretamente à **meta** sem pisar na **bomba**, maximizando a recompensa acumulada descontada.
- Exemplo: [q learning grid 2x2.ipynb](#)


A maldição da dimensionalidade

- O *Q-learning* tem uma limitação conhecida como o **problema do espaço de estados**.
- Ele requer que todos os estados estejam em uma tabela.
- Porém, e se quisermos treiná-lo para jogar Xadrez?
 - São aproximadamente 10^{40} estados.
- E se quisermos treiná-lo para dirigir um carro autônomo usando uma câmara para observar o ambiente?
 - Milhões de pixels gerando bilhões de estados contínuos.
- É impossível armazenar a tabela-Q na memória do computador ou percorrê-la a tempo de tomar uma decisão, tornando o treinamento impossível.

A maldição da dimensionalidade

- Para problemas com poucas ações e estados, a tabela é ótima.
- Mas, por exemplo, em engenharia robótica, os estados são contínuos:
 - Por exemplo, velocidade, ângulo da articulação.
- Não podemos ter uma linha na tabela-Q para um ângulo de 45,1 graus e outra para 45,2 graus.
- Assim, se o espaço de estados é **grande ou contínuo** a tabela-Q é inviável.
- Precisamos de **generalização**.

Trocando a tabela-Q por redes neurais



- **A solução:** Em vez de usar uma matriz para buscar $Q(s, a)$, usamos uma **rede neural** para *aproximar* a função Q .
- A rede aprender a generalizar estados: o agente não precisa visitar todos os estados.
- **Entrada:** O estado (e.g., a imagem da câmera).
 - Agora, o estado pode ser composto por valores contínuos.
- **Saída:** Os valores Q para todas as ações possíveis naquele estado.

Onde RL é usado?



- **Robótica e manufatura:** Ensinar robôs a andar, agarrar objetos ou equilibrar cargas.
- **Otimização de redes e sistemas:** Roteamento de pacotes dinâmico para evitar gargalos na rede.
- **Sistemas de recomendação:** Otimizar qual vídeo ou anúncio mostrar para você na internet com base no engajamento a longo prazo.
- **Controle industrial:** Ajuste fino de caldeiras e refrigeração em data centers para reduzir consumo de energia.

Exemplo

- [Exemplo: q-learning.ipynb](#)



Lista de exercícios

Lista #14 – Q-Learning

Perguntas?

Obrigado!

Figuras

