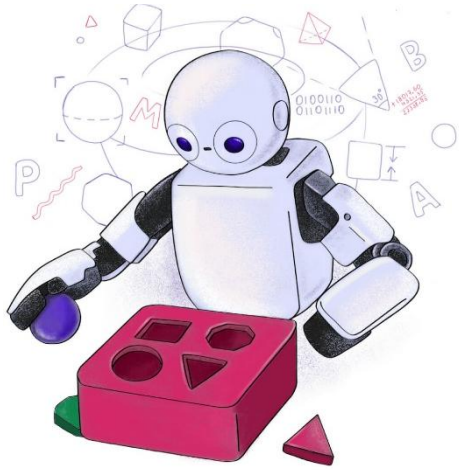
C24 – Inteligência Artificial:
Árvores de decisão

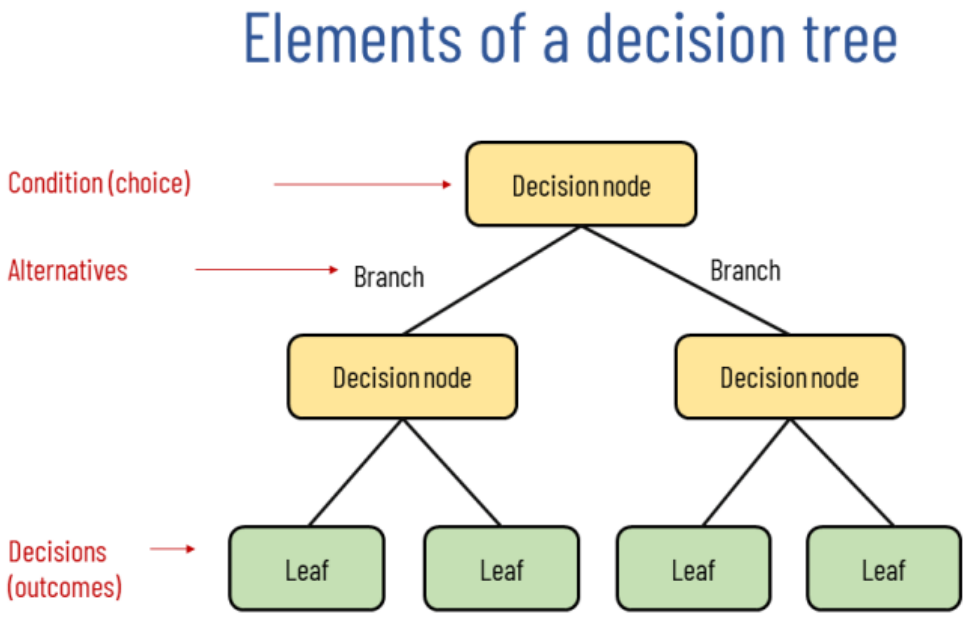


Inatel

Felipe A. P. de Figueiredo
felipe.figueiredo@Inatel.br

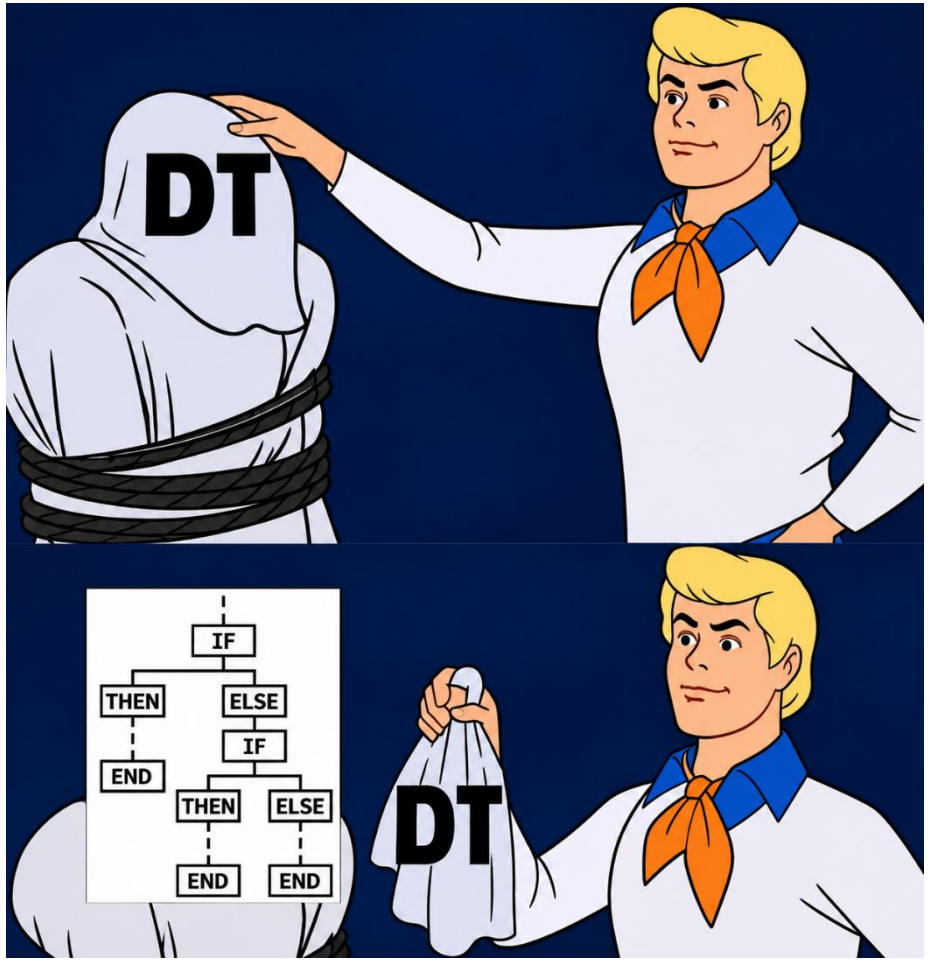

TREES
TREES EVERYWHERE

O que é uma árvore de decisão?



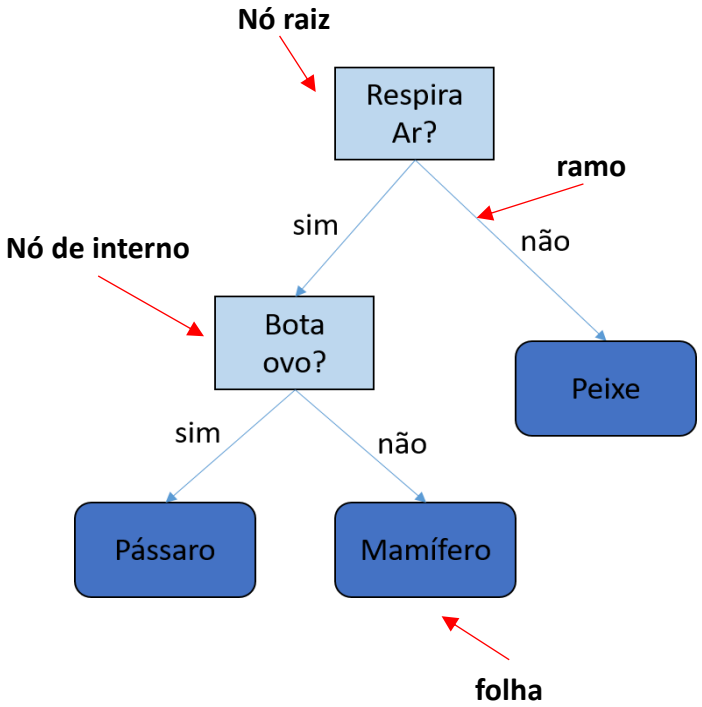
- **Árvores de decisão** (do inglês, ***decision trees - DTs***), são modelos de
  - **aprendizado supervisionado**
  - **não-paramétrico**
  - e **não-lineares.**
- São usadas em tarefas de **classificação** e **regressão**.

O que é uma árvore de decisão?



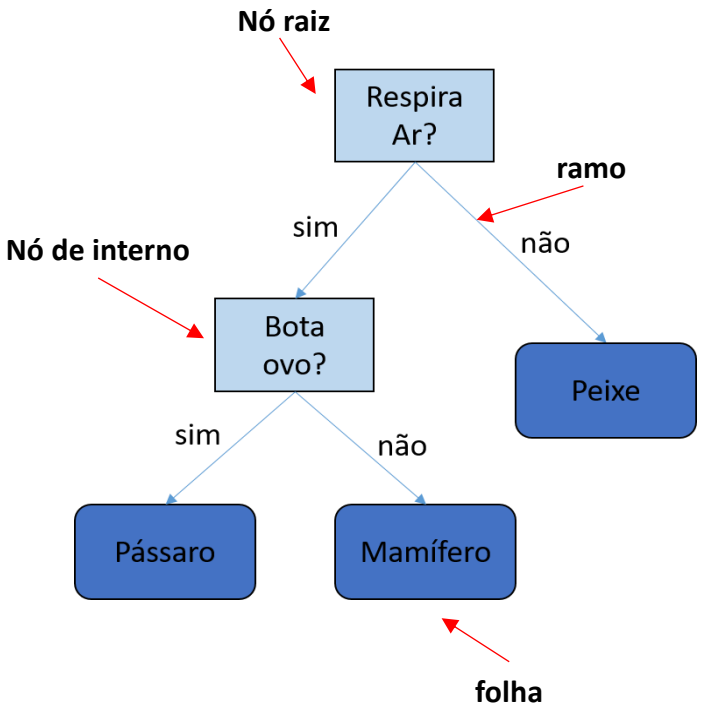
- Árvores de decisão podem ser interpretadas como **estruturas de controle de fluxo**
- Durante o treinamento, as árvores aprendem **regras de decisão** a partir dos **atributos e rótulos de treinamento**.
- **Vantagens**: interpretáveis, necessitam de pouco pré-processamento.
- **Limitação**: uma árvore isolada tende ao sobreajuste.

Anatomia de uma árvore de decisão



- As árvores são compostas por
  - Um nó raiz:
    - **Faz o primeiro teste da árvore**.
    - E realiza a **primeira divisão dos dados** (*split*)
  - Nós internos
    - representam **testes (i.e., condições)**
    - **testam um atributo e dividem os dados** em subconjuntos
  - Ramos
    - representam o **resultado de um teste**
  - e (nós) folhas
    - representam o **valor final de uma predição (e.g., uma classe ou um valor)**
- **Exemplo:** Se respira e bota ovo então é Pássaro.

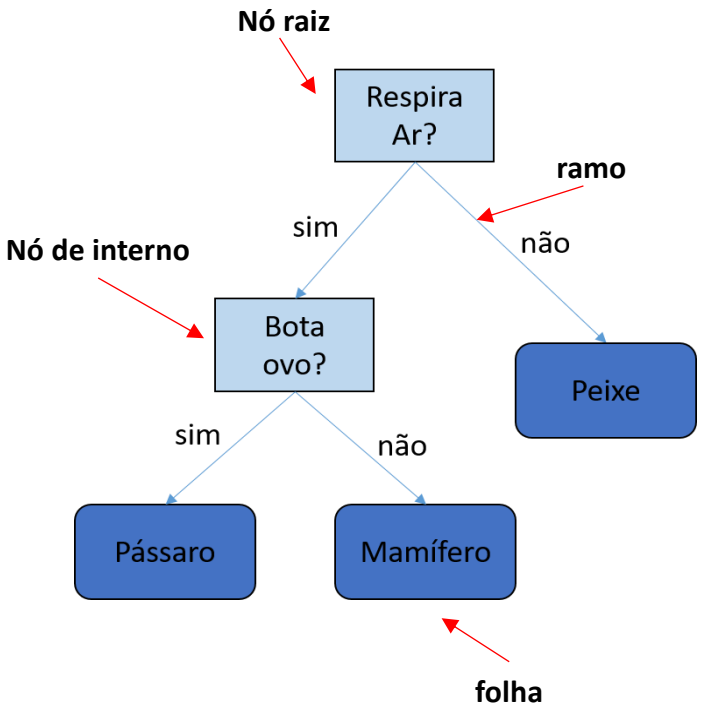
Anatomia de uma árvore de decisão



- Formalmente, uma árvore é um **grafo conexo e acíclico.**
  - Isso significa que entre quaisquer dois nós existe exatamente um caminho.
- Ela é **orientada da raiz para as folhas**.
  - As arestas apontam da raiz para as folhas.
- Cada nó (exceto a raiz) tem um único pai, e a inferência percorre a árvore de cima para baixo.

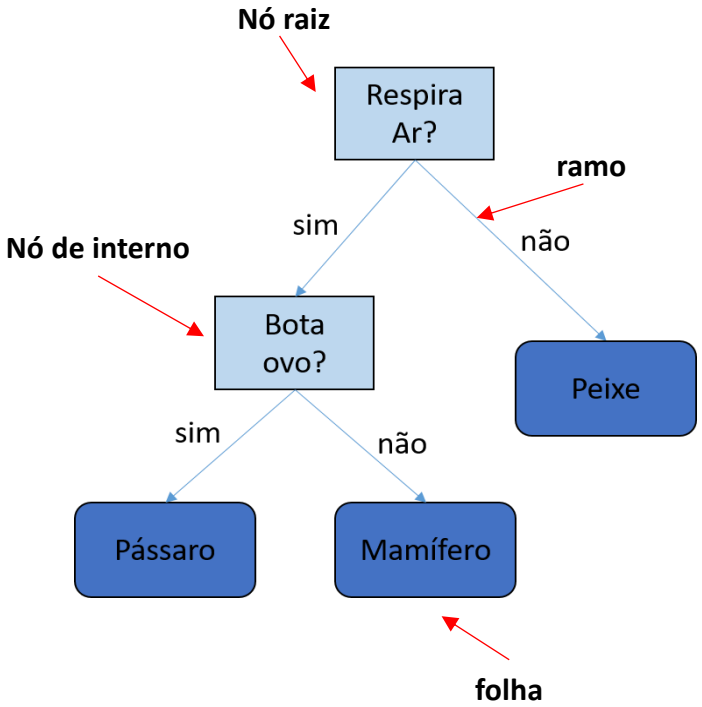
A questão central: **como induzir (i.e., criar) uma árvore a partir dos dados de treinamento?**

Modelos de caixa branca



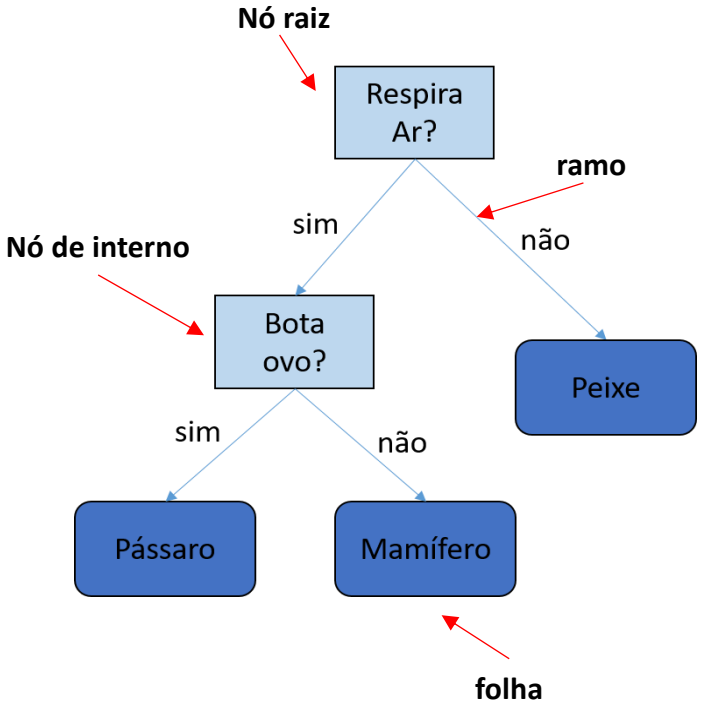
- Árvores são modelos de **caixa branca.**
- Isso significa que é possível seguir o **caminho desde a raiz até uma folha e explicar cada predição**.
- São o oposto dos modelos de **caixa preta.**
- Os **resultados são difíceis de interpretar.**
- **Não é fácil entender como os atributos interagem entre si para produzir uma predição.**
  - Redes neurais são exemplos de modelos de caixa preta.

O que significa ser um modelo paramétrico?



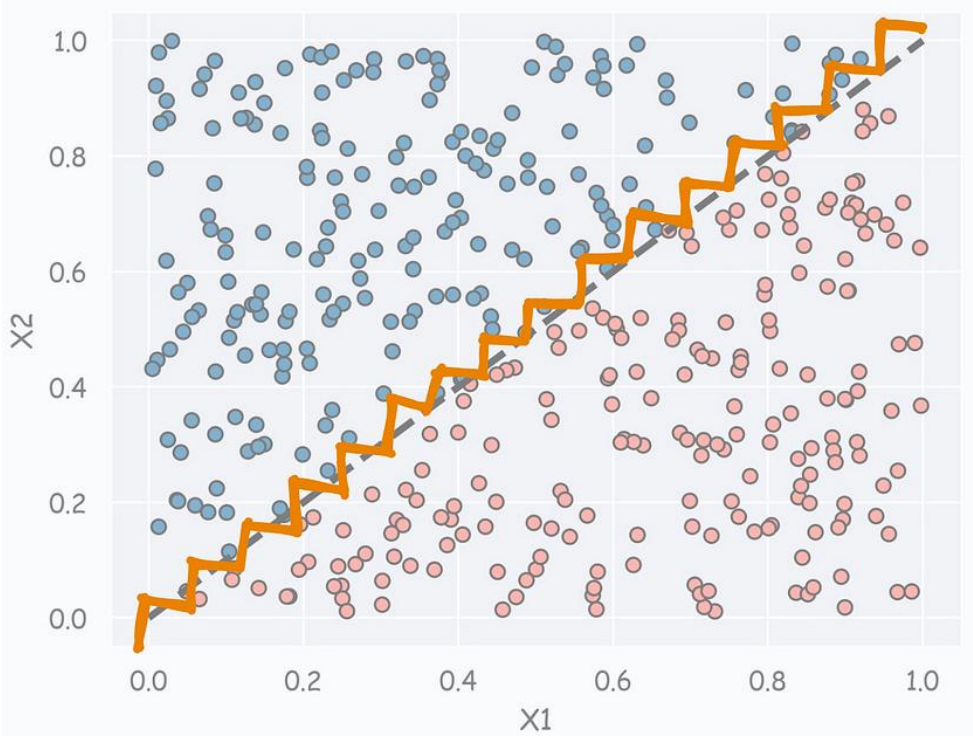
- Um modelo **paramétrico** tem:
  - **forma funcional fixa**.
    - Uma **equação** como no caso da regressão linear.
  - **número fixo de parâmetros, definido antes do treinamento**.
    - **Regressão linear**: **quantidade de pesos** de uma **função hipótese é constante**.
  - **complexidade constante**: não cresce com os dados.
- Além disso, alguns modelos fazem suposições sobre a distribuição dos dados.
  - **Naive Bayes**: assumem distribuições normal, multinominal ou Bernoulli dependendo da versão.
  - **Gaussian Mixture Models (GMMs)**: assumem que os dados vêm de misturas de gaussianas.

O que significa ser um modelo não-paramétrico?



- Um modelo **não-paramétrico**:
  - **não** assume forma funcional fixa
    - Não tem uma equação como no caso da regressão linear.
  - **não** fixa o número de parâmetros
    - O número de parâmetros é definido **durante** o treino
  - tem **complexidade que depende dos dados**
    - Sua complexidade (i.e., número de parâmetros) tende a crescer com o tamanho da base de dados.
    - Ou seja, o modelo cria parâmetros (cresce) dinamicamente para se adaptar aos dados de treinamento.
- Fazem **menos suposições fortes** sobre a distribuição dos dados.

O que significa ser um modelo não-linear?



Classes separadas diagonalmente

- As **funções aproximadora e discriminante não são lineares**.
  - Ou seja, os dados **não são** aproximados ou separados por **hiperplanos**.
- Cada nó faz um **corte paralelo a um eixo** do espaço de atributos.
- A combinação dos cortes gera uma **função constante por partes**, altamente não-linear.
- Na figura, uma fronteira diagonal é **aproximada** por “degraus”.

Como induzir uma árvore a partir dos dados de treinamento?

O problema da indução

- Criar e testar **todas as árvores possíveis** e escolher a menor (seguindo o princípio da navalha de Occam) é **inviável** (alto custo computacional).
- Encontrar a **árvore ótima é um problema NP-completo**:
  - Uma solução é verificável em tempo polinomial, mas não se conhece algoritmo polinomial para encontrá-la.
- **Exemplo**: Problema do caixeiro viajante, onde há 12 rotas distintas com 5 cidades e cerca de 6×10^{16} com 20 e o objetivo é **encontrar o menor caminho que visite todas elas.**
  - O número de rotas cresce de forma fatorial!
  - Verificar uma solução é rápido, mas encontrar a solução ótima pode levar muito tempo e consumir muita memória dependendo do número de cidades.

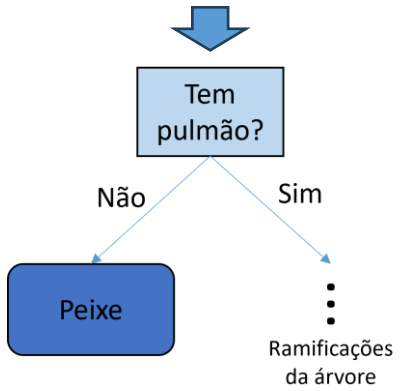
Solução prática

Conjunto de treinamento

Atributos					Rótulo
Tem pulmão?	**Bota ovo?**	**Mama?**	**Tem penas?**	**Tem escamas?**	**Classe**
Y	Y	Y	N	N	Mamífero
Y	Y	N	Y	N	Ave
Y	N	Y	N	N	Mamífero
Y	N	N	N	Y	Réptil
N	Y	N	N	Y	Peixe
N	N	N	N	Y	Peixe
Y	Y	N	N	Y	Réptil
Y	Y	N	N	N	Anfíbio
Y	N	N	Y	N	Ave
N	Y	N	N	Y	Peixe

Subconjunto obtido quando **Tem pulmão?** == "N"

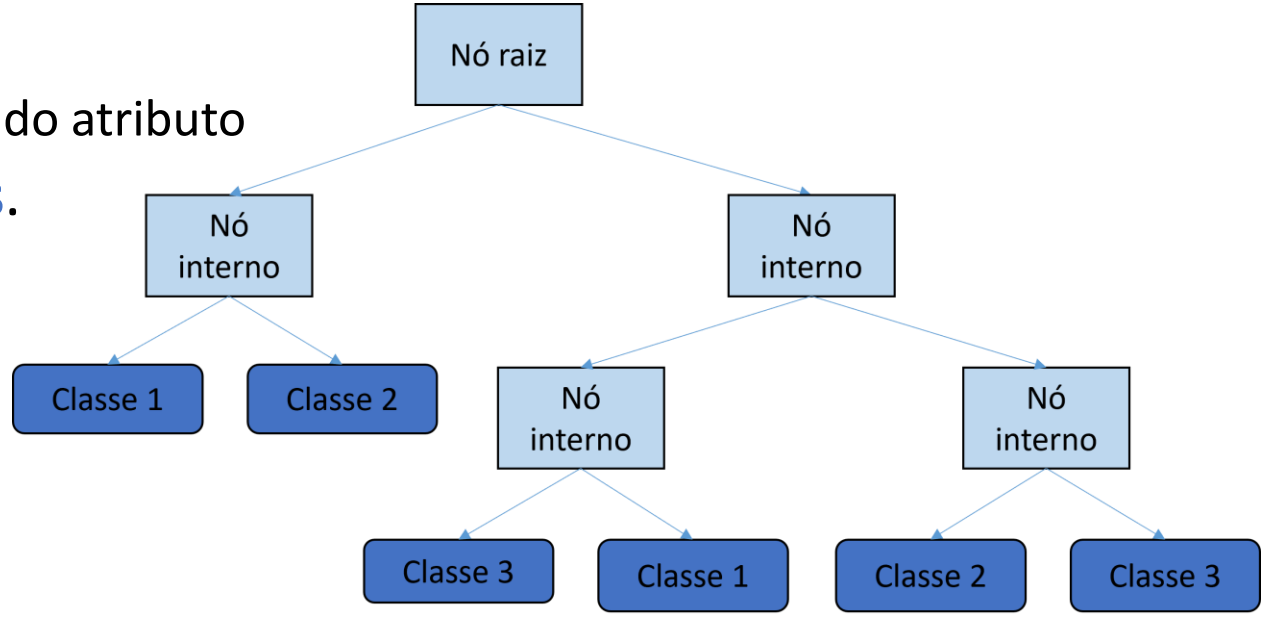
Atributos					Rótulo
Tem pulmão?	**Bota ovo?**	**Mama?**	**Tem penas?**	**Tem escamas?**	**Classe**
N	Y	N	N	Y	Peixe
N	N	N	N	Y	Peixe
N	Y	N	N	Y	Peixe



- Utilizar **heurísticas gulosas** como: **ID3**, C4.5, C5.0, **CART (*scikit-learn*)**.
- Elas **não garantem a árvore ótima**, mas produzem boas árvores rapidamente.
- Por ser o algoritmo mais simples e que mostra a ideia central por trás da indução de árvores de decisão, focaremos no ***Iterative Dichotomiser 3* (ID3)**.
- **Dicotomização iterativa** significa **dividir-se o conjunto de dados sucessivamente.**

O algoritmo ID3

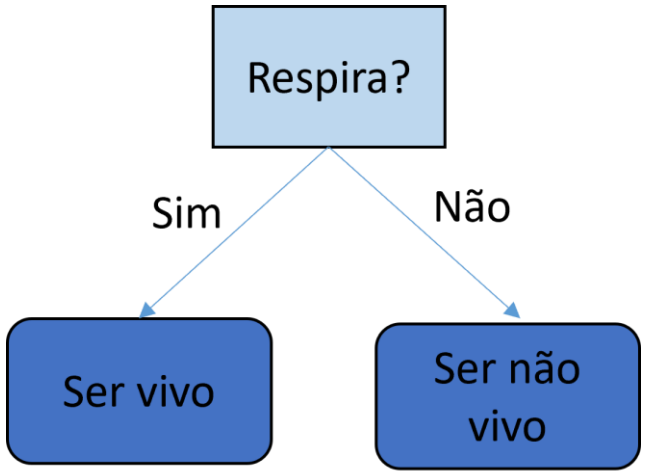
- Funciona apenas para classificação com atributos categóricos.
- Ele constrói uma árvore de forma **iterativa de cima (raiz) para baixo (folhas)**:
  - Escolhe o atributo que **melhor separa os dados** para ser um nó
    - No caso do ID3, **separar significa classificar os dados**
  - Divide os dados em subconjuntos
    - Ou seja, **cria ramos** a partir dos valores do atributo
  - Repete o processo nos **subconjuntos**.



O algoritmo ID3

- O ID3 segue uma **estratégia gulosa**.
  - A cada iteração, ele sempre escolhe o **melhor atributo localmente**
    - Qual atributo separa melhor os dados AGORA?
    - Ele **não reconsidera** decisões **anteriores** e **não testa se escolher um atributo pior agora levaria a uma árvore menor ou mais precisa no final**.
  - Portanto, isso não garante uma solução ótima, apenas uma que ela seja razoável e encontrada de forma rápida.
- Para escolher o melhor atributo, ele usa a métrica conhecida como **ganho de informação.**
  - O atributo com o **maior ganho de informação** é selecionado como nó.

Ganho de informação



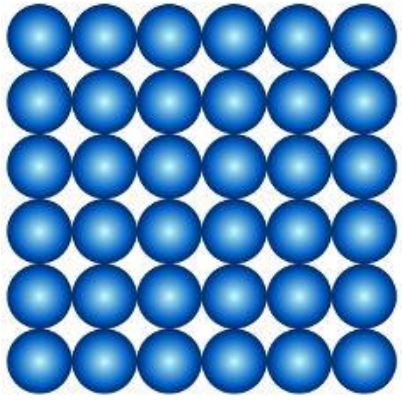
Exemplo: No problema binário para classificar objetos entre seres vivos e inanimados, o atributo “Respira?” tem ganho de informação máximo, pois **separa perfeitamente os exemplos nas duas classes (atributo perfeito)**.

- O ganho de informação **mede o quão bem um atributo classifica os exemplos de treinamento**.
- O ID3 escolhe como nó, o atributo que melhor classificar os dados.
  - **Ganho zero**: o atributo é inútil (o mesmo atributo está associado a mais de uma classe).
  - **Ganho máximo**: o atributo separa as classes perfeitamente.
- O ganho de informação é **definido em termos da entropia**, que é uma medida vinda da **teoria da informação**.

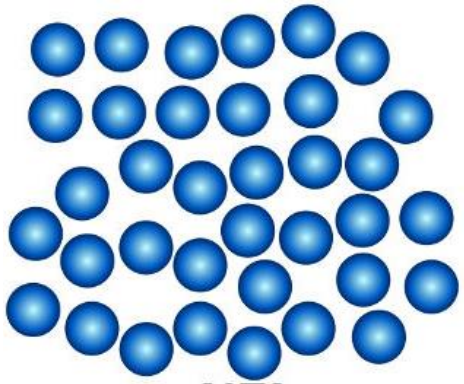
Entropia

- A entropia, H, mede a **quantidade de incerteza ou aleatoriedade** de uma variável aleatória.
  - No caso do ID3, consideramos o conjunto de (i.e., o vetor de) rótulos como sendo uma variável aleatória.
- No ID3, a **entropia mede a incerteza (ou "mistura" ou "bagunça") das classes em um conjunto de exemplos**.
  - **Entropia máxima**: conjunto totalmente misturado, os exemplos estão igualmente divididos entre as classes.
  - **Entropia mínima (0)**: conjunto é "puro", ou seja, todos os exemplos pertencem à mesma classe (não há "bagunça").
- Vejamos como calcular a entropia e alguns exemplos.

Cálculo da entropia



BAIXA ENTROPIA



ALTA ENTROPIA

- A **entropia** da k-ésima variável aleatória discreta, X_k, que assume D valores distintos, $x_{k,i}, i \in \{1, .., D\}$, onde cada um dos distintos valores tem probabilidade $P(x_{k,i})$, é definida como

$$H(X_k) = -\sum_{i=1}^{D} P(x_{k,i}) \log_2\big(P(x_{k,i})\big).$$

- As probabilidades $P(x_{k,i})$ usadas no cálculo são, na prática, as **frequências relativas observadas no conjunto de treinamento**.
- **OBS**.: O logaritmo na base 2 é usado porque a unidade natural de medida da informação na computação e na teoria da informação é o *bit*.

Exemplos de entropia



- Uma variável com apenas um único valor **não tem nenhuma incerteza** associada.
  - Por exemplo, o arremesso de uma moeda com **cara** em ambos os lados.
- Portanto, sua **entropia é igual a zero**.
- Isso significa que **não se ganha nenhuma informação nova ao se observar o valor de um arremesso**.

Exemplos de entropia





- Por outro lado, o resultado de se arremessar uma **moeda honesta** é igualmente provável de resultar em **cara** ou **coroa.**
- Neste caso, esta variável tem **1 bit de entropia**, significando que se necessita de 1 bit para representar os 2 possíveis resultados.

Exemplos de entropia





- Agora imaginem um **moeda desonesta** que tem probabilidade de resultar em **coroa** em 99% dos arremessos.
- Nesse caso, a **entropia** deve ser um **valor muito próximo de zero**, pois a incerteza do resultado é muito baixa.
- Outro exemplo: a variável aleatória que representa o resultado de se rolar um **dado honesto de 4 lados**, **tem 2 bits de entropia**, pois necessita-se de 2 bits para se representar os 4 possíveis valores.

Ganho de informação

- O **ganho de informação** é a **diferença entre a entropia do rótulo, y, antes e depois da divisão do conjunto de dados** com base nos valores do k-ésimo atributo, x_k.
- Ele **mede o quanto a incerteza sobre y diminui após conhecermos x_k**

$$Gain(x_k) = \underbrace{H(y)}_{\text{entropia antes da divisão}} - \underbrace{H(y|x_k)}_{\text{entropia após a divisão}},$$

ou seja, mede o quanto de informação o atributo x_k traz sobre y.

- $H(y|x_k)$ é a entropia condicional de y dado o atributo x_k, também chamada de **entropia restante**, ou ***remainder*** em inglês.
  - Dado a informação de x_k, o que sobra de aleatoriedade em y.

Ganho de informação

- Portanto, **um ganho de informação** corresponde a uma **redução da entropia**.
- Em outras palavras, ele **mede o quanto um atributo reduz a "bagunça" das classes de um conjunto**.
- Assim, o **ganho** mede o **quanto conseguimos classificar corretamente os exemplos de um conjunto** dado os valores de um atributo.
- Agora retornamos ao problema da indução de **árvores de decisão.**
- Vamos induzir uma árvore de decisão para resolver um problema de classificação binária.

Indução de uma árvore de decisão

- Se um conjunto de treinamento, E, contém p exemplos pertencentes à classe positiva (*P*) e n exemplos pertencentes à classe negativa (*N*), então a **entropia do rótulo** para **todo** o conjunto de treinamento é dada por

$$H(y) = B\left(\frac{p}{p+n}\right) = -\left[\frac{p}{p+n}\log_2\left(\frac{p}{p+n}\right) + \left(1-\frac{p}{p+n}\right)\log_2\left(1-\frac{p}{p+n}\right)\right],$$

onde $B\left(\frac{p}{p+n}\right)$ é a **entropia de uma variável booleana que é positiva com probabilidade igual a** $\frac{p}{p+n}$**.**

Indução de uma árvore de decisão

- Um atributo, x_k, pode **reduzir toda ou parte** da **incerteza (entropia) do objetivo**, $H(y)$.
- Nós medimos o **quanto cada atributo reduz a entropia do objetivo** através do cálculo da **entropia restante após o teste do atributo**.
- Para o cálculo da **entropia restante**, precisamos definir que:
- Um **atributo x_k com D valores distintos divide o conjunto de treinamento E em $\boldsymbol{D}$ subconjuntos**: $E_1, \ldots, E_D$.
- Cada subconjunto $E_i, i \in \{1, \ldots, D\}$, possui $p_i, i \in \{1, \ldots, D\}$, exemplos da classe positiva, *P*, e $n_i, i \in \{1, \ldots, D\}$, exemplos da classe negativa, *N*.

Indução de uma árvore de decisão

- Um exemplo escolhido aleatoriamente do conjunto de treinamento tem probabilidade igual a $(p_i + n_i)/(p + n)$ de pertencer ao i-ésimo subconjunto, E_i, do atributo x_k.
- Assim, a **entropia restante** após o teste do atributo x_k é dada por

$$Remainder(x_k) = \sum_{i=1}^{D} \frac{p_i + n_i}{p + n} B\left(\frac{p_i}{p_i + n_i}\right).$$

- Ela é a **média ponderada das entropias de cada subconjunto** após o teste do atributo, x_k.
- Resumindo, a **entropia restante** é a **medida da incerteza que sobra depois que usamos a informação do atributo.**

Indução de uma árvore de decisão

- Assim, o **ganho de informação** com o atributo x_k é a **redução na entropia do rótulo**, que é dado por

$$Gain(x_k) = B\left(\frac{p}{p+n}\right) - Remainder(x_k) \geq 0.$$

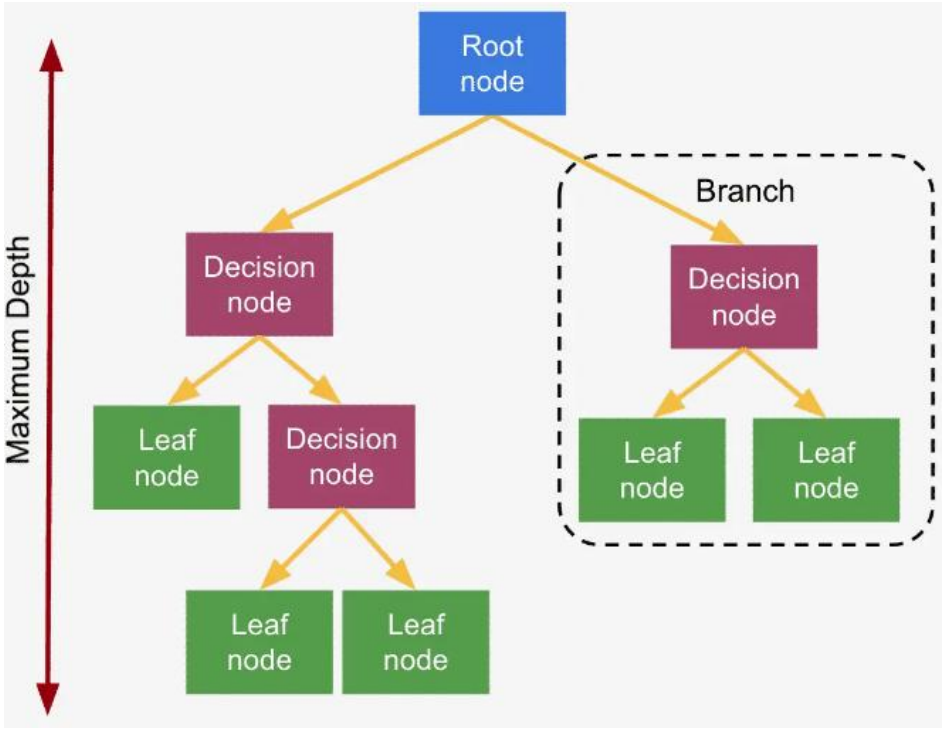
- O menor valor de $Gain(x_k)$ é 0 (*remainder* igual à B), que ocorre quando o atributo x_k **não reduz nenhuma incerteza do conjunto**, ou seja, é inútil.
- Já o maior valor, $Gain(x_k) = B\left(\frac{p}{p+n}\right)$, ocorre quando x_k **explica toda a incerteza e, portanto, $\boldsymbol{Remainder(x_k) = 0}$**.
- Ou seja, x_k faz a classificação perfeita do conjunto de dados.

Sequência de passos do algoritmo ID3

1. Cálcular a **entropia do rótulo** para o conjunto **atual**.
2. Cálcular o **ganho de informação** de cada atributo x_k ainda disponível.
3. Criar um nó com o atributo de maior **ganho de informação**, com um ramo por valor, e remover esse atributo do caminho (i.e., ramificação).
4. Dividir o conjunto atual em subconjuntos usando cada valor distinto do nó (i.e., cada valor cria um ramo, que divide o conjunto atual).
5. Repetir os passos 1 à 4 nos **subconjuntos** usando os atributos restantes.

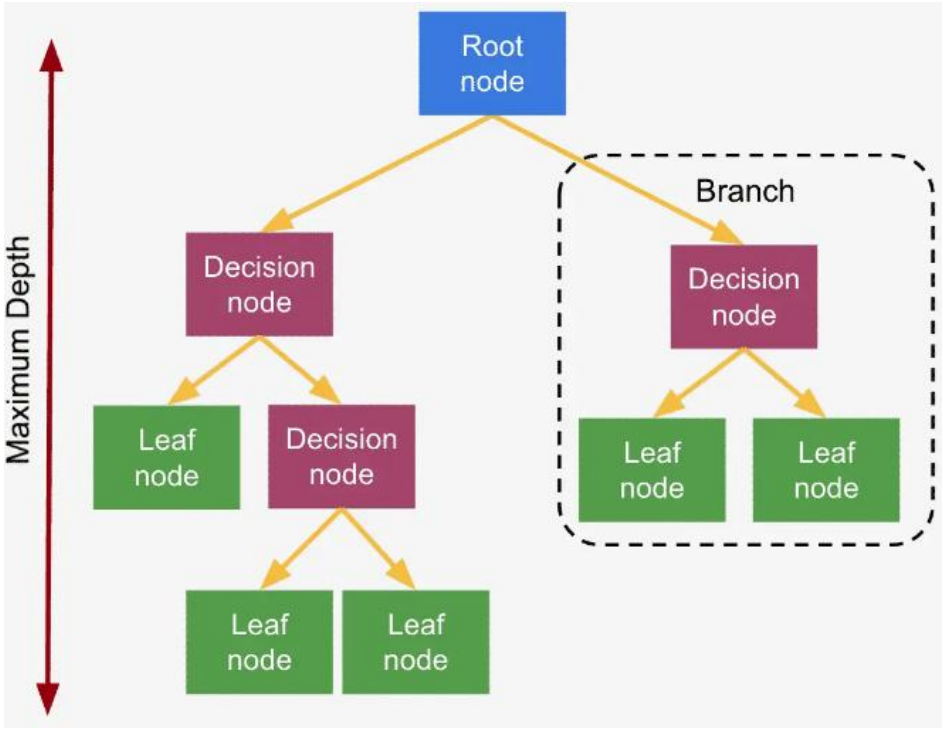
Parada: As iterações **continuam até que a árvore classifique perfeitamente todos os exemplos de treinamento** ou **até que todos os atributos tenham sido utilizados**.

Sequência de passos do método ID3



- O **ID3** segue a seguinte regra para ramificar:
  - Um **nó** com **entropia igual a zero**, i.e., ganho máximo, é uma **folha**.
  - Um **nó** com **entropia maior do que zero precisa de divisão adicional**.
- **Limitação do ID3:** atributos com muitos valores distintos (como ID ou CPF) têm ganho de informação máximo, mas só **memorizam os dados e não generalizam (sobreajuste)**.

Inconsistência nos dados de treinamento



- **Inconsistência**: Dois ou mais exemplos com os **mesmos valores de atributos**, mas com **classes diferentes**.
- **Consequência:** nenhum teste consegue separá-los, e não se encontra um nó com entropia 0, mesmo depois de usar todos os atributos.
- **O que fazer:**
  - criar atributos mais informativos;
  - revisar os rótulos e remover os exemplos errados ou duplicados;

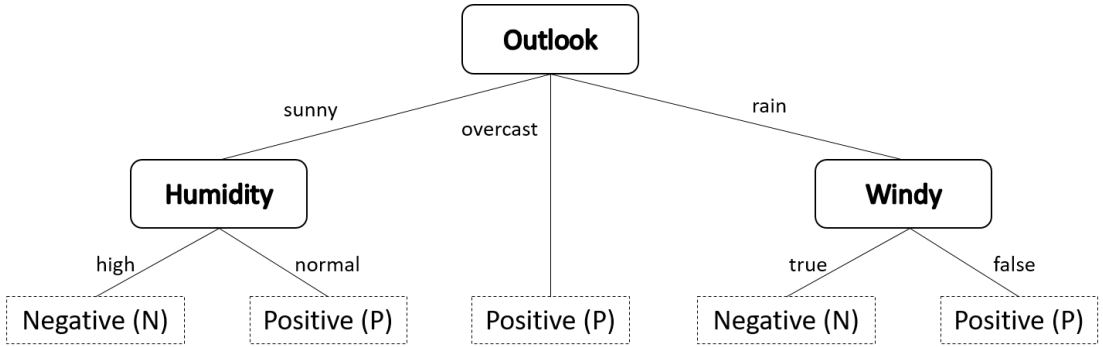
Exemplo de indução de uma árvore de decisão com o método ID3

Exemplo de indução com método ID3

- Vamos construir uma árvore de decisão para **predizer se jogadores irão ou não praticar um esporte** baseado em algumas **condições meteorológicas**.
  - Problema de classificação binária.
- Vamos considerar um conjunto de dados da forma $(\boldsymbol{x}_i, d_i)$, onde $\boldsymbol{x}_i$ é o i-ésimo **vetor de atributos** e d_i é o i-ésimo **rótulo** correspondente ao vetor de atributos.
- Nesse conjunto, cada linha diz respeito à condição meteorológica de um dia e se os jogadores jogaram ou não.

Exemplo de indução com método ID3

- Existem **quatro** atributos **categóricos**:
  - **Outlook**: {sunny, overcast, rain}
  - **Temperature**: {cold, mild, hot}
  - **Humidity**: {high, normal}
  - **Windy**: {true, false}
- Os rótulos são: **Positive** (P), i.e., jogar, e **Negative** (N), i.e., não jogar.



Exemplo de indução com método ID3

- O conjunto de treinamento do exemplo é dado pela tabela abaixo.

Dia	**Atributos**				**Rótulo** (y)
	Outlook	**Temperature**	**Humidity**	**Windy**	
1	sunny	hot	high	false	N
2	sunny	hot	high	true	N
3	overcast	hot	high	false	P
4	rain	mild	high	false	P
5	rain	cool	normal	false	P
6	rain	cool	normal	true	N
7	overcast	cool	normal	true	P
8	sunny	mild	high	false	N
9	sunny	cool	normal	false	P
10	rain	mild	normal	false	P
11	sunny	mild	normal	true	P
12	overcast	mild	high	true	P
13	overcast	hot	normal	false	P
14	rain	mild	high	true	N

planilha

Exemplo de indução com método ID3

- A **entropia do objetivo**, i.e., y, para todo o conjunto de treinamento é

$$H(y) = -\left[\frac{9}{14}\log_2\left(\frac{9}{14}\right) + \left(1-\frac{9}{14}\right)\log_2\left(1-\frac{9}{14}\right)\right] = 0.9403.$$

- Encontrando o nó raiz: o **ganho de informação** de cada atributo é calculado como

		Jogar?		
		P	N	
Outlook	sunny	2	3	5
	overcast	4	0	4
	rain	3	2	5
				14

		Jogar?		
		P	N	
Temperature	hot	2	2	4
	mild	4	2	6
	cool	3	1	4
				14

		Jogar?		
		P	N	
Humidity	high	3	4	7
	normal	6	1	7
				14

		Jogar?		
		P	N	
Windy	true	3	3	6
	false	6	2	8
				14

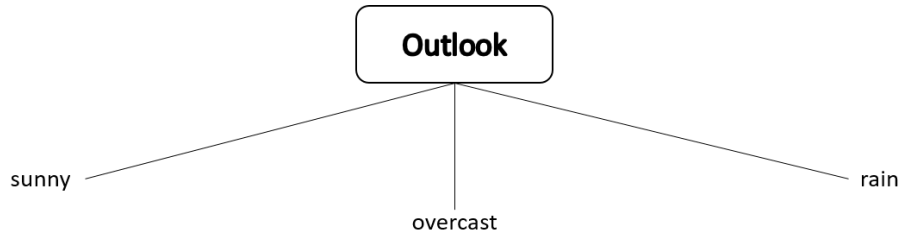
$$Gain(\mathbf{Outlook}) = 0.9403 - \left[\frac{5}{14}B\left(\frac{2}{5}\right) + \frac{4}{14}B(1) + \frac{5}{14}B\left(\frac{3}{5}\right)\right] = \boxed{0.247}$$

$$Gain(\mathbf{Temperature}) = 0.9403 - \left[\frac{4}{14}B\left(\frac{2}{4}\right) + \frac{6}{14}B\left(\frac{4}{6}\right) + \frac{4}{14}B\left(\frac{3}{4}\right)\right] = 0.029$$

$$Gain(\mathbf{Humidity}) = 0.9403 - \left[\frac{7}{14}B\left(\frac{3}{7}\right) + \frac{7}{14}B\left(\frac{6}{7}\right)\right] = 0.1518$$

$$Gain(\mathbf{Windy}) = 0.9403 - \left[\frac{6}{14}B\left(\frac{3}{6}\right) + \frac{8}{14}B\left(\frac{6}{8}\right)\right] = 0.04813$$

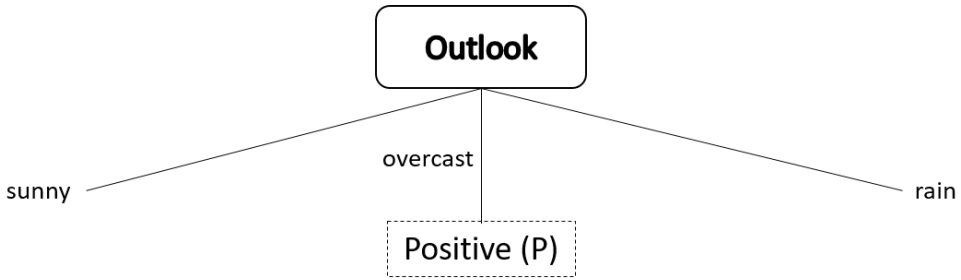
O **ganho de informação** é maximizado com o atributo **Outlook**, que é, portanto, escolhido como o nó raíz da árvore.



Exemplo de indução com método ID3

- Agora, criamos **subconjuntos para cada um dos valores** do atributo **Outlook** e **refazemos** os cálculos do **ganho de informação** para cada um deles.
- Quando **Outlook = overcast**, o subconjunto abaixo mostra que os valores dos outros atributos não importam, **decisão será sempre pela classe Positive (P) se o tempo estiver nublado**.
- A **entropia nessa caso é igual a zero** (pois não há incerteza), indicando uma **folha** da árvore.
- Portanto, encontramos a folha deste ramo.

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
3	overcast	hot	high	false	P
7	overcast	cool	normal	true	P
12	overcast	mild	high	true	P
13	overcast	hot	normal	false	P



Exemplo de indução com método ID3

- Quando **Outlook = rain**

Outlook = rain		Jogar?		
		P	N	
Temperature	hot	0	0	0
	mild	2	1	3
	cool	1	1	2
				5

Outlook = rain		Jogar?		
		P	N	
Humidity	high	1	1	2
	normal	2	1	3
				5

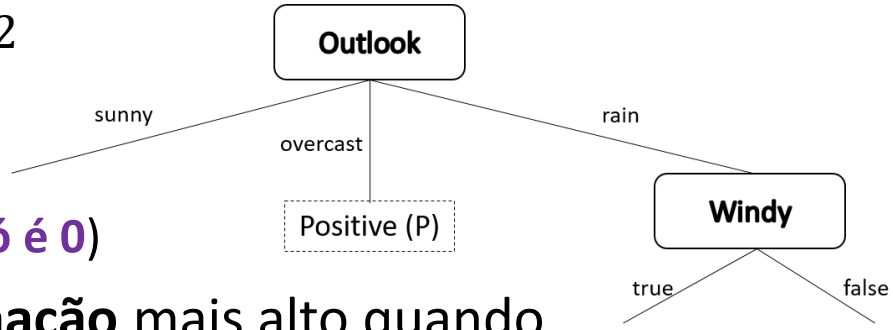
Outlook = rain		Jogar?		
		P	N	
Windy	true	0	2	2
	false	3	0	3
				5

Entropia do objetivo para o subconjunto $\mathbf{Outlook = rain}$: $H(y \mid \mathbf{Outlook = rain}) = 0.971$

$$Gain(\mathbf{Temperature}) = 0.971 - \left[\frac{0}{5} B\left(\frac{0}{0}\right)^{*} + \frac{3}{5} B\left(\frac{2}{3}\right) + \frac{2}{5} B\left(\frac{1}{2}\right)\right] = 0.02$$

$$Gain(\mathbf{Humidity}) = 0.971 - \left[\frac{2}{5} B\left(\frac{1}{2}\right) + \frac{3}{5} B\left(\frac{2}{3}\right)\right] = 0.02$$

$$Gain(\mathbf{Windy}) = 0.971 - \left[\frac{2}{5} B\left(\frac{0}{2}\right) + \frac{3}{5} B\left(\frac{3}{3}\right)\right] = \boxed{0.971}$$ (**entropia do nó é 0**)



- Aqui, o atributo **Windy** resulta no valor de **ganho de informação** mais alto quando o tempo estiver chovendo (i.e., **Outlook = rain**).
- Por isso, o atributo **Windy** será o nó do 2º nível da árvore, no ramo **rain** de **Outlook**.

* Por convenção, um ramo sem amostras tem entropia 0.

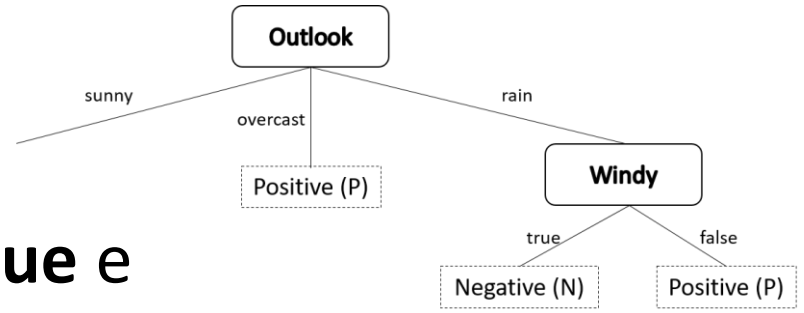
Exemplo de indução com método ID3

- Se analisarmos o subconjunto onde **Outlook = rain** e **Windy = false**, percebemos que a decisão será sempre pela classe **Positive** (*P*). A entropia H(y|Outlook = rain, windy = false) = 0.

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
4	rain	mild	high	false	P
5	rain	cool	normal	false	P
10	rain	mild	normal	false	P

- Além disso, a decisão sempre será pela classe Negative (*N*) se **Outlook = rain** e **Windy = true**. A entropia H(y|Outlook = rain, windy = false) = 0.

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
6	rain	cool	normal	true	N
14	rain	mild	high	true	N



- Portanto, encontramos as folhas para os ramos **true** e **false** do nó **Windy**.

Exemplo de indução com método ID3

- Quando **Outlook = sunny**

Outlook = sunny		Jogar? P	N	
Temperature	hot	0	2	2
	mild	1	1	2
	cool	1	0	1
				5

Outlook = sunny		Jogar? P	N	
Humidity	high	0	3	3
	normal	2	0	2
				5

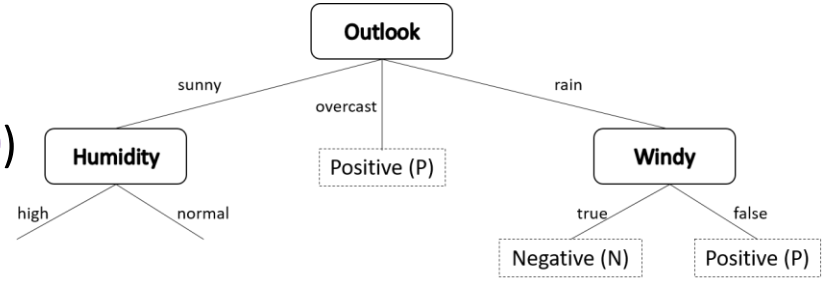
Outlook = sunny		Jogar? P	N	
Windy	true	1	1	2
	false	1	2	3
				5

A **entropia do objetivo** para o subconjunto dado por **Outlook = sunny**: $H(y \mid \textbf{Outlook} = \textbf{sunny}) = 0.971$

$Gain(\textbf{Temperature}) = 0.971 - \left[\frac{2}{5}B\left(\frac{0}{2}\right) + \frac{2}{5}B\left(\frac{1}{2}\right) + \frac{1}{5}B\left(\frac{1}{1}\right)\right] = 0.570$

$Gain(\textbf{Humidity}) = 0.971 - \left[\frac{3}{5}B\left(\frac{0}{3}\right) + \frac{2}{5}B\left(\frac{2}{2}\right)\right] = \boxed{0.971}$ (**entropia nó é 0**)

$Gain(\textbf{Windy}) = 0.971 - \left[\frac{2}{5}B\left(\frac{1}{2}\right) + \frac{3}{5}B\left(\frac{1}{3}\right)\right] = 0.02$



- Aqui, o atributo **Humidity** resulta no **ganho de informação** mais alto quando o tempo estiver ensolarado (i.e., **Outlook = sunny**).
- Por isso, o atributo **Humidity** será o nó do 2º nível da árvore no ramo ***sunny***.

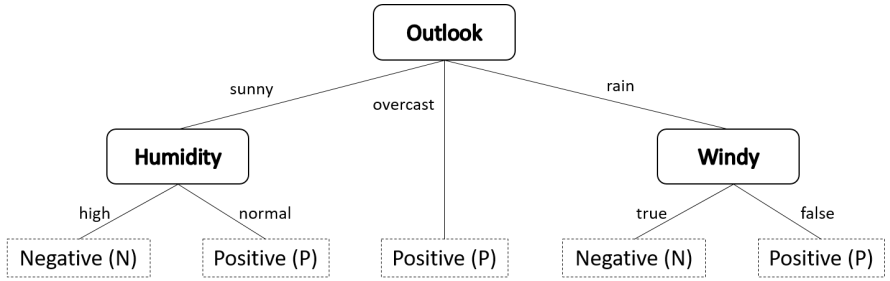
Exemplo de indução com método ID3

- A decisão será sempre pela classe **Positive** (*P*) quando **Outlook = sunny** e **Humidity = normal**. A entropia H(y|Outlook = sunny, Humidity = normal) = 0.

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
9	sunny	cool	normal	false	P
11	sunny	mild	normal	true	P

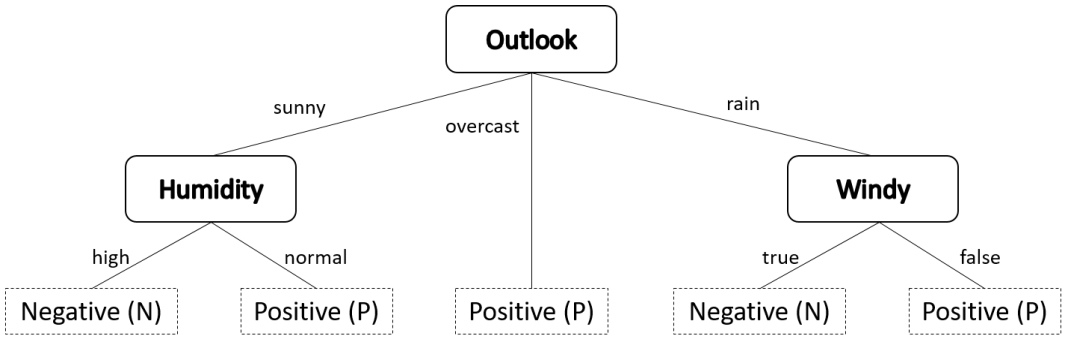
- A decisão será sempre pela classe **Negative** (N) quando **Outlook = sunny** e **Humidity = high**. A entropia H(y|Outlook = sunny, Humidity = high) = 0

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
1	sunny	hot	high	false	N
2	sunny	hot	high	true	N
8	sunny	mild	high	false	N



- Portanto, encontramos as folhas para os ramos **normal** e **high** do nó **Humidity**.

Exemplo de indução com método ID3



- Com isso, a construção da **árvore de decisão** se encerra e podemos usar as regras encontradas para classificar exemplos inéditos.
- **Algum atributo ficou de fora?**
  - Sim, **Temperature**, indicando que ele **não trouxe ganho de informação suficiente para ser selecionado** em nenhum nó da árvore.
- Isso mostra uma característica fundamental de algoritmos de indução de árvores:
  - Eles fazem **seleção embutida de atributos** durante a indução da árvore.

Algumas considerações gerais sobre as árvores de decisão

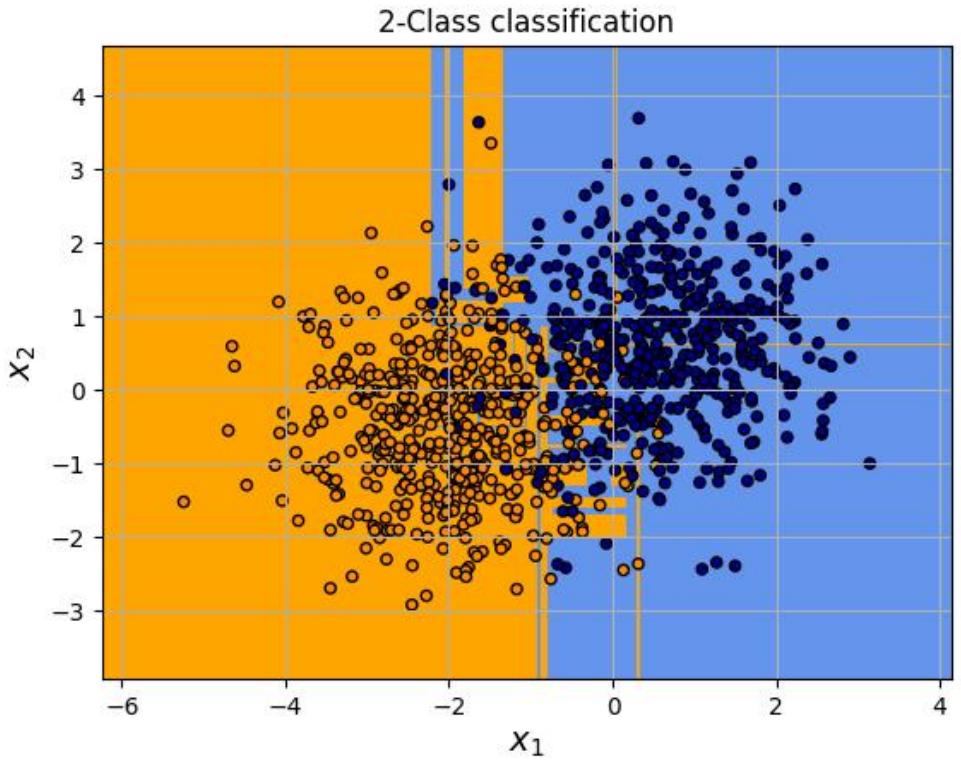
Considerações sobre as árvores de decisão

- O ID3 não suporta atributos contínuos, apenas se forem transformados em faixas ou categorias (i.e., discretizados).
- C4.5 e CART suportam atributos contínuos encontrando limiares ótimos para a divisão dos ramos.
- Algoritmos que suportam atributos contínuos não necessitam de escalonamento: a árvore só compara valores com limiares.
- Em geral, são sensíveis a atributos com valores faltantes. Algumas formas de se tratar o problema:
  - Remover exemplos incompletos.
  - Remover atributos se a quantidade de valores faltantes for muita alta.
  - Imputar valores: estatística (média, mediana, moda) e preditiva (modelos estimam o valor com base nos valores dos outros atributos).
  - Alguns algoritmos têm tratamento nativo próprio: C4.5 e o CART.

Considerações sobre as árvores de decisão

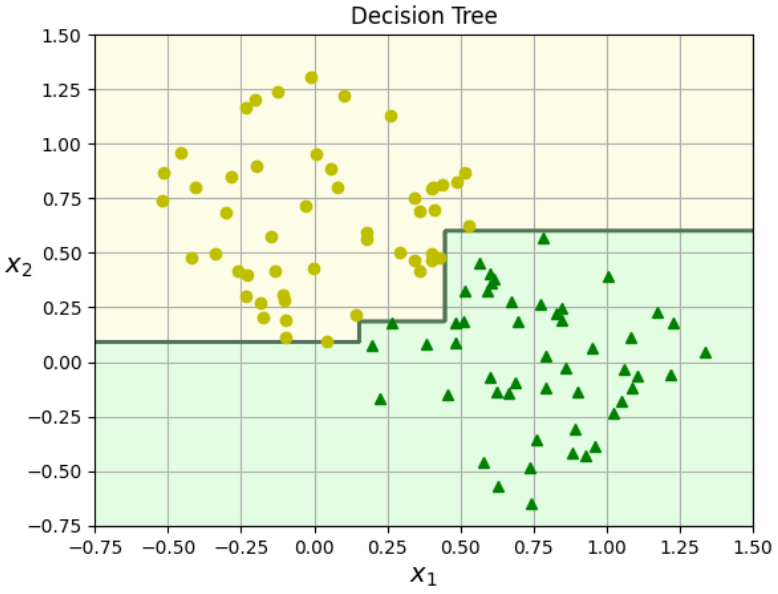
- Árvores se **sobreajustam** facilmente porque **crescem até separar todos os exemplos de treinamento**, inclusive o ruído presente nos dados.
- O sobreajuste ocorre quando se tem:
  - um número muito grande de atributos,
  - poucos dados,
  - árvores muito profundas,
  - e ruído nos dados
- Algumas formas para se minimizar o problema:
  - Coletar mais dados.
  - Limitar o crescimento (profundidade) da árvore (regularização).
  - Podar (***tree prunning***) ramos que contribuem pouco para a predição.
  - Ou utilizar conjuntos (*ensembles*) de árvores, as chamadas **florestas aleatórias**.
    - Florestas reduzem o sobreajuste ao combinar várias árvores, aumentando a generalização.

Considerações sobre as árvores de decisão



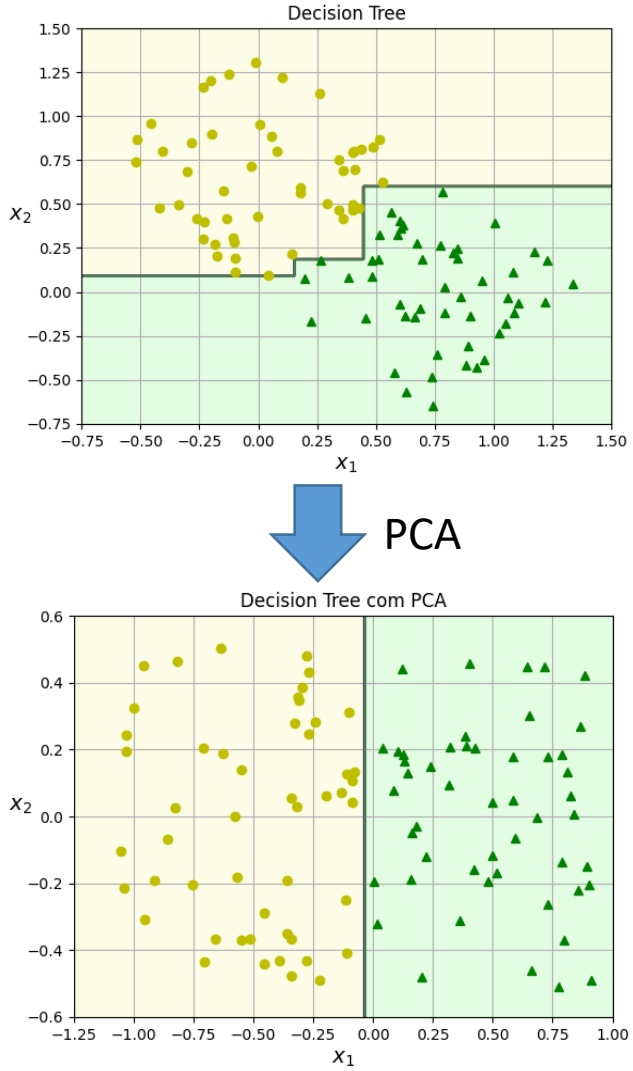
- Em problemas de classificação, quando as **classes não são bem separadas** (sobreposição), **as árvores são suscetíveis a se sobreajustar** ao conjunto de treinamento.
- A figura ao lado mostra uma superfície de separação extremamente complexa.
- Formas de se minimizar o problema: limitar o crescimento, podar ou usar florestas.

Considerações sobre as árvores de decisão



- Árvores são muito **sensíveis a rotações nos dados de treinamento**.
- Em classificação, quando os dados estão rotacionados, elas criam **fronteiras de decisão extremamente complexas** compostas por vários **degraus.**
- A consequência é que elas ficam **maiores (mais complexas) do que o necessário** e há um maior **risco de sobreajuste**.
- Na figura, a árvore aproxima uma reta na diagonal com uma escada (vários degraus).
- Um modelo linear (reta) seria menos complexo e generalizaria melhor.

Considerações sobre as árvores de decisão

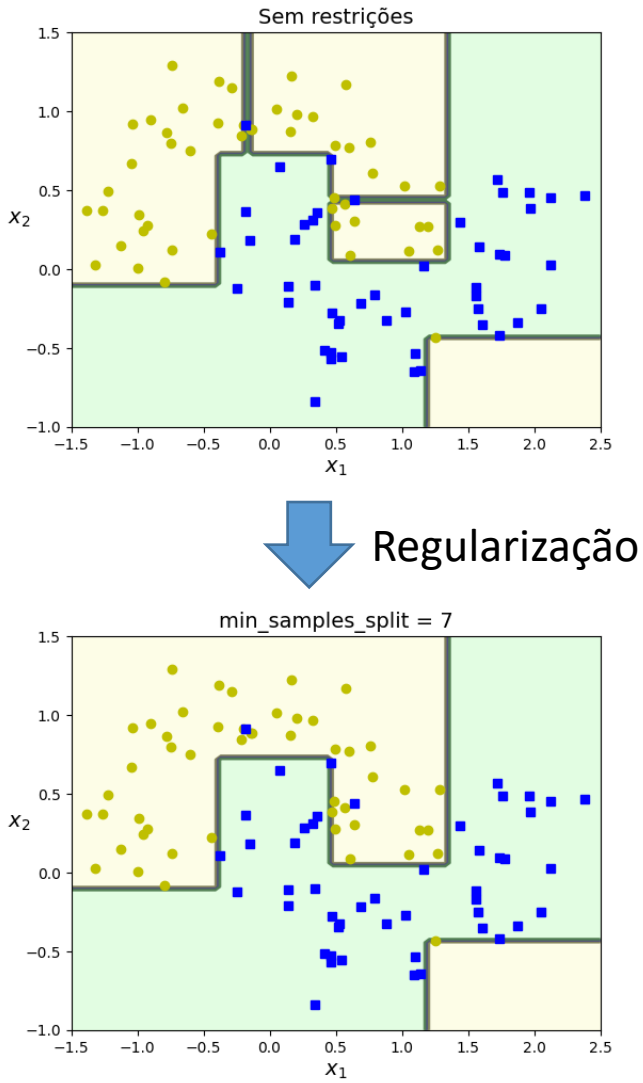


- Uma maneira de **minimizar** a sensibilidade à rotação é aplicar **PCA** aos dados.
- Ele **centraliza os dados** e **rotaciona os eixos** para as **direções de maior variância** (os componentes principais).
- Na figura, a variância máxima está na direção que separa as classes.
- Após a aplicação do PCA, um único corte vertical (i.e., nó) separa as classes.
- Podemos usar também *ensembles* e engenharia de atributos (aumentando as dimensões).

Considerações sobre as árvores de decisão

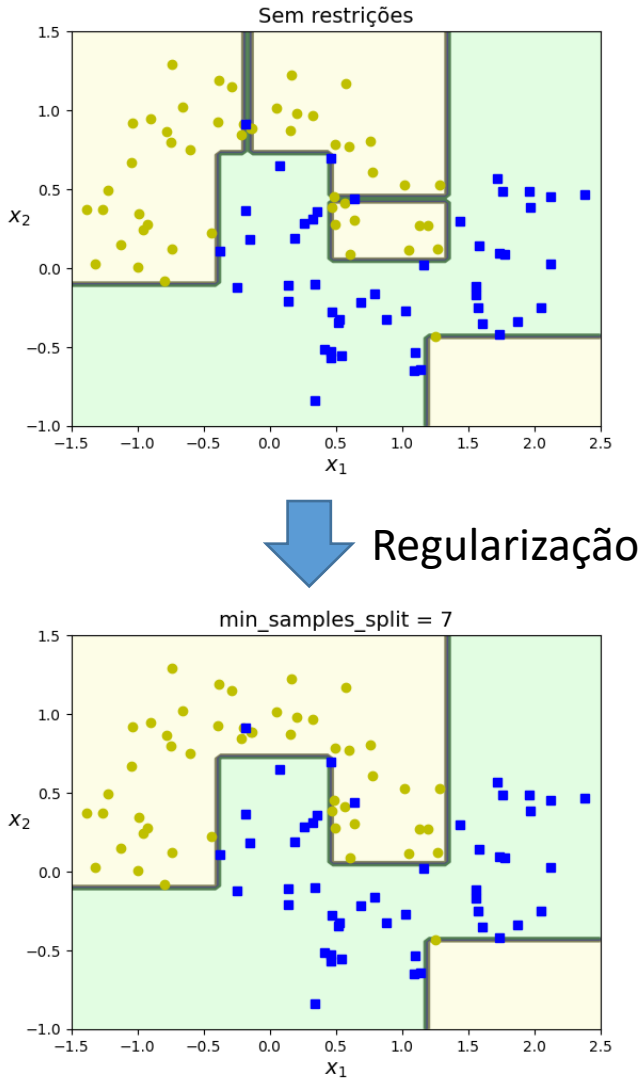
- Alguns algoritmos de indução de árvores introduzem **aleatoriedade durante o treinamento** e podem **gerar árvores diferentes** para diferentes **sementes aleatórias**.
  - Se a semente for fixa, o resultado do treinamento se torna reproduzível.
- Por exemplo, o CART **embaralha a ordem dos atributos a cada divisão**, se **vários atributos têm o mesmo valor para a métrica de escolha de um nó**, o **escolhido é o primeiro encontrado** na ordem sorteada, gerando **árvores diferentes**.
- Dependendo da configuração, o CART testa um **subconjunto aleatório de atributos** e não todos os disponíveis para definir um nó.
  - Consequência: O melhor atributo pode não estar no subconjunto sorteado.

Considerações sobre as árvores de decisão



- No CART, nós podemos minimizar o sobreajuste restringindo o crescimento da árvore ou a podando após a sua criação.
- A restrição do crescimento (regularização) pode ser feita através de alguns hiperparâmetros:
  - ***max_depth***: define a profundidade máxima (i.e., número de níveis).
  - ***min_samples_split***: define o número mínimo de amostras que um nó deve ter antes de poder ser dividido.
  - ***min_samples_leaf***: define o número mínimo de amostras que um nó folha deve ter.

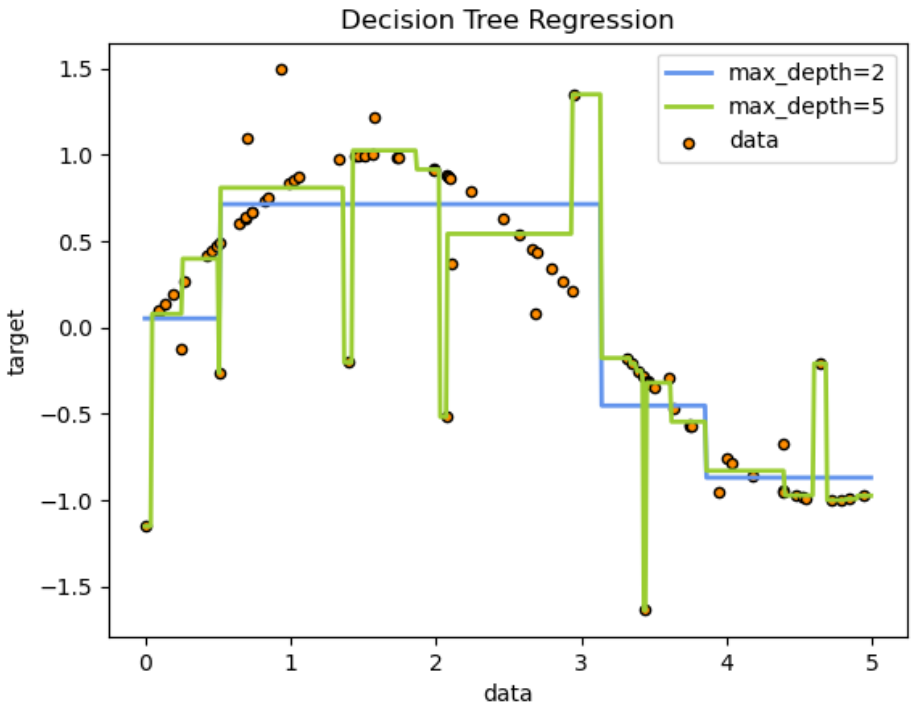
Considerações sobre as árvores de decisão



- ***max_leaf_nodes***: define o número máximo de nós folha.
- ***max_features***: define número máximo de atributos que são avaliados para criação de uma divisão (nó).

- A poda é configurada através do:
  - ***ccp_alpha***: controla o número de nós cortados. A poda é feita após a criação da árvore.
- Aumentar os valores dos hiperparâmetros ***min_**** e ***ccp_alpha*** ou reduzir os ***max_**** regularizará ou podará a árvore.
- Os melhores valores são encontrados através de otimização hiperparamétrica.

Considerações sobre as árvores de decisão

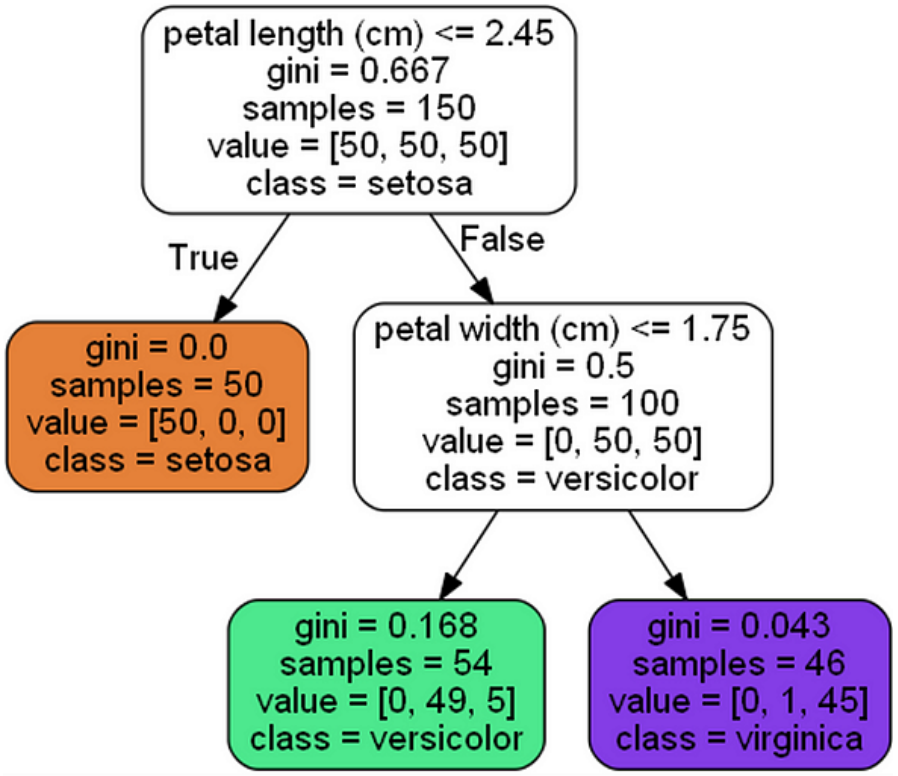


- O *Scikit-Learn* apresenta 2 classes que implementam o CART:
  - DecisionTreeClassifier
  - DecisionTreeRegressor
- **Árvores de decisão para regressão** também podem se **sobreajustar**.
- Predições feitas por **árvores de regressão não são suaves nem contínuas**, mas **aproximações constantes por trechos**, conforme a figura ao lado mostra.
  - Florestas tendem a suavizar a aproximação.
- A predição é o **valor médio** dos exemplos **em cada trecho**.

Diferenças entre ID3 e CART

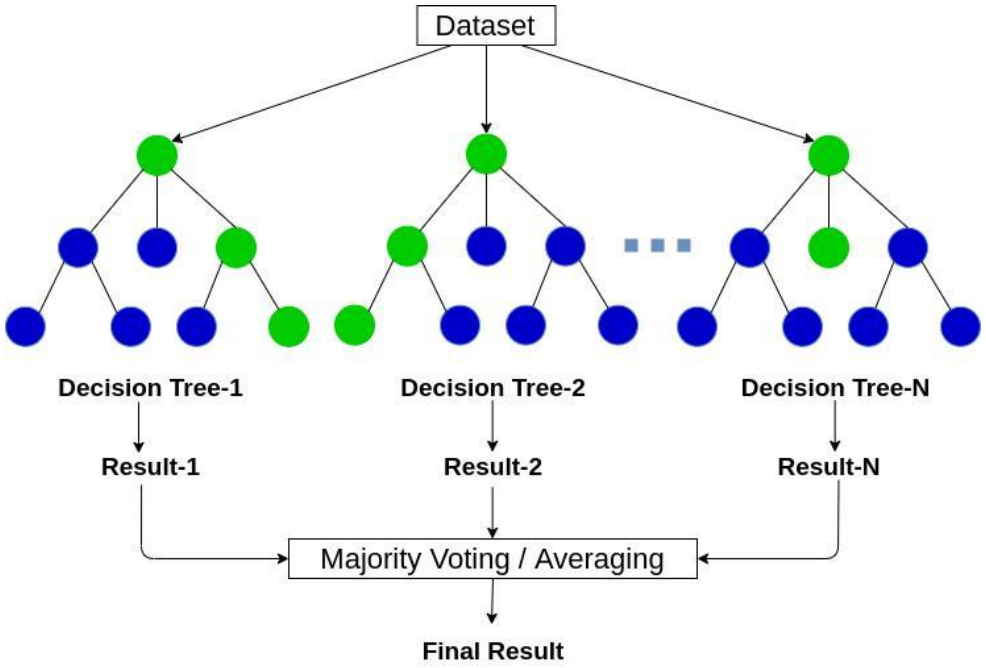
Característica	ID3	CART
Tipo de problema	Apenas classificação	Classificação & regressão
Critério de divisão	Ganho de informação	• Classificação: Gini, *log loss* e entropia • Regressão: EQM
Tipo de atributos	• Foi projetado para trabalhar com atributos categóricos. • Não lida bem com atributos contínuos, precisando discretizá-los antes.	• Lida naturalmente com atributos contínuos. • Atributos categóricos devem ser codificados antes.
Formato da árvore	• Pode gerar múltiplos ramos ▪ Ex.: Atributo Cor = {vermelho, azul, verde} → 3 ramos	• Sempre faz divisões binárias (i.e., cada nó sempre tem 2 ramos) ▪ Ex.: Cor ∈ {vermelho}? → sim/não
Repete atributo em um caminho?	Não repete atributos no mesmo caminho (raiz → folha)	• Pode repetir atributos várias vezes no mesmo caminho • A cada divisão, por padrão, todos os atributos são testados

Índice de Gini



- Além do **ganho de informação**, a **métrica da impureza**, chamada de **índice de Gini**, é bastante usada para a indução de árvores com o algoritmo CART.
- Ele mede o quão bagunçado (i.e., impuro) é um conjunto de dados.
  - Valor 0: **conjunto puro**, todas as amostras pertencem à mesma classe.
  - Valor > 0: **conjunto impuro**, as amostras pertencem a várias classes.

Florestas aleatórias (*random forests*)



- São **conjuntos de árvores**: cada uma é treinada com **um conjunto sorteado com reposição** das amostras: algumas aparecem repetidas, outras ficam de fora.
- Em cada divisão, a árvore considera apenas **alguns atributos sorteados**, e não todos.
- O resultado são **árvores diferentes entre si**, o que **reduz a variância** quando suas predições são **combinadas**.
  - Predição: **média** (regressão) ou **votação majoritária** (classificação) com as predições individuais.
- Estão entre os modelos mais fortes para dados tabulares.

Exemplo

- Exemplo: árvores_de_decisão.ipynb



Lista de exercícios

Lista #12 – Árvores de decisão

Perguntas?

Obrigado!

Anexo I: Cálculo da entropia para mais de duas classes

Cálculo da entropia para mais de duas classes

- Veja a tabela ao lado com os exemplos de treinamento.
- Problema com três classes: 0, 1, e 2. Portanto, o cálculo da entropia terá três termos.
- A ***entropia*** do objetivo, i.e., y, para o conjunto de treinamento é

$$H(y) = -\left[\frac{2}{4}\log_2\left(\frac{2}{4}\right) + \left(\frac{1}{4}\right)\log_2\left(\frac{1}{4}\right) + \left(\frac{1}{4}\right)\log_2\left(\frac{1}{4}\right)\right] = 1.5$$

- Separando os atributos em tabelas separadas, temos

		Classes (y)			
		0	1	2	
x1	0	1	0	0	1
	1	0	0	1	1
	2	1	1	0	2
					4

		Classes (y)			
		0	1	2	
x2	0	2	0	0	2
	1	0	1	1	2
					4

- O ***ganho de informação*** de cada atributo é calculado como:

$$Gain(\boldsymbol{x1}) = H(y) - \left\{\frac{1}{4}H(x1=0) + \frac{1}{4}H(x1=1) + \frac{2}{4}H(x1=2)\right\}$$

$$Gain(\boldsymbol{x2}) = H(y) - \left\{\frac{2}{4}H(x2=0) + \frac{2}{4}H(x2=1)\right\}$$

Atributos		Rótulos
x1	**x2**	**Classe (y)**
0	0	0
2	1	1
1	1	2
3	0	0

Cálculo da entropia para mais de duas classes

Obs.:
- $H(0) = 0$
- $H(1) = 0$
- $0 * \log_2(0) = 0$

Como exemplo do cálculo da entropia, vejamos como $H(x1 = 0)$ deve ser calculado.

$$H(x1 = 0) = -\sum_{i=0}^{2} p(y = i|x1 = 0)\log_2\big(p(y = i|x1 = 0)\big)$$

$$= -\big[p(y = 0|x1 = 0)\log_2\big(p(y = 0|x1 = 0)\big) + p(y = 1|x1 = 0)\log_2\big(p(y = 1|x1 = 0)\big) + p(y = 2|x1 = 0)\log_2(p(y = 2|x1 = 0))\big]$$

Assim, os ganhos de informação para $x1$ e $x2$ são calculados como

$$Gain(x1) = H(y) - \left\{\frac{1}{4}H(x1 = 0) + \frac{1}{4}H(x1 = 1) + \frac{2}{4}H(x1 = 2)\right\}$$

$$= H(y) - \left\{\frac{1}{4}\left[\frac{1}{1}\log_2\left(\frac{1}{1}\right)\right] + \frac{1}{4}\left[\frac{1}{1}\log_2\left(\frac{1}{1}\right)\right] + \frac{2}{4}\left[\frac{1}{2}\log_2\left(\frac{1}{2}\right) + \frac{1}{2}\log_2\left(\frac{1}{2}\right)\right]\right\}$$

$$Gain(x2) = H(y) - \left\{\frac{2}{4}H(x2 = 0) + \frac{2}{4}H(x2 = 1)\right\}$$

$$= H(y) - \left\{\frac{2}{4}\left[\frac{2}{2}\log_2\left(\frac{2}{2}\right)\right] + \frac{2}{4}\left[\frac{1}{2}\log_2\left(\frac{1}{2}\right) + \frac{1}{2}\log_2\left(\frac{1}{2}\right)\right]\right\}$$

		Classes (y)			
		0	1	2	
x1	0	1	0	0	1
	1	0	0	1	1
	2	1	1	0	2
					4

		Classes (y)			
		0	1	2	
x2	0	2	0	0	2
	1	0	1	1	2
					4

Anexo II: Qual a entropia de 0?

Qual a entropia de 0?

- À primeira vista, pode parecer que $-x\log_2(x)$ para $x = 0$ é um valor indeterminado, pois resulta em $0 \times -\infty$. Porém, se fizermos uma pequena modificação na equação:

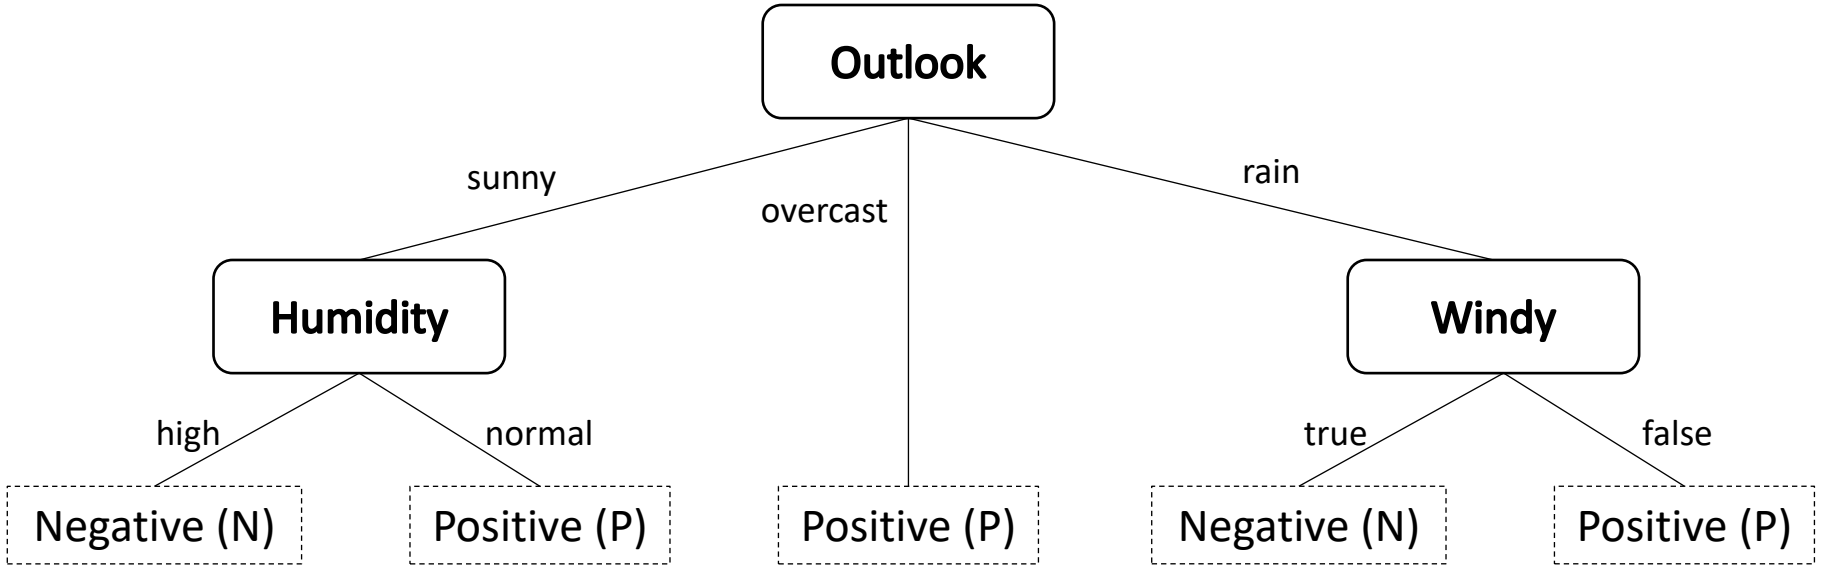
$$H(x) = -x\log_2(x) = -\frac{\log_2(x)}{\frac{1}{x}},$$

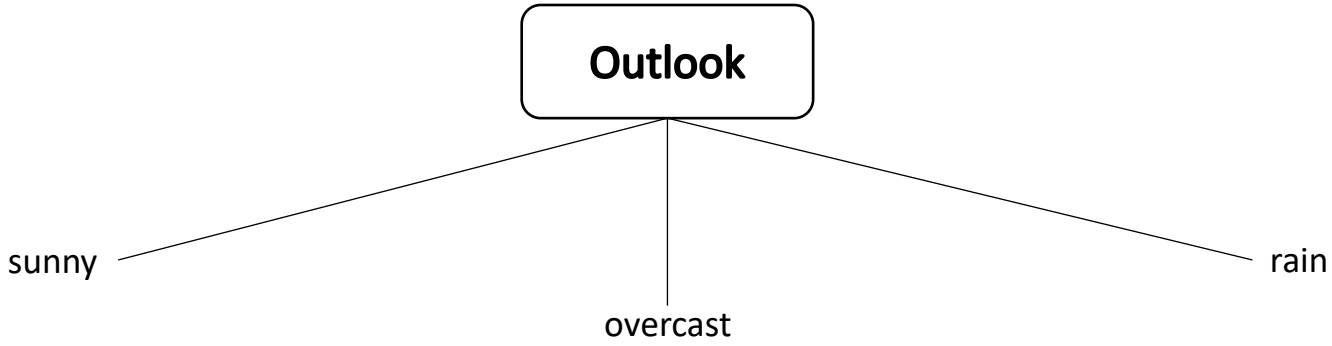
e, na sequência, aplicarmos a regra de L'Hôpital, conseguimos encontrar o valor quando x se aproxima de zero do lado positivo (0_+):

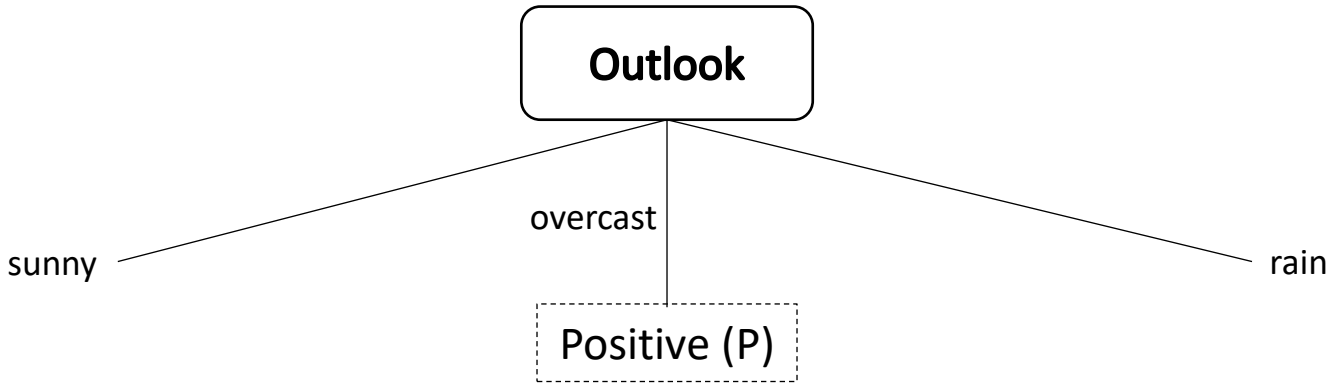
$$\lim_{x\to 0_+} H(x) = \lim_{x\to 0_+} -\frac{\frac{1}{x\log_2(2)}}{-\frac{1}{x^2}} = \lim_{x\to 0_+} \frac{x}{\log_2(2)} = 0.$$

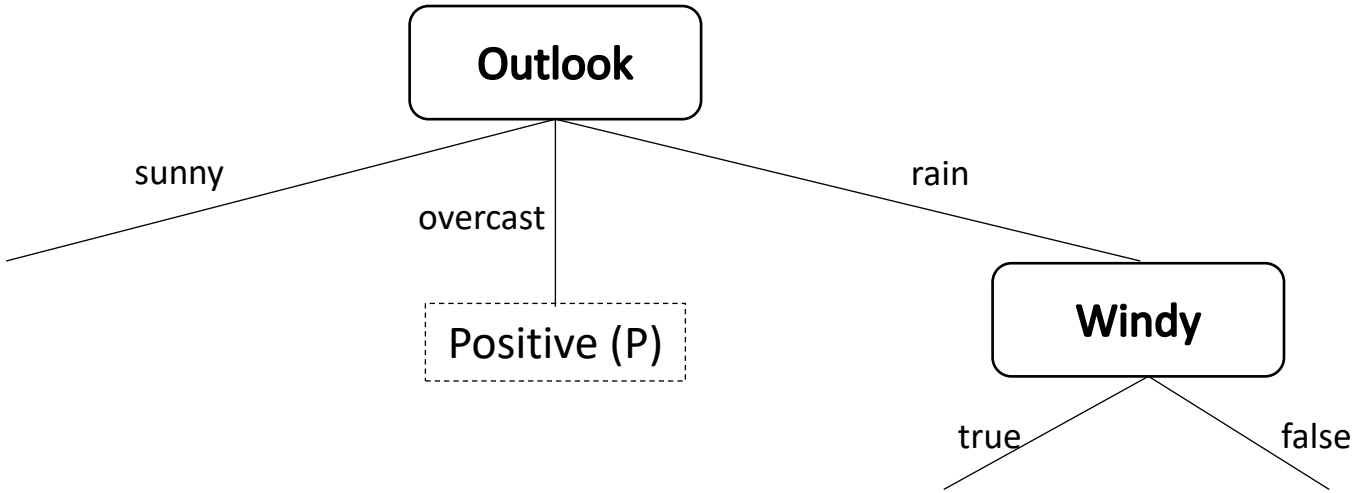
Assim, $H(x) = 0$.

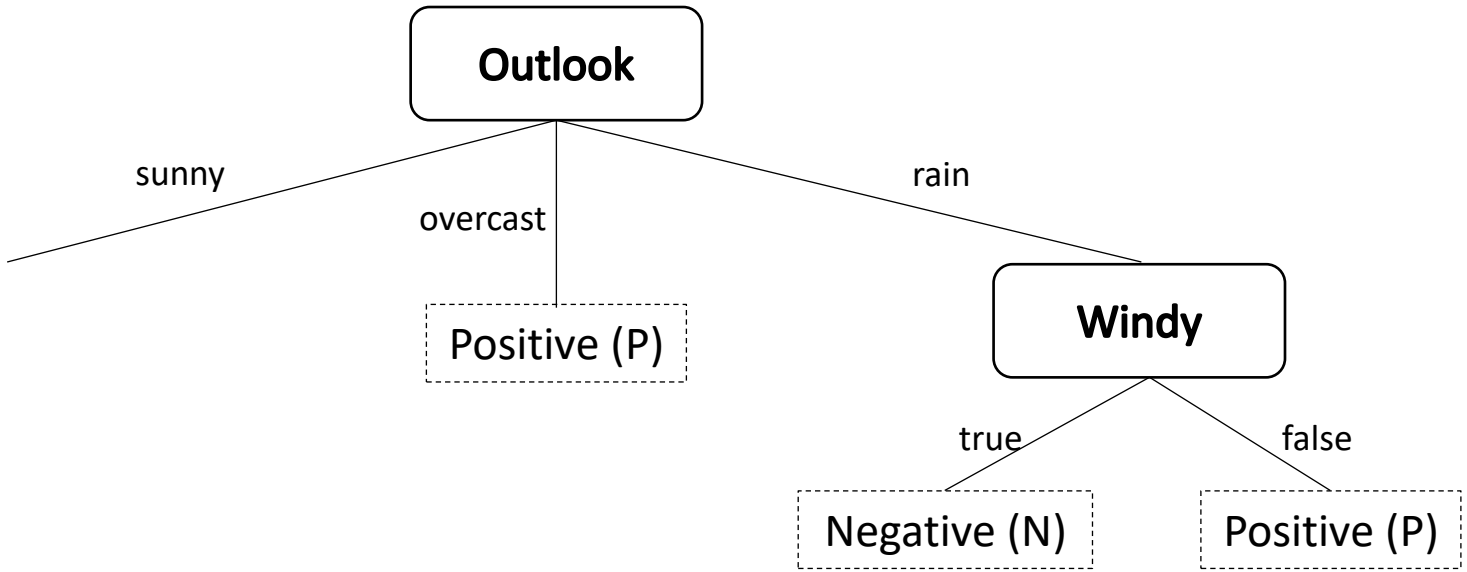
Figuras

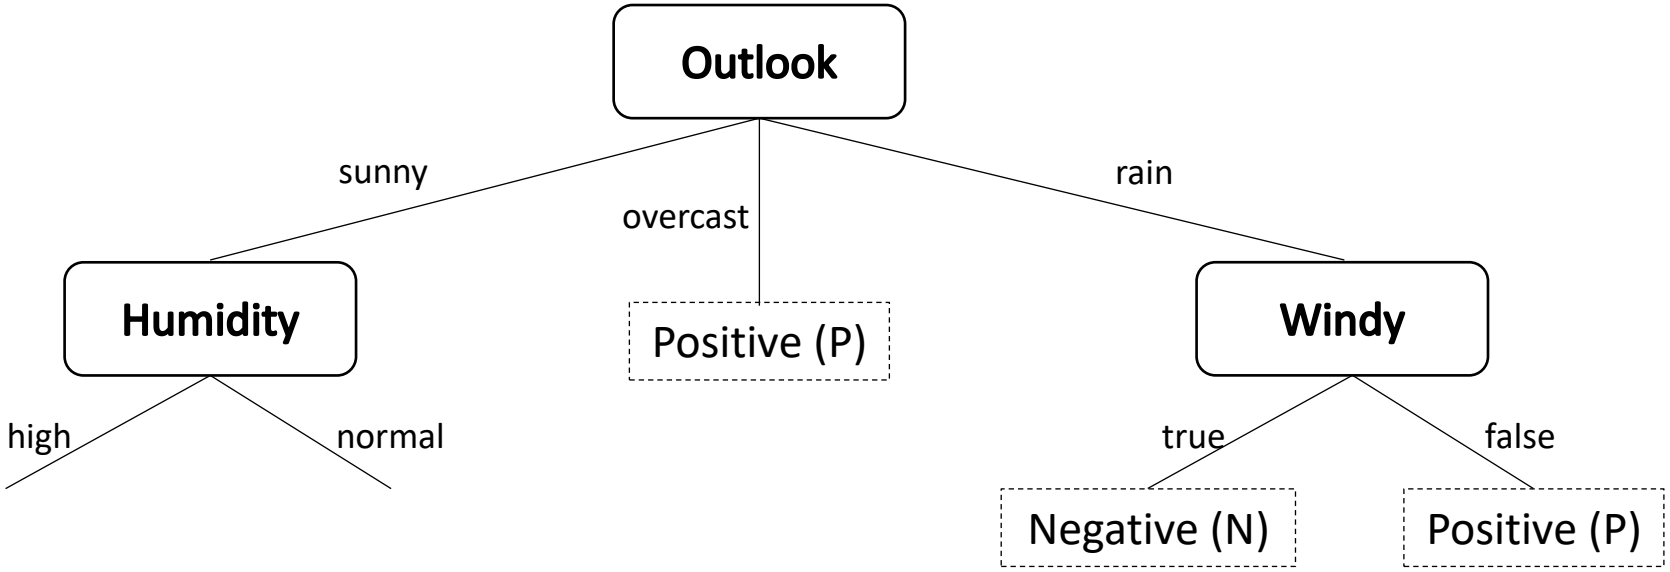

Outlook
sunny
overcast
rain
Humidity
Windy
high
normal
true
false
Negative (N)
Positive (P)
Positive (P)
Negative (N)
Positive (P)

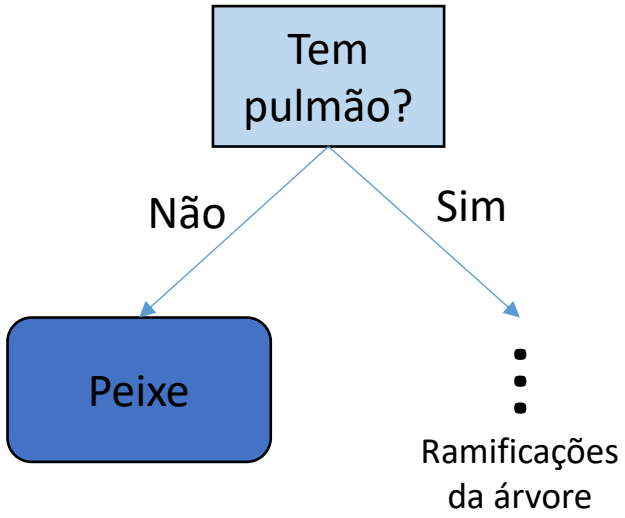

Outlook
sunny
overcast
rain

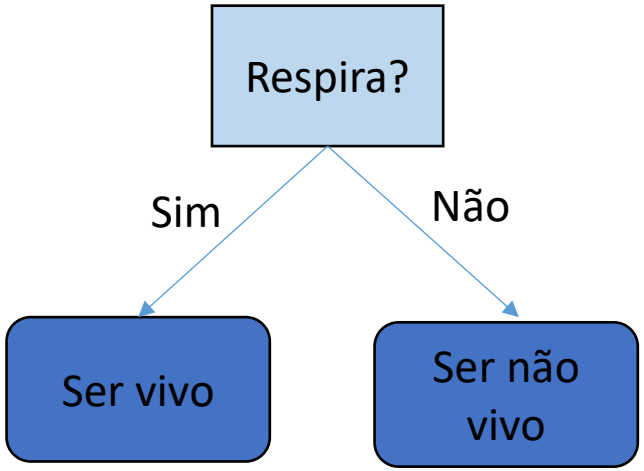

Outlook
sunny
overcast
rain
Positive (P)

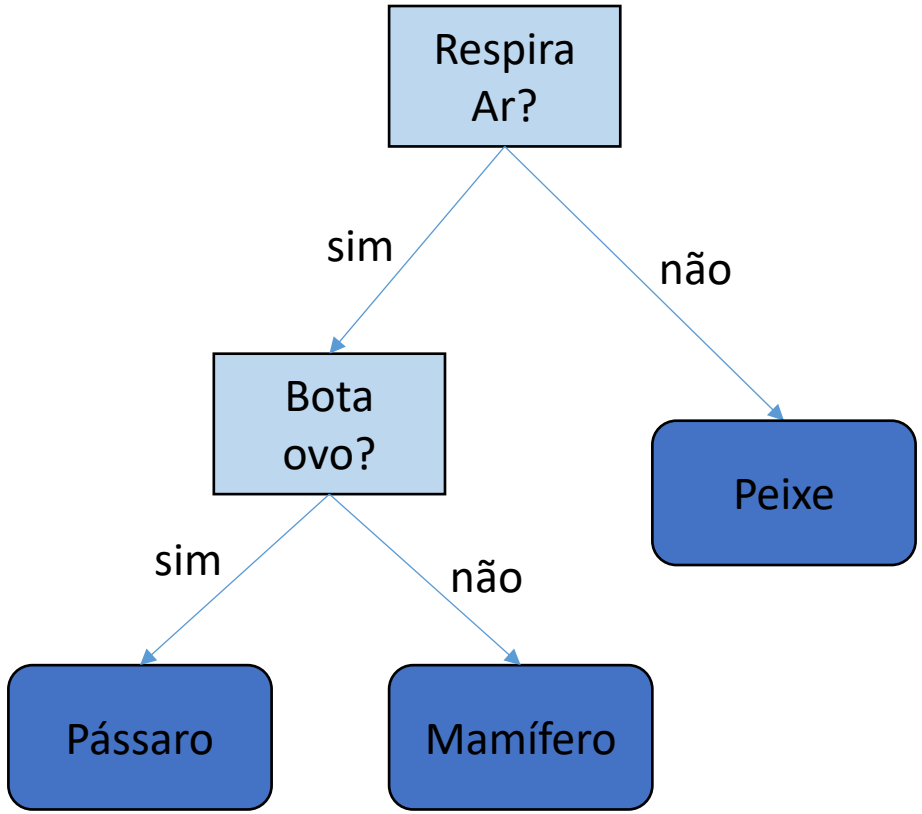

Outlook
sunny
overcast
rain
Positive (P)
Windy
true
false

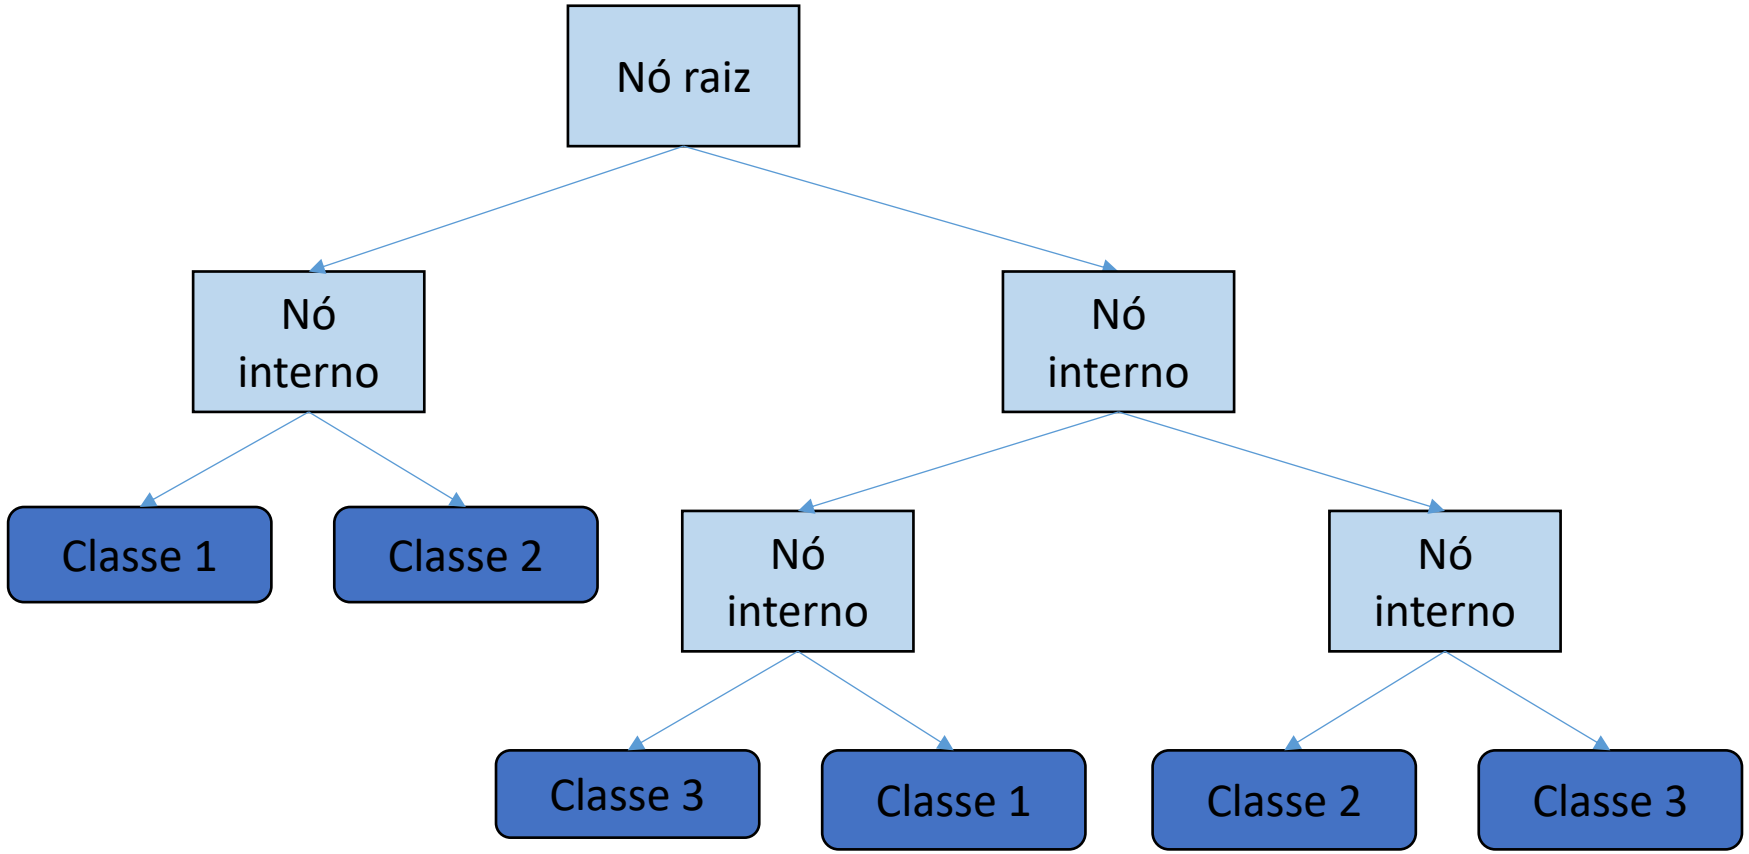

Outlook
sunny
overcast
rain
Positive (P)
Windy
true
false
Negative (N)
Positive (P)


Outlook
sunny
overcast
rain
Humidity
Positive (P)
Windy
high
normal
true
false
Negative (N)
Positive (P)


Tem pulmão?
Não
Sim
Peixe
Ramificações da árvore


Respira?
Sim
Não
Ser vivo
Ser não vivo


Respira Ar?
sim
não
Bota ovo?
Peixe
sim
não
Pássaro
Mamífero


Nó raiz
Nó interno
Nó interno
Classe 1
Classe 2
Nó interno
Nó interno
Classe 3
Classe 1
Classe 2
Classe 3