



C24 – Inteligência Artificial: *Árvores de decisão*






Árvores de decisão

Elements of a decision tree




- **Árvores de decisão** (do inglês, *decision trees*), são modelos de
 - **aprendizado supervisionado** **não-paramétrico**
 - e **não-lineares**.
- Elas podem ser utilizadas tanto para **classificação** quanto para **regressão**.



Árvores de decisão
podem ser interpretadas
como **estruturas de
controle de fluxo**.

O que significa ser paramétrico?


Elements of a decision tree



- Um modelo **paramétrico**:
 - assume uma **forma funcional fixa**.
 - Uma **equação** como no caso da regressão linear.
 - possui um **número fixo de parâmetros**.
 - Por exemplo, na **regressão linear**, a **quantidade de pesos** de uma **função hipótese é constante**.
 - Complexidade constante.
 - Não varia com a quantidade de dados.
 - Alguns modelos fazem suposições sobre a distribuição dos dados.
 - **Naive Bayes**: dependendo da versão, assume distribuições normal, multinomial ou Bernoulli.
 - **Gaussian Mixture Models (GMMs)**: assume que os dados vêm de uma mistura de gaussianas.

O que significa ser não-paramétrico?


Elements of a decision tree



- Um modelo **não-paramétrico**:
 - **não** assume forma funcional fixa
 - Não tem uma equação como no caso da regressão linear.
 - **não** fixa o número de parâmetros
 - a complexidade do modelo não é fixa a priori.
 - a **complexidade depende dos dados**
 - Sua complexidade (número de parâmetros) aumenta à medida que os dados crescem
 - Ou seja, a estrutura do modelo cresce dinamicamente
 - fazem **menos suposições fortes** sobre a distribuição dos dados.


O que significa ser não-paramétrico?

Elements of a decision tree



- Os **parâmetros** são **criados durante o treinamento** para explicar os dados.
- O **tamanho da árvore**, i.e., o número de parâmetros, tende a **crescer** com o **tamanho da base de dados**.
- O **número de parâmetros não é determinado antes do treinamento**, de modo que a **árvore é livre para se adaptar** aos dados de treinamento.


O que significa ser não-linear?



- As **funções aproximadora e discriminante são funções não-lineares**, i.e., os dados **não são** aproximados ou separados por **hiperplanos**.
- Cada nó faz um “**corte**” no espaço de **atributos**.
 - Os cortes são **paralelos aos eixos** do espaço de atributos.
- A **combinação** desses cortes **gera uma função** altamente **não-linear**, conforme mostrado na figura ao lado.


Qual o objetivo de uma árvore de decisão?

Árvores de decisão




- O objetivo é criar um modelo que realize previsões aprendendo **regras simples de decisão inferidas** a partir dos **atributos do conjunto de treinamento**.
- As árvores são compostas por
 - um nó raiz: **primeiro nó da árvore**.
 - realiza a **primeira divisão dos dados** (*split*)
 - nós de decisão
 - representam **testes/condições**
 - **dividem os dados em subconjuntos** menores
 - ramificações
 - representam o **resultado de uma condição**
 - e (nós) folhas
 - representam a **predição final**

Árvores de decisão




- As **árvores de decisão** são os componentes fundamentais das **florestas aleatórias** (do inglês, *random forests*) que estão entre os **algoritmos mais robustos e populares** para **dados tabulares**.
- **Florestas aleatórias** são compostas por **várias pequenas árvores** treinadas com subconjuntos aleatórios dos dados.
- As **predições combinam suas respostas** através de **média** (regressão) ou **votação** (classificação).

Árvores de decisão




- Formalmente, uma árvore é um **grafo direcionado acíclico** (sem realimentação) no qual **dois nós quaisquer se conectam por um único caminho**.
 - Um ciclo é um caminho em que o primeiro e o último nó coincidem.
- Por exemplo, na árvore ao lado, o **nó “Pássaro”** só se conecta ao **nó “Mamífero”** através do **nó “Bota ovo?”** e **não existem ciclos**.
- É **direcionado**, pois a informação percorre a árvore do **topo para baixo**.

Árvores de decisão



- O processo de decisão se **inicia** pelo **nó raiz**.
- Nesse processo, **valores distintos dos atributos geram ramificações (nós de decisão)** e, quando se chega a um **nó folha**, ocorre a **atribuição de uma classe ou valor**.


Árvores de decisão



- **Árvores de decisão** são modelos de **caixa branca**.
- Ou seja, é possível **entender e explicar facilmente como o modelo realiza a predição** (classificação ou regressão) baseando-se nos atributos.
- Elas são o oposto dos modelos de **caixa preta**, onde os **resultados são difíceis de interpretar** e **não é fácil entender como os atributos interagem entre si para gerar a saída**.
 - Redes neurais artificiais são exemplos de modelos de caixa preta.


Árvores de decisão

- A figura abaixo mostra uma **árvore de decisão para classificação** criada a partir de informações se **jogadores jogarão tênis ou não** dependendo dos valores dos atributos **Clima, Humidade e Vento**.
- Cada **nó da árvore atua como um caso de teste** para algum atributo, e cada terminação ou folha, corresponde a uma classe.




Árvores de decisão

- Na figura, cada atributo leva a uma ramificação até que se atinja um nó folha, onde decide-se sobre jogar ou não.
- O **uso da árvore para classificar padrões é direto**, mas é preciso responder uma questão crucial: **como induzir uma árvore de decisão a partir dos dados de treinamento?**



O processo de indução de uma árvore de decisão

- Uma primeira abordagem para induzir uma árvore poderia ser **construir, de maneira exaustiva, todas as árvores capazes de resolver o problema** da classificação ou regressão e **selecionar a mais simples** (menos complexa) utilizando a **regra da navalha de Occam**.
- Entretanto, essa abordagem pode ser **computacionalmente muito custosa**.




O processo de indução de uma árvore de decisão


- Encontrar uma árvore de decisão ótima é um problema de **tempo polinomial não-determinístico completo** (NP-completo).
- Esses são problemas onde **conferir uma solução é fácil**, **mas descobrir a resposta é extremamente difícil**.
- Exemplo: O problema do caixeiro viajante.
 - Objetivo: Encontrar o **menor caminho que visite todas as cidades**.
 - Se alguém te dá um caminho: $A \rightarrow B \rightarrow C \rightarrow D \rightarrow A$
 - ✓ Nós só precisamos somar as distâncias para conferir a solução (rápido).
 - Mas encontrar o melhor caminho entre todos os possíveis:
 - ✓ 5 cidades $\rightarrow$ já são muitas combinações
 - ✓ 20 cidades $\rightarrow$ número gigantesco
 - ✓ O problema cresce exponencialmente.

O processo de indução de uma árvore de decisão

- Como a indução de árvores é um **problema NP-completo**, em geral, usa-se **abordagens heurísticas** para induzir árvores de decisão.
 - **Heurística: regra prática** que guia a busca por boas soluções, mas **não garante a melhor solução** possível.
- As **heurísticas** mais conhecidas são: **ID3**, C4.5, C5.0 e **CART (scikit-learn)**.




O processo de indução de uma árvore de decisão



- Um dos métodos **heurísticos** de indução de árvores de decisão mais conhecidos é o **ID3** (do inglês, **I**terative **D**ichotomiser **3**).
- Ele foi desenvolvido **especificamente para classificação**, não para regressão.
 - O CART suporta regressão e classificação.
- **Dicotomização iterativa** significa **dividir-se sucessivamente o conjunto de dados**.

O processo de indução de uma árvore de decisão



- O método constrói a árvore iterativamente:
 - escolhe um atributo que **melhor separa os dados**
 - divide os dados
 - repete o processo nos subconjuntos.
- O **método ID3** é uma abordagem que **não garante** a obtenção da **menor árvore possível**, mas busca obter **árvores apropriadas num intervalo de tempo relativamente curto**.


O processo de indução de uma árvore de decisão

- O ID3 usa uma **estratégia gananciosa**.
 - Sempre escolhe o **melhor atributo localmente**
 - Qual atributo separa melhor os dados AGORA?
 - Ele **não reconsidera** decisões **anteriores** e não testa **combinações futuras**
 - Não garante solução ótima global.
 - Escolher o melhor atributo agora **não garante o melhor resultado final**
- É **top-down**.
 - Começa do nó raiz e vai descendo.
 - Ou seja, a árvore é **criada de cima para baixo** e um **nó é definido** selecionando-se o **atributo que melhor divide o conjunto de dados naquela iteração**.

O processo de indução de uma árvore de decisão


- Como se decide (métrica) **qual é o melhor atributo?**
 - O ID3 se baseia na **teoria da informação** para selecionar o melhor atributo de cada nó da árvore.
- A ideia central do **método ID3** é construir uma árvore escolhendo, a cada passo, o **atributo que mais reduz a incerteza dos dados**.
- Ou seja, a cada passo, escolhe-se como **nó** o **atributo que for o mais longe possível em dividir os exemplos nas classes corretas**.

O processo de indução de uma árvore de decisão




- No caso da classificação, um **atributo perfeito** divide perfeitamente todos os exemplos em suas respectivas classes.
- Ou seja, é o atributo que consegue **explicar perfeitamente o conjunto de dados**.
- Por exemplo, o atributo **Windy** divide as amostras em duas classes perfeitamente.

O processo de indução de uma árvore de decisão




- Então, tudo o que precisamos é uma medida formal de **atributo razoavelmente bom** ou **realmente inútil**.
- O **ID3** utiliza a noção de **ganho de informação**, o qual é **definido em termos da entropia**, que é uma quantidade fundamental em **teoria da informação**.
- A seguir, veremos alguns conceitos úteis para que possamos usar o **método ID3** para inferir árvores de decisão.

Ganho de informação




- É uma **propriedade estatística** que **mede o quão bem um determinado atributo separa os exemplos** de treinamento de acordo com suas classes.
- Portanto, construir uma **árvore de decisão** tem tudo a ver com encontrar, para cada nó, **um atributo que retorne o maior ganho de informação**.

Entropia



- É uma medida da **quantidade de incerteza ou aleatoriedade** de uma variável aleatória.
 - No nosso caso, a **aleatoriedade** do conjunto de dados.
- Ela mede o quão “bagunçado” está o conjunto de dados.
 - Alta entropia → dados misturados
 - Baixa entropia → dados “puros”
 - Se todos são da mesma classe → entropia = 0

Entropia



- Portanto, **um ganho de informação** corresponde a uma **redução na entropia**.
- Em outras palavras, ele **mede o quanto um atributo reduz a incerteza** (“bagunça”).
- Quando **ganhamos informação** sobre o conjunto, a **incerteza diminui**.
- Portanto, o **ganho** mede o **quanto conseguimos explicar do conjunto** com um dado atributo.

Entropia

- O **ganho de informação** dá a **diferença entre a entropia antes e depois da divisão do conjunto de dados** com base nos valores de um determinado atributo.

- Assim, podemos escrever que o **ganho de informação** é dado por

Ganho de informação = entropiaAntesDaDivisão – entropiaApósADivisão.


- Ela mede o quanto a incerteza sobre y diminui após conhecermos x

$$\text{Ganho de informação} = H(y) - H(y|x),$$

ou seja, o quanto conhecimento sobre x reduz a incerteza sobre y .


- Vejamos alguns exemplos de como a entropia é calculada.

Exemplo de entropia




- Uma variável com apenas um único valor **não tem nenhuma incerteza** associada.
 - Por exemplo, o arremesso de uma moeda com **cara** em ambos os lados.
- Portanto, sua **entropia é igual a zero**.
- Isso significa que **não se ganha nenhuma informação nova ao se observar o valor de um arremesso**.

Exemplo de entropia




- Por outro lado, o resultado de se arremessar uma **moeda honesta** é igualmente provável de resultar em **cara** ou **coroa**, os quais são associados aos valores 0 ou 1, respectivamente.
- Neste caso, esta variável tem **1 bit de entropia**, significando que se necessita de 1 bit para representar os 2 possíveis resultados.

Exemplo de entropia



- Dessa forma, a variável aleatória que representa o resultado de se rolar um **dado honesto de 4 lados, tem 2 bits de entropia**, pois necessita-se de 2 bits para se representar os 4 possíveis valores.
- Agora imaginem um **moeda desonesta** que tenha uma probabilidade de resultar em **cara** em 99% dos arremessos.
- Nesse caso, a **entropia** deve ser um **valor positivo muito próximo de zero**, pois a incerteza do resultado é muito baixa.

Cálculo da entropia



- Assim, a **entropia** de uma variável aleatória discreta, V , com valores v_i , onde cada um dos valores tem probabilidade $P(v_i)$, é definida como

$$H(V) = -\sum_i P(v_i) \log_2(P(v_i)).$$

- Agora retornamos ao problema da indução de **árvores de decisão**.

Indução de uma árvore de decisão

- Se um conjunto de treinamento, E , contém p exemplos pertencentes à classe positiva (P) e n exemplos pertencentes à classe negativa (N), então a **entropia do objetivo** (i.e., do rótulo) para **todo** o conjunto de treinamento é dada por

$$\begin{aligned} H(\text{Goal}) &= B\left(\frac{p}{p+n}\right) \\ &= -\left[\frac{p}{p+n} \log_2\left(\frac{p}{p+n}\right) + \left(1 - \frac{p}{p+n}\right) \log_2\left(1 - \frac{p}{p+n}\right)\right]. \end{aligned}$$

- Assim, $B\left(\frac{p}{p+n}\right)$ é a **entropia de uma variável booleana** que é positiva com probabilidade igual a $\frac{p}{p+n}$.

Indução de uma árvore de decisão

- Um atributo, x_k , pode **reduzir toda ou apenas parte** da **incerteza (entropia) do objetivo**, $H(Goal)$.
- Nós podemos medir o **quanto cada atributo contribui para a entropia do objetivo** através do cálculo da **entropia restante após o teste do atributo**.
- Para o cálculo da **entropia restante**, precisamos definir que:
- Um **atributo x_k com d valores distintos divide o conjunto de treinamento E em d subconjuntos: $E_1, \dots, E_d$** .
- Cada subconjunto $E_i, i \in \{1, \dots, d\}$, possui $p_i, i \in \{1, \dots, d\}$, exemplos da classe positiva, P , e $n_i, i \in \{1, \dots, d\}$, exemplos da classe negativa, N .

Indução de uma árvore de decisão

- Um exemplo escolhido aleatoriamente do conjunto de treinamento tem probabilidade igual a $(p_i + n_i)/(p + n)$ de pertencer ao i -ésimo subconjunto, E_i , do atributo x_k .

- Assim, a **entropia restante** após o teste do atributo x_k é dada por

$$Remainder(x_k) = \sum_{i=1}^d \frac{p_i + n_i}{p + n} B \left(\frac{p_i}{p_i + n_i} \right).$$

- Ela é a **entropia média restante** após o teste do atributo, x_k .
- Ou seja, ela é a **medida da incerteza que sobra depois do teste do atributo**.


Indução de uma árvore de decisão

- Assim, o **ganho de informação** com o atributo x_k é a **redução na entropia do objetivo**, que é dado por

$$Gain(x_k) = B\left(\frac{p}{p+n}\right) - Remainder(x_k) \geq 0.$$

- O menor valor de $Gain(x_k)$ é 0, pois x_k pode **explicar toda a incerteza do conjunto**.
- Ou seja, x_k é **responsável por toda a bagunça** do conjunto de dados.

Método ID3




- A ideia central do **método ID3** é selecionar, **em cada etapa**, o **atributo x_k que maximiza o ganho de informação**.
- Esse **atributo** é usado para **dividir o conjunto de treinamento** em **subconjuntos**.
- O processo é **repetido recursivamente usando-se os demais atributos** até a construção completa da árvore de decisão.

Sequência de passos do método ID3

- a) Cálculo da **entropia do objetivo** para o (sub)conjunto de treinamento **corrente**.
 - **OBS.:** o (sub)conjunto é alterado a cada nova iteração do método de acordo com o(s) atributo(s) sendo testado(s).
- b) Cálculo do **ganho de informação** de cada atributo $x_k, k = 1, \dots, K$ do conjunto de treinamento, E .
- c) Criação de um nó com o atributo que maximizou o **ganho de informação**.
- d) **Particionamento do (sub)conjunto em subconjuntos** usando o atributo x_k para o qual o **ganho de informação** resultante após a divisão é maximizado.
- e) Repetir os itens a) até d) em **subconjuntos de treinamento** usando os atributos restantes. Essa sequência **continua até que a árvore classifique perfeitamente todos os exemplos de treinamento** ou **até que todos os atributos tenham sido utilizados**.

Sequência de passos do método ID3




- O **ID3** segue a regra:
 - um **ramo** com uma **entropia igual a zero** é uma **folha**
 - e um **ramo** com **entropia maior do que zero** **precisa de partição adicional**.
- O **método ID3** será exemplificado através do exemplo apresentado em breve.

Características do método ID3


- Ele é aplicado apenas a problemas de classificação.
 - Foi projetado para **variáveis alvo (rótulo) categóricas**.
- Pode **sobreajustar** aos dados de treinamento
 - Para evitar o sobreajuste (**árvore muito grande**), árvores de decisão menores devem ser preferidas ao invés das maiores.
- O método ID3 geralmente produz árvores pequenas, **mas nem sempre produz a menor árvore possível**.
- **Ideal para atributos categóricos**.
 - Apresenta dificuldade com atributos contínuos (precisa de discretização).
- Atributos contínuos **aumentam significativamente o número de possíveis pontos de divisão** e a busca pelo melhor ponto de divisão pode se tornar demorada.

Observações




- Além do **ganho de informação**, existem outras métricas que podem ser usadas para a indução.
- Uma possibilidade é usar uma **métrica de impureza**, como o **índice de Gini**.
 - Usado no método *Classification and Regression Trees* (CART) implementado pela biblioteca SciKit-Learn.
- Mede o quão bagunçado (i.e., impuro) é um conjunto de dados.
 - Valor 1: **conjunto puro**, todas as amostras pertencem a uma mesma classe.
 - Valor 0: **conjunto totalmente impuro**, as amostras pertencem a classes diferentes.

Observações



- Outro ponto importante é que as árvores são, em geral, **sensíveis a dados faltantes**.
- Assim, se for o caso, deve-se buscar metodologias para se **lidar com atributos com valores faltantes**.
- Existem várias soluções, como por exemplo:
 - Remover exemplos incompletos.
 - Atribuir ao atributo a média de seus valores.
 - E outros que vimos antes.

Observações




- Um conjunto que contenha inconsistências, como, por exemplo, **dois exemplos com os mesmos valores de atributos, porém classes diferentes**, precisará ser reconsiderado, pois os atributos atuais podem **não ser suficientes para a classificação**, precisando de mais atributos.

Observações

- Um problema muito comum das **árvores de decisão** é o **sobreaajuste**.
- Que pode ocorrer quando se tem
 - um número muito grande de atributos,
 - poucos dados,
 - árvores muito profundas,
 - e ruído nos dados
- Algumas formas para se minimizar o problema:
 - Coletar mais dados
 - Limitar a profundidade da árvore
 - Podar as árvores de decisão (***tree pruning***).
 - Ou utilizar **florestas aleatórias**.
 - Florestas reduzem a variância ao combinar várias árvores.


Exemplo de indução de uma árvore de decisão com o método ID3

Exemplo de indução com método ID3



- Vamos construir uma árvore de decisão para **predizer se jogadores irão ou não praticar um determinado esporte** baseado em algumas **condições meteorológicas**.
- Vamos considerar um conjunto de dados da forma (x_i, d_i) , onde x_i é um vetor de atributos e d_i é um rótulo correspondente ao vetor de atributos.
- Nesse conjunto, cada entrada diz respeito à condição meteorológica de um dia e se os jogadores jogaram ou não.

Exemplo de indução com método ID3



- Existem **quatro** atributos **categóricos**:
 - **Tempo**: {ensolarado, nublado, chuvoso}
 - **Temperatura**: {frio, agradável, quente}
 - **Umidade**: {alta, normal}
 - **Vento**: {presente, ausente}
- Os rótulos são dois (problema binário): **positivo** (P), i.e., jogar, e **negativo** (N), i.e., não jogar.
- Um exemplo de condição meteorológica de um determinado dia poderia ser descrito por:

{nublado, frio, normal, ausente}

Exemplo de indução com método ID3

- O conjunto de treinamento do exemplo é dado pela tabela abaixo.

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
1	sunny	hot	high	false	N
2	sunny	hot	high	true	N
3	overcast	hot	high	false	P
4	rain	mild	high	false	P
5	rain	cool	normal	false	P
6	rain	cool	normal	true	N
7	overcast	cool	normal	true	P
8	sunny	mild	high	false	N
9	sunny	cool	normal	false	P
10	rain	mild	normal	false	P
11	sunny	mild	normal	true	P
12	overcast	mild	high	true	P
13	overcast	hot	normal	false	P
14	rain	mild	high	true	N

Exemplo de indução com método ID3

- A **entropia do objetivo**, i.e., y , para todo o conjunto de treinamento é

$$H(y) = - \left[\frac{9}{14} \log_2 \left(\frac{9}{14} \right) + \left(1 - \frac{9}{14} \right) \log_2 \left(1 - \frac{9}{14} \right) \right] = 0.9403.$$

- Encontrando o nó raiz: o **ganho de informação** de cada atributo é calculado como

		Jogar?		
		P	N	
Outlook	sunny	2	3	5
	overcast	4	0	4
	rain	3	2	5
				14

		Jogar?		
		P	N	
Temperature	hot	2	2	4
	mild	4	2	6
	cool	3	1	4
				14

		Jogar?		
		P	N	
Humidity	high	3	4	7
	normal	6	1	7
				14

		Jogar?		
		P	N	
Windy	true	3	3	6
	false	6	2	8
				14


$$Gain(\mathbf{Outlook}) = 0.9403 - \left[\frac{5}{14} B\left(\frac{2}{5}\right) + \frac{4}{14} B(1) + \frac{5}{14} B\left(\frac{3}{5}\right) \right] = \boxed{0.247}$$

$$Gain(\mathbf{Temperature}) = 0.9403 - \left[\frac{4}{14} B\left(\frac{2}{4}\right) + \frac{6}{14} B\left(\frac{4}{6}\right) + \frac{4}{14} B\left(\frac{3}{4}\right) \right] = 0.029$$

$$Gain(\mathbf{Humidity}) = 0.9403 - \left[\frac{7}{14} B\left(\frac{3}{7}\right) + \frac{7}{14} B\left(\frac{6}{7}\right) \right] = 0.1518$$

$$Gain(\mathbf{Windy}) = 0.9403 - \left[\frac{6}{14} B\left(\frac{3}{6}\right) + \frac{8}{14} B\left(\frac{6}{8}\right) \right] = 0.04813$$


O **ganho de informação** é maximizado com o atributo **Outlook**, que é, portanto, escolhido como o nó raiz da árvore.



Exemplo de indução com método ID3

- Agora, criamos **subconjuntos para cada um dos valores** do atributo **Outlook** e refazemos os cálculos do **ganho de informação** para cada um deles.
- Quando **Outlook = overcast**, o subconjunto abaixo mostra que os valores dos outros atributos não importam, sendo a classe escolhida sempre a **Positiva (P)**, ou seja, a **decisão será sempre pela classe Positiva se o tempo estiver nublado**.
- A **entropia nessa caso é igual a zero** (pois não há incerteza), indicando uma **folha** da árvore.
- Portanto, encontramos a folha deste ramo.

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
3	overcast	hot	high	false	P
7	overcast	cool	normal	true	P
12	overcast	mild	high	true	P
13	overcast	hot	normal	false	P



Exemplo de indução com método ID3

- Quando **Outlook = rain**

Outlook = rain		Jogar?		
		P	N	
Temperature	hot	0	0	0
	mild	2	1	3
	cool	1	1	2
				5

Outlook = rain		Jogar?		
		P	N	
Humidity	high	1	1	2
	normal	2	1	3
				5

Outlook = rain		Jogar?		
		P	N	
Windy	true	0	2	2
	false	3	0	3
				5


Entropia do objetivo para o subconjunto **Outlook = rain**: $H(y | \text{Outlook} = \text{rain}) = 0.971$

$$\text{Gain}(\text{Temperature}) = 0.971 - \left[\frac{0}{5} B\left(\frac{0}{0}\right) + \frac{3}{5} B\left(\frac{2}{3}\right) + \frac{2}{5} B\left(\frac{1}{2}\right) \right] = 0.02$$

$$\text{Gain}(\text{Humidity}) = 0.971 - \left[\frac{2}{5} B\left(\frac{1}{2}\right) + \frac{3}{5} B\left(\frac{2}{3}\right) \right] = 0.02$$

$$\text{Gain}(\text{Windy}) = 0.971 - \left[\frac{2}{5} B\left(\frac{0}{2}\right) + \frac{3}{5} B\left(\frac{3}{3}\right) \right] = \mathbf{0.971}$$

- Aqui, o atributo **Windy** resulta no valor de **ganho de informação** mais alto quando o tempo estiver chuvoso (i.e., **Outlook = rain**).
- Por isso, o atributo **Windy** será o nó do 2º nível da árvore, no ramo **rain** de **Outlook**.




Exemplo de indução com método ID3

- Se analisarmos o subconjunto onde **Outlook = rain** e **Windy = false**, percebemos que a decisão será sempre pela classe **Positiva (P)**. A entropia $H(y | \text{Outlook} = \text{rain}, \text{windy} = \text{false}) = 0$.

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
4	rain	mild	high	false	P
5	rain	cool	normal	false	P
10	rain	mild	normal	false	P

- Além disso, a decisão sempre será pela classe Negativa (N) se **Outlook = rain** e **Windy = true**. A entropia $H(y | \text{Outlook} = \text{rain}, \text{windy} = \text{true}) = 0$.

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
6	rain	cool	normal	true	N
14	rain	mild	high	true	N



- Portanto, encontramos as folhas para os dois ramos, **true** e **false** do nó **Windy**.

Exemplo de indução com método ID3

- Quando **Outlook = sunny**

Outlook = sunny		Jogar?		
		P	N	
Temperature	hot	0	2	2
	mild	1	1	2
	cool	1	0	1
				5

Outlook = sunny		Jogar?		
		P	N	
Humidity	high	0	3	3
	normal	2	0	2
				5

Outlook = sunny		Jogar?		
		P	N	
Windy	true	1	1	2
	false	1	2	3
				5


Entropia do objetivo para o subconjunto dado por **Outlook = sunny**: $H(y \mid \text{Outlook} = \text{sunny}) = 0.971$

$$\text{Gain}(\text{Temperature}) = 0.971 - \left[\frac{2}{5} B\left(\frac{0}{2}\right) + \frac{2}{5} B\left(\frac{1}{2}\right) + \frac{1}{5} B\left(\frac{1}{1}\right) \right] = 0.570$$

$$\text{Gain}(\text{Humidity}) = 0.971 - \left[\frac{3}{5} B\left(\frac{0}{3}\right) + \frac{2}{5} B\left(\frac{2}{2}\right) \right] = \boxed{0.971}$$

$$\text{Gain}(\text{Windy}) = 0.971 - \left[\frac{2}{5} B\left(\frac{1}{2}\right) + \frac{3}{5} B\left(\frac{1}{3}\right) \right] = 0.02$$

- Aqui, o atributo **Humidity** resulta no **ganho de informação** mais alto quando o tempo estiver ensolarado (i.e., **Outlook = sunny**).
- Por isso, o atributo **Humidity** será o nó do 2º nível da árvore no ramo **sunny**.




Exemplo de indução com método ID3

- O decisão sempre será pela classe **Positiva (P)** quando **Outlook = sunny** e **Humidity = normal**. A entropia $H(y | \text{Outlook} = \text{sunny}, \text{Humidity} = \text{normal}) = 0$.

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
9	sunny	cool	normal	false	P
11	sunny	mild	normal	true	P

- A decisão sempre será pela classe **Negativa (N)** quando **Outlook = sunny** e **Humidity = high**. A entropia $H(y | \text{Outlook} = \text{sunny}, \text{Humidity} = \text{high}) = 0$

Day	Attributes				Class (y)
	Outlook	Temperature	Humidity	Windy	
1	sunny	hot	high	false	N
2	sunny	hot	high	true	N
8	sunny	mild	high	false	N




- Portanto, encontramos as folhas para os dois ramos, **normal** e **high** do nó **Humidity**.
- Com isso, a construção da **árvore de decisão** se encerra e podemos usar as regras encontradas para classificar novos exemplos.
- **Algun atributo ficou de fora?** Sim, **Temperature**, indicando que ele não traz informação útil ao problema.

Considerações sobre as árvores de decisão



- Embora as **árvores de decisão** sejam poderosos algoritmos de **classificação**, elas podem apresentar um **longo tempo de treinamento, principalmente quando os atributos são contínuos**.
- Árvores de decisão **precisam de muito pouco pré-processamento dos dados**.
- Em particular, elas **não necessitam de escalonamento dos atributos**, mas **valores faltantes devem ser tratados de alguma forma**.

Considerações sobre as árvores de decisão



- Quando as **classes não são bem separadas** (sobreposição), **as árvores são suscetíveis a sobreajustar** ao conjunto de treinamento.
- Para evitar **sobreajuste**, existem duas maneiras:
 1. Limitamos sua profundidade e/ou o número mínimo de amostras necessárias em um nó folha.
 2. Geramos primeiro uma árvore completa e, em seguida, eliminamos alguns ramos (i.e., podamos a árvore).

Considerações sobre as árvores de decisão




- O **principal problema** das árvores é que elas são **muito sensíveis a rotações nos dados de treinamento**.
- Elas criam **fronteiras de decisão compostas por trechos perpendiculares aos eixos**, o que as torna **sensíveis à rotação do conjunto de treinamento**.
- Uma maneira para **minimizar** esse problema da sensibilidade à rotação é usar **análise de componentes principais (PCA)**, que rotaciona e dimensiona linearmente a matriz de atributos.


Considerações sobre as árvores de decisão

- Alguns **algoritmos para inferência de árvores são estocásticos** e, portanto, **podem gerar árvores completamente diferentes com o mesmo modelo e conjunto de dados, mas sementes aleatórias diferentes**.
- Por exemplo, o CART permuta aleatoriamente o conjunto de atributos a cada divisão, podendo gerar diferentes divisões.
- Se a melhoria do critério de divisão for idêntica para várias divisões, escolhe-se a divisão de forma aleatória.
- As **florestas aleatórias** podem limitar essa instabilidade calculando a média ou voto majoritário das predições feitas por diversas **árvores**.

Considerações sobre as árvores de decisão




Regularização



- Se não for restringida, a **árvore** poderá se adaptar muito bem aos dados de treinamento, se **sobreajustando** a eles.
- Para evitar o **sobreajuste** do modelo, nós precisamos **restringir a liberdade de crescer** da árvore durante seu treinamento.
 - Essa restrição é feita através de alguns hiperparâmetros.
 - Essa restrição pode ser visto como uma forma de **regularização**.

Considerações sobre as árvores de decisão



- O Scikit-Learn tem 2 classes de árvores que implementam o algoritmo CART:
 - `DecisionTreeClassifier`
 - `DecisionTreeRegressor`
- As **árvores de decisão** também tendem a se **sobreajustar** ao lidar com tarefas de **regressão**.
- Predições feitas por **árvores de regressão não são suaves nem contínuas**, mas **aproximações constantes por partes/trechos**, conforme visto na figura ao lado.
- O valor previsto para cada trecho é sempre o **valor médio** dos exemplos **nesse trecho**.

Considerações sobre as árvores de decisão

- A regularização destas árvores pode ser controlada pelos hiperparâmetros:
 - **max_depth**: profundidade máxima (i.e., número de níveis).
 - **min_samples_split**: número mínimo de exemplos um nó deve ter para poder ser dividido.
 - **min_samples_leaf**: número mínimo de exemplos que um nó folha deve ter.
 - **max_leaf_nodes**: número máximo de nós folha.
 - **max_features**: número máximo de atributos que são avaliados para criação de uma divisão (i.e., split).
- Aumentar os hiperparâmetros **min_*** ou reduzir os hiperparâmetros **max_*** regularizará o modelo.
- Como encontramos os melhores valores para os hiperparâmetros?
 - Usando validação cruzada, por exemplo.

Diferenças entre ID3 e CART

Característica	ID3	CART
Tipo de problema	Apenas classificação	Classificação + regressão
Critério de divisão	Ganho de informação	• Classificação: Gini e entropia • Regressão: EQM
Tipo de atributos	• Funciona melhor com dados categóricos • Não lida bem com dados contínuos (quantização)	• Lida naturalmente com: ▪ dados contínuos ▪ dados categóricos
Formato da árvore	• Pode gerar múltiplos ramos ▪ Ex.: Cor = {vermelho, azul, verde} → 3 ramos	• Sempre binária (2 ramos) ▪ Ex.: Cor ∈ {vermelho}? → sim/não
Repete atributo?	Não repete atributo no mesmo caminho (raiz → folha)	• Pode repetir atributo várias vezes no mesmo caminho • A cada divisão, todos os atributos são testados

Exemplo

- [Exemplo: árvores de decisão.ipynb](#)



Lista de exercícios

[Lista #12 – Árvores de decisão](#)

Perguntas?

Obrigado!

Anexo I: Cálculo da entropia para mais de duas classes

Cálculo da entropia para mais de duas classes

- Veja a tabela ao lado com os exemplos de treinamento.
- Problema com três classes: 0, 1, e 2. Portanto, o cálculo da entropia terá três termos.
- A **entropia** do objetivo, i.e., y , para o conjunto de treinamento é

$$H(y) = - \left[\frac{2}{4} \log_2 \left(\frac{2}{4} \right) + \left(\frac{1}{4} \right) \log_2 \left(\frac{1}{4} \right) + \left(\frac{1}{4} \right) \log_2 \left(\frac{1}{4} \right) \right] = 1.5$$

- Separando os atributos em tabelas separadas, temos

		Classes (y)			
		0	1	2	
x1	0	1	0	0	1
	1	0	0	1	1
	2	1	1	0	2
					4

		Classes (y)			
		0	1	2	
x2	0	2	0	0	2
	1	0	1	1	2
					4

Atributos		Rótulos
x1	x2	Classe (y)
0	0	0
2	1	1
1	1	2
3	0	0

- O **ganho de informação** de cada atributo é calculado como:

$$Gain(x1) = H(y) - \left\{ \frac{1}{4} H(x1 = 0) + \frac{1}{4} H(x1 = 1) + \frac{2}{4} H(x1 = 2) \right\}$$

$$Gain(x2) = H(y) - \left\{ \frac{2}{4} H(x2 = 0) + \frac{2}{4} H(x2 = 1) \right\}$$

Cálculo da entropia para mais de duas classes

Como exemplo do cálculo da entropia, vejamos como $H(x1 = 0)$ deve ser calculado.

$$\begin{aligned}
 H(x1 = 0) &= - \sum_{i=0}^2 p(y = i | x1 = 0) \log_2(p(y = i | x1 = 0)) \\
 &= -[p(y = 0 | x1 = 0) \log_2(p(y = 0 | x1 = 0)) + p(y = 1 | x1 = 0) \log_2(p(y = 1 | x1 = 0)) + \\
 &\quad p(y = 2 | x1 = 0) \log_2(p(y = 2 | x1 = 0))]
 \end{aligned}$$

Assim, os ganhos de informação para $x1$ e $x2$ são calculados como

$$\begin{aligned}
 Gain(x1) &= H(y) - \left\{ \frac{1}{4} H(x1 = 0) + \frac{1}{4} H(x1 = 1) + \frac{2}{4} H(x1 = 2) \right\} \\
 &= H(y) - \left\{ \frac{1}{4} \left[\frac{1}{1} \log_2 \left(\frac{1}{1} \right) \right] + \frac{1}{4} \left[\frac{1}{1} \log_2 \left(\frac{1}{1} \right) \right] + \frac{2}{4} \left[\frac{1}{2} \log_2 \left(\frac{1}{2} \right) + \frac{1}{2} \log_2 \left(\frac{1}{2} \right) \right] \right\}
 \end{aligned}$$

$$\begin{aligned}
 Gain(x2) &= H(y) - \left\{ \frac{2}{4} H(x2 = 0) + \frac{2}{4} H(x2 = 1) \right\} \\
 &= H(y) - \left\{ \frac{2}{4} \left[\frac{2}{2} \log_2 \left(\frac{2}{2} \right) \right] + \frac{2}{4} \left[\frac{1}{2} \log_2 \left(\frac{1}{2} \right) + \frac{1}{2} \log_2 \left(\frac{1}{2} \right) \right] \right\}
 \end{aligned}$$

Obs.:

- $H(0) = 0$
- $H(1) = 0$
- $0 * \log_2(0) = 0$

		Classes (y)			
		0	1	2	
x1	0	1	0	0	1
	1	0	0	1	1
	2	1	1	0	2
					4

		Classes (y)			
		0	1	2	
x2	0	2	0	0	2
	1	0	1	1	2
					4

Anexo II: Qual a entropia de 0?

Qual a entropia de 0?

- À primeira vista, pode parecer que $-x \log_2(x)$ é um valor indeterminado, pois resulta em $0 \times -\infty$. Porém, se fizermos uma pequena modificação na equação:

$$H(x) = -x \log_2(x) = -\frac{\log_2(x)}{\frac{1}{x}}.$$

e, na sequência, aplicarmos a regra de L'Hôpital, conseguimos encontrar o valor quando x se aproxima de zero do lado positivo (0_+):

$$\lim_{x \rightarrow 0_+} H(x) = \lim_{x \rightarrow 0_+} -\frac{\frac{1}{x \log_2(2)}}{-\frac{1}{x^2}} = \lim_{x \rightarrow 0_+} \frac{x}{\log_2(2)} = 0.$$

Assim, $H(x) = 0$.

Figuras

